

目录

4 线性空间与线性映射	3
4.1 线性空间	3
4.1.1 例子与概念	3
4.1.2 重要概念复习	5
4.1.3 向量的坐标表示	6
4.1.4 线性映射与线性同构	8
4.2 再论线性映射与矩阵	10
4.2.1 线性映射的矩阵表示	10
4.2.2 线性变换与坐标变换	12
4.2.3 * 主动观点与被动观点	14
4.3 线性映射的分解	16
4.3.1 矩阵的等价和相似	16
4.3.2 线性空间的直和分解	19
4.3.3 不变子空间直和分解	21
4.3.4 特征值与特征向量	22
4.4 习题	23
4.4.1 线性空间的概念	23
4.4.2 线性映射与矩阵	32
4.4.3 线性同构	34
5 矩阵的运算	39
5.1 矩阵的加法、数乘和乘法	39
5.1.1 基本性质	39
5.1.2 矩阵运算与秩	40
5.2 可逆矩阵与初等变换	42
5.2.1 可逆矩阵的性质	42
5.2.2 初等变换与初等矩阵	42
5.2.3 分块矩阵与分块初等变换	43
5.3 矩阵的转置	44
5.3.1 * 对偶空间	45
5.3.2 * 线性映射的转置	46
5.3.3 $\text{rank}(A^T) = \text{rank}(A)$	47
5.4 习题	48
5.4.1 秩相关的证明 I——分块矩阵法	48
5.4.2 秩相关的证明 II——线性映射法	53

5.4.3	特殊矩阵的性质分析	58
5.4.4	伴随矩阵	61
5.4.5	降阶公式	63
5.4.6	摄动法	65
6	矩阵的相抵与相似	67
6.1	基本概念提要	67
6.2	相似不变量	68
6.3	矩阵可对角化的一般条件	69
6.4	实对称矩阵的性质	71
6.5	习题	71
6.5.1	相抵标准型的计算	71
6.5.2	相抵标准型的应用	73
6.5.3	相似对角化的计算	76
6.5.4	对角化相关证明	77
6.5.5	* 相似对角化的应用	80
7	二次型	82
7.1	从代数到几何	82
7.1.1	实内积空间概述	82
7.1.2	内积的表示——正定实对称矩阵	83
7.1.3	广义内积的引入与表示——实对称矩阵	84
7.1.4	* 自伴算子	85
7.1.5	矩阵的合同	86
7.1.6	保度规变换与正交矩阵	87
7.2	矩阵合同的进一步讨论	88
7.2.1	合同标准型和规范型	88
7.2.2	规范型的进一步讨论	90
7.3	* 复内积空间	91
7.3.1	复内积的定义及其矩阵表示	91
7.3.2	自伴矩阵及其性质	92
7.4	习题	94
7.4.1	合同标准型和规范型	94
7.4.2	正定二次型	97
7.4.3	数学归纳法	102
7.4.4	* 二次型的应用	105

4 线性空间与线性映射

4.1 线性空间

4.1.1 例子与概念

在 n 维向量空间 $\mathbb{K}^n$ 中, “向量” 被规定为 n 维数组. 这种规定固然方便, 但是如果把它当作对于 “向量” 概念的分析, 却不太令人满意. 事实上, 如果抛开一切语境来问 “向量是什么?”, 似乎有点难回答. 我们一般会认为, “向量” 应当是一些能做加法和数乘, 可以反映方向性质的一类东西. 但是上述要求可以被各式各样的数学对象所承载, 并不限于 n 维数组. 以下略举几例, 请体会它们是否承载了我们熟悉的 $\mathbb{R}^2$ 所描述的向量的性质:

例 1 根据高中平面向量的观念定义所谓 “几何向量”: 把平面中的箭头 (有向线段) 称为向量, 箭头之间可以按平行四边形法则做加法, 用实数 k 的数乘代表箭头的 (有向) 长度变为原来的 k 倍. 任意两个不共线的箭头都可以唯一地线性表示出每个箭头.

例 2 复数域 $\mathbb{C}$. 任何一个复数 z 可以表示为 $a+bi$, 其中 $a, b \in \mathbb{R}$, 分别称为 z 的实部和虚部. z 可以看成 1 与 i 的线性组合, a 和 b 是组合系数. 两个复数 $z_1 = a_1 + b_1i$ 和 $z_2 = a_2 + b_2i$ 之间的加法规定为 $z_1 + z_2 = (a_1 + a_2) + (b_1 + b_2)i$, 复数 $z = a + bi$ 被实数 k 数乘规定为 $kz = ka + kbi$. 可以把复数用箭头的形式表示在复平面上, 则复数加法和数乘的几何意义就是箭头的加法和数乘.

例 3 线性方程组 $A_{m \times n} \mathbf{x} = \mathbf{0}$ 的解集 $\text{Ker } A$, 其中 $\text{rank}(A) = n - 2$. 我们此前证明过, $\text{Ker } A$ 是 $\mathbb{K}^n$ 的一个 2 维子空间. 可以取出 2 个线性无关的向量 ξ_1, ξ_2 作为基础解系, 并给出通解的形式 $c_1 \xi_1 + c_2 \xi_2$, $c_1, c_2 \in \mathbb{K}$.

上述 3 例, 虽然表现形式差异很大, 但似乎都能作为 “平面向量” 的实体来看待. 以下继续给出 3 个例子, 它们乍看与 “向量” 没什么关系, 但是细想之下, 其实相似之处极多.

例 4 常系数齐次线性微分方程 $y'' + y = 0$ 的通解. 在高等数学中曾经证明过, 该方程的任意两个解相加, 或者一个解乘以实数 k , 仍然是该方程的解 (即解集对加法和数乘封闭). 可以写出方程的通解 $C_1 \sin x + C_2 \cos x$. 其中, $\sin x$ 和 $\cos x$ 是方程的两个线性无关的特解, 称为基本解组.

例 5 电子的自旋量子态. 在特定方向上测量一个电子的自旋, 结果可能为上旋或者下旋, 分别记为 $|\uparrow\rangle$ 和 $|\downarrow\rangle$. 这两种状态是电子在该方向上自旋的本征态. 当一个电子未被测量时, 它的自旋状态可以被表示为本征态的一个特定的线性组合, 即所谓量子叠加态 $\lambda_1 |\uparrow\rangle + \lambda_2 |\downarrow\rangle$, 其中 $\lambda_1, \lambda_2 \in \mathbb{C}$.

例 6 $\mathbb{R}$ 上不超过 1 次的多项式集合 $\mathbb{R}_1[x]$. 其中的每个元素 $f(x)$ 可以表示为 $ax+b$, 其中 $a, b \in \mathbb{R}$. $\mathbb{R}_1[x]$ 中的加法和数乘即是多项式的加法和数乘. 确定 $\mathbb{R}_1[x]$ 中的元素只需确定一次项系数 a 和常数项 b . 换句话说, $\mathbb{R}_1[x]$ 中的元素可以看成 x 与 1 的线性组合, a 和 b 是组合系数.

用心体会这 6 个例子与 $\mathbb{R}^2$ 的共同点, 你可能感觉到所有这些例子从某种角度上可以说是“本质没有区别”的. 具体有哪些共同点呢? 不妨停下来想一想, 再看是否和我总结的一样:

(1) 在某个集合 V 中, 规定了加法和数乘两种运算. 注意数乘需要使用到 V 之外的“数”, 因此需要给 V 指派一个数域 $\mathbb{K}$ 作为数乘所用的“数”. 上述大部分例子中指派的数域都是 $\mathbb{R}$, 只有例 5 使用的是 $\mathbb{C}$. 加法和数乘对于集合 V 必须是封闭的.

(2) 可以选出 V 中 2 个线性无关的元素 (请自行回顾“线性无关”的含义), V 中的任何一个元素都能唯一地表示为它们的线性组合. 因此, 这 2 个元素在 V 中扮演了基础性的角色. 无论是线性方程组的“基础解系”, 齐次线性微分方程的“基本解组”, 还是粒子的“本征态”, 都体现了类似的概念. 这实际上就是为 V 找到了一组基.

对于加法和数乘上的共同点, 需要思考地更深入一些. 形式化地说, 所谓加法就是 $V \times V \rightarrow V$ 的二元映射, 所谓数乘就是 $\mathbb{K} \times V \rightarrow V$ 的二元映射. 但是, 所谓的“二元映射”浩如烟海, 其中许多连加法结合律, 加法交换律之类最基本的运算规律都不满足, 这当然不符合我们对“向量”的要求. 因此, 我们需要对向量的运算性质做一些基本的规定. 事实上, 在 $\mathbb{R}^n$ 中, 我们曾经总结过 8 条运算性质 (请先自行回顾, 在后文会重新列举一遍). 这正是我们现在所需要的.

经过以上的思考, 我们把众多例子的共同点给刻画了出来. 这就自然地引出了线性空间的定义. 可以认为这是对“向量”的一种更抽象也更泛用的定义.

线性空间的定义 设 V 是一个集合. 为它指派一个数域 $\mathbb{K}$, 并在 V 中定义元素之间的加法和数乘, 满足以下 8 条规则, 那么称 V 是数域 $\mathbb{K}$ 上的线性空间, V 中的元素称为向量:

- (1) 加法单位元: V 中存在唯一的零元素 $\mathbf{0}$, 使得对任意 $x \in V$, $\mathbf{0} + x = x$.
- (2) 加法结合律: $x_1 + (x_2 + x_3) = (x_1 + x_2) + x_3$, $\forall x_1, x_2, x_3 \in V$.
- (3) 加法的逆: $\forall x \in V$, 存在一个它的“负元素” $-x$, 使得 $x + (-x) = \mathbf{0}$.
- (4) 加法交换律: $x_1 + x_2 = x_2 + x_1$, $\forall x_1, x_2 \in V$.
- (5) 数乘单位: $1 \cdot x = x$, $\forall x \in V$.
- (6) 数乘结合律: $k(lx) = (kl)x$, $\forall k, l \in \mathbb{K}$, $x \in V$.
- (7) 数乘分配律 I: $k(x_1 + x_2) = kx_1 + kx_2$, $\forall k \in \mathbb{K}$, $x_1, x_2 \in V$.
- (8) 数乘分配律 II: $(k + l)x = kx + lx$, $\forall k, l \in \mathbb{K}$, $x \in V$.

按此定义, 之前给出的所有 6 个例子全都是线性空间. 其中, 电子的自旋量子态构成 $\mathbb{C}$ 上的线性空间, 其余是 $\mathbb{R}$ 上的线性空间.

关于线性空间的概念做几条注记:

(1) 我们对线性空间中的元素“长得如何”是只字不提的, 无所谓它是箭头、数组, 甚至是函数、多项式、量子态等等. 即: 我们不会用“向量长什么样”的方式来回答“向量是什么”的问题, 而是会说“向量是满足 xxx 性质的一类数学对象”. 至于箭头、数组、量子态等都是向量的具体例子. 这种观点相比以前更加抽象, 但是抓住了向量最本质的特点.

(2) 中学阶段认为, 向量是一种“既有大小又有方向”的量. 但是现在把向量看作线性空间的元素, 这说法就是完全错误的了. 所谓大小、长度等概念, 在线性空间中称为**范数**; “方向”则是由**内积**给出 (即计算向量的“夹角”). 然而线性空间的定义本身并没有给出向量的范数和内积, 它们是需要额外附加的装备. 例如, 目前我们知道例 4 中的函数集合 $C_1 \sin x + C_2 \cos x$ 构成线性空间, 此时谈论函数的“大小”和“方向”似乎是毫无意义的, 必须在指定了范数和内积结构之后才能谈论 (参见高等数学傅里叶级数章节).

(3) 线性空间定义中的 8 条规则如同线性空间中的“公理”, 其他我们所熟知的向量运算性质, 即使看起来十分显然, 也不是天生就有的, 需要通过这 8 条规则证明出来. 比如, 可以尝试证明 $0 \cdot \boldsymbol{x} = \mathbf{0}$, $(-1) \cdot \boldsymbol{x} = -\boldsymbol{x}$.

(4) 注意区分数域 $\mathbb{K}$ 中的数 0 与线性空间 V 中的零元素 $\mathbf{0}$ (零向量). 也许在某些情况下你会忘记这种区分, 比如把 $\mathbb{C}$ 看作 $\mathbb{R}$ 上的线性空间时, $\mathbb{C}$ 中的 0 和 $\mathbb{R}$ 中的 0 一样吗? 按线性空间的定义来说是不一样的. 同理, 也要注意区分数域中的加法乘法与线性空间中的加法和数乘. 不同的线性空间的加法和数乘亦有不同, 但习惯上都以 $+$ 和 $\cdot$ (常常省略) 表示, 需要特别小心.

(5) 在线性代数中, 大部分结论与线性空间所配套的数域 $\mathbb{K}$ 无关 (例如第二章中讲到的内容), 甚至换成更一般的域 F 也成立. 因此我们经常省略数域 $\mathbb{K}$ 不提,

(6) 第一次接触线性空间这种抽象化概念可能有陌生感. 其实它的性质和向量空间 $\mathbb{R}^n$ 完全没有区别, 只不过“向量”的表现形式不同而已. 接下来的小节将详细解释这一点.

4.1.2 重要概念复习

之前在 $\mathbb{R}^n$ 中讨论过的许多概念都可以照搬进一般的线性空间中讨论, 只不过把“ $\mathbb{R}^n$ 中的元素”替换为“线性空间 V ”中的元素. 作为复习, 这里把概念的定义重新写一遍.

线性子空间 设 V 是线性空间, V_0 是 V 的一个子集. 如果 V_0 对 V 中规定的加法和数乘封闭, 则称 V_0 是 V 的一个线性子空间, 简称子空间.

注 1: 该定义其实就是要求 V_0 作为线性空间 V 的子集也是一个线性空间.

注 2: $\{0\}$ 与 V 都是 V 的线性子空间, 它们分别是 V 的最小和最大的子空间, 称为平凡子空间.

注 3: 线性子空间 V_0 的加法和数乘必须是从 V 直接继承而来, 而不是为 V_0 规定一种不同于 V 中的加法和数乘运算.

线性相关/线性无关 线性空间 V 中的向量组 $\alpha_1, \alpha_2, \dots, \alpha_s$ ($s \geq 1$) 是线性相关的, 当且仅当有数域 $\mathbb{K}$ 中的一组不全为 0 的系数 $k_1, k_2, \dots, k_s$, 使得

$$k_1\alpha_1 + k_2\alpha_2 + \dots + k_s\alpha_s = 0$$

反之, 如果上式成立可以推出系数 $k_1, k_2, \dots, k_s$ 全为 0, 那么称该向量组是线性无关的.

极大线性无关组 设 $\{v_1, v_2, \dots, v_s\}$ 是线性空间 V 的一个向量组. 如果它的一个部分组本身是线性无关的, 但是从向量组的其余向量 (如果还有的话) 中任取一个添进去, 得到的新部分组都线性相关, 称它是一个极大线性无关组.

注: 一个向量组的极大线性无关组的向量个数是唯一的, 这一点并不那么显然. 详见第二章的讨论.

线性空间的基 把整个线性空间 V 看成一个无穷向量组, 它的一个极大线性无关组就是线性空间 V 的一组基. 展开来说, V 中的一个向量组要成为 V 的一组基当且仅当以下两个条件都满足: (1) 该向量组线性无关; (2) 该向量组能线性表示 V 中的每个向量.

线性空间的维数 线性空间 V 的一组基的向量个数称为 V 的维数, 记作 $\dim V$.

注: 在线性代数中, 默认只讨论有限维的线性空间.

4.1.3 向量的坐标表示

对于任意的 n 维线性空间 V , 都能选取它的 n 个线性无关向量作为一组基, 用它线性表示 V 中的每个向量, 且表示方法唯一. 这是我们之前总结的线性空间的重要共同点.

我们在中学阶段会用解析几何的办法把几何问题给代数化, 基本方法是建立平面/空间直角坐标系, 把几何上的点 (向量) 用坐标来表示, 极大地方便了计算. 所谓坐标, 其实就是 $\mathbb{K}^n$ 中的元素 (中学的平面坐标是 $\mathbb{R}^2$ 中的元素, 空间坐标是 $\mathbb{R}^3$ 中的元素). 在线性代数中, 我们又学习了矩阵和行列式等工具, 它们把线性映射和向量的问题归结到数域 $\mathbb{K}$ 中进行计算. 我们自然希望在一般的线性空间 V 中使用这些工具. 第一步便是设法把 V 中元素表示成坐标.

设 V 是 n 维线性空间, $\{e_1, e_2, \dots, e_n\}$ 是 V 的一组基. 任取 V 中的一个向量 α , 则它可以唯一地用这组基线性表示:

$$\alpha = x_1 e_1 + x_2 e_2 + \dots + x_n e_n$$

所谓“唯一”, 就是说如果给定 $\{e_1, e_2, \dots, e_n\}$ 这组基, 线性表示的系数 $(x_1, x_2, \dots, x_n)$ 对 α 来说是唯一的. 我们把这组系数称为 α 在这组基下的坐标. 这样, 对于 n 维线性空间 V 里的每个元素, 都能唯一地给它分配一个坐标. 同一个向量不可能拥有两个不同的坐标, 每一个坐标也必定对应了某个向量. 以上的事实用更形式化的方式来描述是这样的 (这个描述很重要):

对于数域 $\mathbb{K}$ 上的 n 维线性空间 V , 给定了它的一组基 $\{e_1, e_2, \dots, e_n\}$, 那么我们会有 $V \rightarrow \mathbb{K}^n$ 的一个双射 φ (可以非正式地称它为“坐标映射”), 它的映射规则如下:

$$\alpha = a_1 e_1 + a_2 e_2 + \dots + a_n e_n \mapsto (a_1, a_2, \dots, a_n)$$

即我们用 $\varphi(\alpha)$ 表示 α 在基 $\{e_1, e_2, \dots, e_n\}$ 下的坐标. 坐标为研究线性空间提供了必要的计算工具. 不久之后我们会学习如何用 $\mathbb{K}^n$ 中的工具计算线性映射和基变换等等. 但是在开始动手之前, 需要解决一些理论问题.

首先, 我们提出坐标的概念是希望线性空间 V 中向量的运算可以转化到 $\mathbb{K}^n$ 中完成, 如何确保这种“转化”是合理的? 我们已经知道坐标映射 φ 是一个双射. 但这个说法还不全面. 我们以一个简单的情形为例: 2 维线性空间 V 中的 2 个向量 α 和 β . 假设它们在基 $\{e_1, e_2\}$ 下的坐标 $\varphi(\alpha)$ 和 $\varphi(\beta)$ 分别是 (a_1, a_2) 和 (b_1, b_2) . 你能够立即说出向量 $\alpha + \beta$ 的坐标是 $(a_1 + a_2, b_1 + b_2)$, 向量 $k\alpha$ 的坐标是 (ka_1, ka_2) ——这些计算是如此顺手以至于你可能都忘了这是从 φ 的定义推出来的:

$$\begin{aligned}\varphi(\alpha + \beta) &= \varphi(a_1 e_1 + a_2 e_2 + b_1 e_1 + b_2 e_2) = \varphi((a_1 + b_1)e_1 + (a_2 + b_2)e_2) \\ &= (a_1 + b_1, a_2 + b_2) = \varphi(\alpha) + \varphi(\beta) \\ \varphi(k\alpha) &= \varphi(k(a_1 e_1 + a_2 e_2)) = \varphi(ka_1 e_1 + ka_2 e_2) \\ &= (ka_1, ka_2) = k \cdot \varphi(\alpha)\end{aligned}$$

同理, 在一般的 n 维线性空间中, 在任何一组基下, 坐标映射 $\varphi: V \rightarrow \mathbb{K}^n$ 有如下性质:

$$\begin{aligned}\varphi(\alpha + \beta) &= \varphi(\alpha) + \varphi(\beta) \\ \varphi(k \cdot \alpha) &= k \cdot \varphi(\alpha)\end{aligned}$$

注意, 符号 $+$ 和 $\cdot$ 在等式两侧的含义是不同的. 在等式左侧它们表示 n 维线性空间 V 中的加法和数乘, 在等式右侧它们表示 n 维向量空间 $\mathbb{K}^n$ 中的加法和数乘. 这两条式子的含义是: 在映射

φ 下, V 中的加法和数乘与 $\mathbb{K}^n$ 中的加法和数乘是一致的, 用坐标来代表 V 中的向量进行加法和数乘运算不会产生错误. 更凝练地说, φ 保持加法和数乘运算, 即保持线性空间的结构.

总而言之, φ 满足两个条件. 第一, φ 是 V 与 $\mathbb{K}^n$ 之间的双射. 这说明, 从集合的角度来讲, V 与 $\mathbb{K}^n$ 的元素数量是“一样多”的. 第二, φ 保持 V 和 $\mathbb{K}^n$ 的加法和数乘运算. 这比集合的条件更进一步, 说明了 V 和 $\mathbb{K}^n$ 的线性结构也是一样的. 我们知道, 线性空间的概念其实就是集合附加了线性结构, 所以上述两个条件就保证了 V 与 $\mathbb{K}^n$ 作为线性空间来说完全相同, 达到了无法区分的地步. 既然如此, 用 $\mathbb{K}^n$ 去计算 V 中的加法和数乘当然就没问题了.

4.1.4 线性映射与线性同构

我们把上一小节关于坐标映射 φ 的讨论推广到任意两个线性空间之间. 给出如下定义:

线性映射 设 V 和 W 都是数域 $\mathbb{K}$ 上的线性空间. $\mathcal{A}$ 是 $V \rightarrow W$ 的映射. 如果 $\mathcal{A}$ 满足以下两个条件:

$$(1) \mathcal{A}(\alpha + \beta) = \mathcal{A}(\alpha) + \mathcal{A}(\beta), \forall \alpha, \beta \in V.$$

$$(2) \mathcal{A}(k \cdot \alpha) = k \cdot \mathcal{A}(\alpha), \forall \alpha \in V, k \in \mathbb{K}.$$

则称 $\mathcal{A}$ 是 $V \rightarrow W$ 的线性映射. 换句话说, 线性映射就是两个线性空间之间保持加法和数乘的映射.

在第二章中, 我们花了较多篇幅讨论 $\mathbb{K}^n \rightarrow \mathbb{K}^m$ 的线性映射. 当时我们说“线性映射就是矩阵, 矩阵就是线性映射”. 现在虽然将线性映射的概念推广到任意的线性空间中, 但是线性空间中的元素又都可以用 $\mathbb{K}^n$ 中的元素作为坐标来表示, 自然可以想到, 推广之后的线性映射也可以写成矩阵, 称为**线性映射的表示矩阵**. 进而可以用矩阵的加法来表示线性映射的加法, 用矩阵的乘法来表示线性映射的复合. 先来看几个最简单的概念和例子:

(1) 设 V 和 W 都是数域 $\mathbb{K}$ 上的线性空间. 若线性映射 $\mathcal{A}: V \rightarrow W$ 满足 $\mathcal{A}(\alpha) = \mathbf{0}$. 则称它是**零映射**, 记为 $\mathbf{0}$. 这种线性映射用零矩阵表示.

(2) 设 V 是数域 $\mathbb{K}$ 上的 n 维线性空间. 若 $\mathcal{A}$ 是 $V \rightarrow V$ 的线性映射, 则称 $\mathcal{A}$ 是 V 上的**线性变换**. 线性变换都用 n 阶方阵表示.

(3) V 到自身的恒等映射就称为**恒等变换**, 记作 id_V 或者 $\mathcal{I}_V$. 在不至于引起混淆的条件下, 可以省略下标 V . 恒等映射用单位矩阵表示.

(4) 线性映射既然也是一类映射, 自然可以讨论它是否是单射或者满射. 根据映射的知识, 如果一个映射既是单射又是满射, 就称它是双射. **单线性映射**的表示矩阵是列满秩的; **满线性映射**的表示矩阵是行满秩的 (证明见习题部分). 在此基础上, 给出如下定义:

线性同构 设 V 和 W 是数域 $\mathbb{K}$ 上的线性空间. 若线性映射 $\sigma: V \rightarrow W$ 既是单射又是满射, 称它是一个线性同构映射, 简称同构映射或同构. 一个线性空间到自身的线性同构映射称为自同构. 若 V 和 W 之间存在线性同构映射, 称这两个线性空间是同构的, 记作 $V \cong W$.

从矩阵的观点看, 同构映射对应的矩阵既行满秩又列满秩, 也就是说矩阵是满秩的方阵. 熟悉矩阵性质的你可能意识到这就是在说可逆矩阵. 从映射的观点看, 同构映射既然是双射, 那就是可逆映射, 对应的矩阵当然是可逆矩阵. 两种观点互为对方的“翻译”.

线性同构的意义在于, 从集合的角度来说, 同构的两个线性空间是“一样大”的; 从线性结构的角度来说, 同构保持了两个空间的线性结构. 而因为线性空间的定义无非是在集合上装备了线性结构, 同构的两个线性空间是“结构完全相同, 没必要区分”的. 我们可以进一步说明线性空间的同构是一种等价关系 (证明见习题部分):

(1) 反身性: 对任意线性空间 V , $V \cong V$. 即存在 $V \rightarrow V$ 的同构映射. 显然, V 上的恒等变换 id_V 是 V 的自同构.

(2) 对称性: 若 $V \cong W$, 则 $W \cong V$ 也成立. 即: 若存在同构映射 $\sigma: V \rightarrow W$, 则一定能找到 $W \rightarrow V$ 的一个同构映射. 因为同构映射 $\sigma: V \rightarrow W$ 是双射, 也是可逆映射, 所以存在 σ 的逆映射 $\sigma^{-1}: W \rightarrow V$. 容易验证它是 $W \rightarrow V$ 的同构映射.

(3) 传递性: 若 $U \cong V, V \cong W$, 则 $U \cong W$. 即若存在同构映射 $\sigma_1: U \rightarrow V$ 和 $\sigma_2: V \rightarrow W$, 则一定能找到 $U \rightarrow W$ 的同构映射. 这条件让人联想起映射的复合. 容易验证复合映射 $\sigma_2 \circ \sigma_1: U \rightarrow W$ 是同构映射.

同构是代数学中最重要的等价关系. 在代数学中, 我们一般不关心集合的“实体”长什么样, 只关心代数体系的代数结构. 代数结构相同的代数体系在我们看来是没有区别的. 同构的概念就完美地刻画了这一点. 对于一类代数体系, 如果能够完全讲清楚它同构的意义下如何分类 (即给出完备的不变量, 或是能够写出每个等价类的一个代表元), 对于这类代数体系的研究就彻底清楚了, 再高明的数学家来到这个领域也没有任何新的问题可做.

线性空间就是这样的一类代数体系, 它的同构分类不仅能说清楚, 而且还异常简单. 在上一节中, 我们实际上证明了坐标映射 φ 是任意 n 维线性空间 V 到 $\mathbb{K}^n$ 的线性同构映射. 也就是说: 任何数域 $\mathbb{K}$ 上的 n 维线性空间都同构于 $\mathbb{K}^n$. 根据同构的传递性: 所有数域 $\mathbb{K}$ 上的 n 维线性空间都同构.

最后这个结论非常漂亮, 它说明, 只要确定了线性空间的数域 $\mathbb{K}$ 和维数, 在同构的意义下就唯一确定了一个线性空间. 我们完全可以用讨论 $\mathbb{K}^n$ 的方式来讨论一切有限维线性空间. 同时也意味着, 一切线性映射都可以按照 $\mathbb{K}^n \rightarrow \mathbb{K}^m$ 的线性映射, 即使用矩阵作为工具来理解.

4.2 再论线性映射与矩阵

4.2.1 线性映射的矩阵表示

本小节的目标是把任意线性空间上的线性映射与 $\mathbb{K}^n \rightarrow \mathbb{K}^m$ 的线性映射建立起联系，即：把任意 n 维线性空间到 m 维线性空间的线性映射用 $m \times n$ 矩阵表示出来。

我们曾写出过一些 $\mathbb{R}^2$ 上线性变换的矩阵. $\mathbb{R}^2$ 线性空间是平面几何的代表. 因此, 可以利用平面几何知识, 推导变换后的向量 (y_1, y_2) 关于变换前的向量 (x_1, x_2) 的线性方程组 (例如: 向量 (x_1, x_2) 逆时针旋转 θ 角的坐标是什么?). 但是所谓的“几何知识”在一般的线性空间中就用不上了.

例 考虑 $\mathbb{R}$ 上的线性空间 $\langle \sin x, \cos x \rangle$. 定义映射 $\mathcal{D}$ 是函数的求导变换, 即 $\mathcal{D}(f(x)) = \frac{d}{dx}f(x)$. 则 $\mathcal{D}$ 是 $\langle \sin x, \cos x \rangle$ 上的线性变换.

我们很容易把这个空间中的任意元素 $c_1 \sin x + c_2 \cos x$ 表示成坐标 (c_1, c_2) . 但是如何写出线性映射 $\mathcal{D}$ 的表示矩阵呢? 虽然没有直观的几何知识帮助, 但是掌握恰当的方法便不难. 先在 $\mathbb{K}^n \rightarrow \mathbb{K}^m$ 的线性映射中观察规律. 设 A 是 $m \times n$ 矩阵, 按列分块表示为 $A = (\alpha_1, \alpha_2, \dots, \alpha_n)$. $\{e_j\}$ 是 $\mathbb{K}^n$ 的标准正交基. 则由矩阵乘法的规则可知, $Ae_j = \alpha_j$. 也就是说, $\{e_j\}$ 被矩阵 A 作用得到的是 A 的第 j 个列向量 (图 4.1). 因此, 我们并不需要通过完全地写出 $y = Ax$ 的公式才能确定 A , 而是只需要计算 n 个最简单的向量 $\{e_j\}$ 被 A 作用的结果, 把它们依次以列向量的形式排列就得到了矩阵 A .




图 4.1: $\mathbb{R}^2$ 上旋转变换的矩阵

从这个想法也看出“基”在线性空间中的重要地位：一个线性映射被它作用在一组基上的像所唯一确定. 刚刚我们在 $\mathbb{K}^n \rightarrow \mathbb{K}^m$ 的线性映射中认识了这一点. 而因为任意 n 维线性空间 V 都

和 $\mathbb{K}^n$ “没区别”，这一点对于任意线性空间之间的线性映射都适用. 我们就依据这个原理写出任意线性映射的表示矩阵.

设 V 与 W 分别是数域 $\mathbb{K}$ 上的 n 维与 m 维线性空间. $\{e_1, e_2, \dots, e_n\}$ 是 V 的一组基. $\{f_1, f_2, \dots, f_m\}$ 是 W 的一组基. V 和 W 中的向量可以在各自的基下写出坐标来. 设 V 中向量 x 在 $\{e_i\}$ 下的坐标是 $(x_1, x_2, \dots, x_n)$. 现在设 $\mathcal{A}: V \rightarrow W$ 是线性映射, 且已知 V 的基向量在 $\mathcal{A}$ 下的像 $\mathcal{A}(e_i)$. 如何用矩阵形式求出 $y = \mathcal{A}(x)$ 在 W 的基 f_i 下的坐标 $(y_1, y_2, \dots, y_m)$? 我们只需要写出每个 $\mathcal{A}(e_i)$ 在 W 的基 f_i 下的坐标:

$$\begin{aligned}\mathcal{A}(e_1) &= a_{11}f_1 + a_{21}f_2 + \dots + a_{m1}f_m \mapsto (a_{11}, a_{21}, \dots, a_{m1}) \\ \mathcal{A}(e_2) &= a_{12}f_1 + a_{22}f_2 + \dots + a_{m2}f_m \mapsto (a_{12}, a_{22}, \dots, a_{m2}) \\ &\dots \\ \mathcal{A}(e_n) &= a_{1n}f_1 + a_{2n}f_2 + \dots + a_{mn}f_m \mapsto (a_{1n}, a_{2n}, \dots, a_{mn})\end{aligned}$$

将这些坐标以列向量的形式依次排列拼成一个矩阵:

$$A_{m \times n} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$

这就是线性映射 $\mathcal{A}$ 在基 $\{e_i\}$ 和基 $\{f_i\}$ 下的表示矩阵. 它的作用是把 $x \in V$ 在基 $\{e_i\}$ 下的坐标 $(x_1, x_2, \dots, x_n)$ 映为 $y = \mathcal{A}(x)$ 在基 $\{f_i\}$ 下的坐标 $(y_1, y_2, \dots, y_m)$, 映射规则以矩阵乘法的形式给出:

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{pmatrix}$$

特别需要注意的是, 用矩阵表示线性映射时, 必须说出选取的是 V 和 W 的哪一组基. 选取的基不同, 表示矩阵也会不同. 这个道理和向量的坐标表示一样. 因此, 可以把矩阵看作是线性映射的“坐标”. 这个观念与在 $\mathbb{K}^n$ 中有所不同. 原来我们认为, “矩阵就是线性映射”. 现在我们认为, **矩阵是线性映射在给定基下的表示**. 因此, 今后在一般的线性空间中, 我们必须开始严格区分“线性映射”与“矩阵”的概念, 正如我们必须区分“向量”与“坐标”的概念一样.

对于向量, 我们有任意 n 维线性空间 V 同构于 $\mathbb{K}^n$ 的结论, 即坐标的线性运算可以代表向量的线性运算. 线性映射和矩阵之间也有类似的关系.

设 V 是 n 维线性空间, W 是 m 维线性空间, 记 $\text{Hom}(V, W)$ 是全体 $V \rightarrow W$ 的线性映射的集合, 记数域 $\mathbb{K}$ 上全体 $m \times n$ 矩阵的集合是 $M_{m \times n}(\mathbb{K})$. 可以证明二者皆为数域 $\mathbb{K}$ 上的 mn 维线性空间, 因此二者作为线性空间是同构的. 此外, 线性映射有复合运算, 矩阵有乘法运算, 二者的乘法结构是一致的. 即: **两个线性映射的复合的表示矩阵, 就是两个线性映射的表示矩阵的乘积.** 因此, 我们完全可以用矩阵的加法、数乘和乘法运算来代表线性映射的加法、数乘和复合运算.

4.2.2 线性变换与坐标变换

设 V 是数域 $\mathbb{K}$ 上的 n 维线性空间. $\mathcal{A}$ 是其上的线性变换. 既然是在同一个空间, 对于映射前后的向量 $\mathbf{x}$ 与 $\mathbf{y} = \mathcal{A}(\mathbf{x})$, 完全可以选择同一组基 $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$ 来写出它们的坐标 (分别记为 $\mathbf{X}$ 和 $\mathbf{Y}$), 不用自找麻烦地选择两组不同的基. 此时可以写出 $\mathcal{A}$ 在这组基下的表示矩阵及坐标映射规则:

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \iff \mathbf{Y} = \mathbf{A}\mathbf{X}$$

可以看到表示矩阵 $\mathbf{A}$ 是 n 阶方阵. 它的第 i 个列向量就是 $\mathcal{A}(\mathbf{e}_i)$ 在基 $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$ 下的坐标.

目前为止, 我们一直在讨论线性映射: V 中的向量 $\mathbf{x}$ 被变换成了另一个向量 $\mathbf{y}$. 在同一组基下, 变换前后的向量坐标不同, 变换的规则由矩阵方程 $\mathbf{Y} = \mathbf{A}\mathbf{X}$ 描述. 然而也可以用一种截然不同的角度理解这个方程: $\mathbf{X}$ 和 $\mathbf{Y}$ 是同一个向量在两组不同的基下的坐标, $\mathbf{Y} = \mathbf{A}\mathbf{X}$ 描述的是基变换下同一个向量坐标的变换规则. 简而言之, **线性变换说的是基不变, 向量在变, 而坐标变换说的是向量不变, 基在变.**

为什么同一条公式能引入两种不同的理解? 我们以旋转变换为例说明. 在图4.2中, 左侧展示的是 $\mathbb{R}^2$ 上逆时针旋转 θ 角的线性变换. 以 $\{\mathbf{e}_1, \mathbf{e}_2\}$ 为基, 浅蓝色点所代表的向量 $\mathbf{x}$ 坐标是 $\mathbf{X} = (x_1, x_2)^T$, 它在被旋转之后变成了另一个向量 $\mathbf{y}$, 其坐标为 $\mathbf{Y} = (y_1, y_2)^T$. 而右图则展示了一个相反的操作: 把浅蓝色点所代表的向量固定不动, 而把基 $\{\mathbf{e}_i\}$ 顺时针旋转 θ 角, 变成了一组新基 $\{\mathbf{f}_i\}$. 在这组新的基下, 同一个向量又获得了新坐标 $\mathbf{Y} = (y_1, y_2)^T$.




图 4.2: 向量旋转 vs 坐标系旋转

“向量逆时针旋转 θ 角”与“坐标系（基）顺时针旋转 θ 角”这两件事真的有任何区别吗？细想之下，图4.2中 x_1 与 x_2 坐标轴虽然看似总是固定不动，但只是我们以纸面（或者电子屏幕）为参照物的错觉。在我们讨论问题的过程中，并未引入第三个坐标系或参考物，那么我们实际上无从判断 x_1 与 x_2 坐标轴的“方向”究竟是变了还是没变。因此，“向量逆时针旋转 θ 角”与“坐标系（基）顺时针旋转 θ 角”只是对同一个相对运动现象的两种不同描述。

借助这个例子，我们很直观地看到：对一个向量施加线性变换 A 的效果，与对一组基施加一个逆向的线性变换 A^{-1} 的效果是等同的。这是一个相当自然的原理，因此这里省去篇幅不再解释如何证明它。我们只解释如何更严肃地用数学语言描述线性变换与坐标变换的关系。设 V 中的一组基 $\{e_i\}$ 变换成 $\{f_i\}$ 。别忘了，一组基在映射下的像可以唯一确定一个线性映射 B 。我们写出 B 在基 $\{e_i\}$ 下的表示矩阵。先写出 $\{f_i\}$ 在基 $\{e_i\}$ 下的展开以及坐标：

$$\begin{aligned} f_1 &= B(e_1) = a_{11}e_1 + a_{21}e_2 + \cdots + a_{n1}e_n \mapsto (a_{11}, a_{21}, \cdots, a_{n1}) \\ f_2 &= B(e_2) = a_{12}e_1 + a_{22}e_2 + \cdots + a_{n2}e_n \mapsto (a_{12}, a_{22}, \cdots, a_{n2}) \\ &\vdots \\ f_n &= B(e_n) = a_{1n}e_1 + a_{2n}e_2 + \cdots + a_{nn}e_n \mapsto (a_{1n}, a_{2n}, \cdots, a_{nn}) \end{aligned}$$

将这些坐标以列向量的形式依次排列拼成一个矩阵，就得到 B 在基 $\{e_i\}$ 下的表示矩阵：

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

请注意，因为 $\{e_i\}$ 的像 $\{f_i\}$ 是 V 的一组基，是一个线性无关的向量组，因此 B 在基 e_i 下

的表示矩阵是列满秩的，即：基变换 B 一定是可逆变换，即 V 的一个自同构，其表示矩阵是可逆矩阵。在教材中，往往会引进一种形式写法来表示基变换：

$$(f_1, f_2, \dots, f_n) = (e_1, e_2, \dots, e_n) \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

其中的“行向量”是由 V 的一组基而非数域 $\mathbb{K}$ 的元素构成，只是在形式上用矩阵方程表示它们之间的关系。在这种写法下，等式右侧的 n 阶方阵与之前给出的 B 的表示矩阵是一样的。这个矩阵称为从 $\{e_i\}$ 到 $\{f_i\}$ 的过渡矩阵。而基的线性变换引起了一个坐标变换 $Y = AX$ 。这里的坐标变换矩阵 A 即是过渡矩阵之逆。

4.2.3 * 主动观点与被动观点

对于同一个矩阵方程 $Y = AX$ ，现在有了两种不同的理解：

- (1) **主动观点：**坐标系没动，向量按照矩阵 A 变换，连同着它的坐标从 X 变成了 Y 。
- (2) **被动观点：**向量没动，基按照矩阵 A^{-1} 变换，引起向量的坐标从 X 变换成 Y 。

正如本节一开始所讨论的，这两种观点等价性很明显，甚至是不言而喻的。但其中的意义却很深刻，可以帮助我们理解许多有趣的问题。

为了提高被动观点的可视化程度，我们可以通过灰色的坐标网格线来展示坐标系的变化。坐标网格以平行等距的形式绘制。根据线性变换的要求，当坐标系变换时，新的坐标网格仍然是平行等距的。我们也能轻易地通过旧的和新的坐标网格分别读出变换前后向量的坐标。为了体现这样做的用处，图4.3展示了一个相对“没什么特点”的线性变换。注意 (x', t') 在左侧图和右侧图中与坐标网格的相对位置是相同的（纵横都是大约 2 格多一点），这是主动观点与被动观点等价性的一种直观体现。




图 4.3: 洛伦兹变换的主动观点与被动观点. 左图显示了主动观点的图像, 向量 α_1 是一把单位长度的“尺子”. 浅蓝色区域是尺子静止的时空图, 蓝色区域是尺子匀速运动的时空图. 在 $t = 0$ 时刻测量动尺的长度, 结果如红色箭头所示, 是比单位长度 α_1 要短的. 右图显示了被动观点的图像. 尺子的时空图在不同参考系下均为浅蓝色区域. 在相对于尺子运动的参考系 (旁观者) 中, 在 $t' = 0$ 时刻测量尺子的长度, 结果如红色箭头所示, 是比 $x' - t'$ 系中的单位长度 β_1 要短的. 注意在 $x - t$ 中, 红色箭头的两端不是同时的 (即 t 坐标不同).

主动观点和被动观点在原则上没有优劣之分, 但是在观察世界时, 我们作为观测者容易偏执一端, 只采取我们习惯的观点, 而忽略另一种可能更具实际价值的观点. 打个比方来说, 当我们抬头望天时, 直觉上会认为是太阳围绕着在地球转动, 这是以“静止”的地面为参考系观测得出的结论. 但实际上, “太阳不动而地球自转”可能是更恰当的观点. 今天我们之所以能轻松地评述这两种观点, 是因为我们的眼界能跳出地球, 甚至跳出太阳系, 从旁观者的角度观察自己的处境. 但是作为当局者时, 我们经常无法想到可以转换视角来看问题.

图4.3展示的线性变换是洛伦兹于 1904 年发表的**洛伦兹变换**. 这是爱因斯坦的狭义相对论中描述不同参考系下时空变换规律的公式:

$$\begin{pmatrix} x' \\ t' \end{pmatrix} = \begin{pmatrix} \gamma & -\gamma\beta \\ -\gamma\beta & \gamma \end{pmatrix} \begin{pmatrix} x \\ t \end{pmatrix}, \quad \text{其中 } \beta = \frac{v}{c}, \gamma = \frac{1}{\sqrt{1-\beta^2}}$$

在狭义相对论之前, 物理学界的主流观点认为光波传播需要一种名为“以太”的介质, 并假设它是绝对静止的参考系. 1887 年, 迈克尔逊-莫雷实验未能探测到地球相对于以太的运动, 几乎完全推翻了以太假说, 物理学界陷入一片迷雾. 由于绝对时空观在人们心中根深蒂固, 许多物理学家仍不愿放弃以太这种绝对时空的载体, 希望修补以太理论. 洛伦兹就是其中之一. 他认为, 物体在以太中运动时, 物体在运动方向上会被“缩短”. 这可以从洛伦兹变换的**主动观点**出发推导出来 (图4.3左). 之所以说是主动观点, 是因为洛伦兹变换虽然涉及空间坐标 x 和时间坐标 t 的共同变换, 但洛伦兹只将它视为辅助的数学技巧, 并不蕴含真实的物理. 真正的物理过程在于物

体的分子间作用力会与以太发生某种作用，使得物体发物理上“真实”的缩短。

在狭义相对论框架下，洛伦兹变换仍然是正确的公式。著名的“动尺缩短效应”与洛伦兹的预测在数学上同根同源。然而，狭义相对论对于洛伦兹变换的解读颠覆性地采用**被动观点**。在对于“动尺缩短效应”的分析中，运动的物体本身并没有发生真实的变化，只不过参考系的相对运动会引起时空的变换，同一个物体在不同的参考系中“测量标准”不同，当然会测出不同的长度（例如，在“动尺”参考系中同时测量尺子的两端，在旁观者眼中就不是同时的）（图4.3右）。

在这个例子中，主动观点与被动观点的区别折射出人们对于“时空”认知的根本性区别。即便对于今人，要摒弃绝对时空观，接受“时空会变”的被动观点，仍然极富挑战性。

4.3 线性映射的分解

4.3.1 矩阵的等价和相似

设 n 维线性空间 V 有一组基 $\{e_i\}$ ， m 维线性空间 W 有一组基 $\{f_i\}$ 。线性映射 $A: V \rightarrow W$ 在基 $\{e_i\}$ 和 $\{f_i\}$ 下的表示矩阵为 $A_{m \times n}$ 。 $y = A(x)$ 的坐标由 $Y = AX$ 给出。现在，如果两个空间中各自发生基变换 $\{e_i\} \mapsto \{e'_i\}$ 和 $\{f_i\} \mapsto \{f'_i\}$ ，分别以 $P_{n \times n}$ 和 $Q_{m \times m}$ 为过渡矩阵，那么 A 的表示矩阵会怎么变化？设 x 和 y 在各自的新基 $\{e'_i\}$ 和 $\{f'_i\}$ 下的坐标分别为 X' 和 Y' 。则 $PX' = X$ ， $QY' = Y$ 。于是有：

$$QY' = APX', \text{ 即 } Y' = Q^{-1}APX'$$

可见，线性映射 φ 在新基下的表示矩阵为 $Q^{-1}AP$ 。也就是说，如果存在 n 阶可逆矩阵 P_1 和 m 阶可逆矩阵 P_2 ，使得 $B = P_2AP_1$ ，则矩阵 $A_{m \times n}$ 和 $B_{m \times n}$ 是**同一个线性映射在不同基下的表示矩阵**。这恰好是讲义第二章中提及的**矩阵等价**的概念。当时我们分析过，两个 $m \times n$ 矩阵等价当且仅当它们的秩相等。于是现在我们知道，**所有秩相等的 $m \times n$ 的矩阵都可以表示同一个线性映射**。同时也知道，秩虽然是在矩阵中定义的，却可以作为线性映射的属性来看待，即与基的选择无关的一个性质。其中的根本原因在于，秩其实是线性映射像空间的维数，后者自然是与基的选择无关的。

在上面的讨论中，我们总是在讨论同一个线性映射 A ，由于基的变换导致它的表示矩阵发生变换。这是一种**被动观点**。我们现在再从**主动观点**来描述矩阵的等价，即：取定每个空间的基不变，等价变换下不同的矩阵代表了不同的线性映射。这里，我们把 P_1 和 P_2 看成两个同构映射的表示矩阵。设 V_1 和 W_1 分别是 n 维和 m 维线性空间， P_1 是同构映射 $\sigma_1: V_1 \rightarrow V$ 的表示矩阵， P_2 是同构映射 $\sigma_2: W \rightarrow W_1$ 的表示矩阵。则等价变换后的矩阵 $B = P_2AP_1$ 表示了一个复合的线性映射 $\sigma_2 \circ A \circ \sigma_1$ ，它是 $V_1 \rightarrow W_1$ 的线性映射。照这种看法，请问 A 与 B 所代表的线性映射

$\mathcal{A}$ 与 $\sigma_2 \circ \mathcal{A} \circ \sigma_1$ 之间有何区别? 答案是**本质上没有区别**. 在同构的意义下, V_1 与 V , W_1 与 W 本就无从区分, 同构映射 σ_1 和 σ_2 的作用只是方便我们在两个“无从区分”的空间之间进行转换而已. 因此, 矩阵等价在主动观点下的意义是告诉我们: **在线性空间同构的意义下, 所有秩相等的线性映射本质上没有区别**.

上面的这些结论的意义是深刻的, 但用途也有限. 我们研究线性映射, 当然不是光研究秩就满足了. 然而对于矩阵等价而言, 同一个线性映射的不同表示矩阵 (或不同的线性映射) 在秩以外的区别是“看不清楚”的. 从被动观点来讲, 这是因为我们允许 V 和 W 的基各自做任意的变换, 这自由度太高了.

本课程的一个重点是研究线性变换的表示矩阵. 对于 n 维空间上的线性变换 $\mathcal{A}: V \rightarrow V$, 根据上一节的介绍, 只需选定一组基 $\{\mathbf{e}_i\}$ 就能写出其表示矩阵 A . 若基变换 $\{\mathbf{e}_i\} \mapsto \{\mathbf{e}'_i\}$ 以 $P_{n \times n}$ 为过渡矩阵, 新旧坐标之间的关系 $P\mathbf{X}' = \mathbf{X}$, $P\mathbf{Y}' = \mathbf{Y}$. 于是有:

$$P\mathbf{Y}' = A P\mathbf{X}', \text{ 即 } \mathbf{Y}' = P^{-1} A P\mathbf{X}'$$

可见, 线性变换 $\mathcal{A}$ 在新基下的表示矩阵为 $P^{-1} A P$. 也就是说, 如果存在 n 阶可逆矩阵 P 使得 $B = P^{-1} A P$, 则矩阵 A 和 B 是 **同一个线性变换在不同基下的表示矩阵**. 此时我们称矩阵 A 和 B 是**相似的**, 记作 $A \sim B$. 变换 $A \mapsto P^{-1} A P$ 称为**相似变换**. 可以证明相似变换是一种等价关系:

- (1) 反身性: 取 $P = I$, 显然 $I^{-1} A I = A$, 因此 $A \sim A$.
- (2) 对称性: 如果 $A \sim B$, 即存在可逆矩阵 P 使得 $B = P^{-1} A P$. 取 $Q = P^{-1}$, 则 $A = Q^{-1} B Q$, 因此 $B \sim A$.
- (3) 传递性: 如果 $A \sim B$, $B \sim C$, 即存在可逆矩阵 P, Q , 使得 $B = P^{-1} A P$, $C = Q^{-1} B Q$, 则 $C = Q^{-1} P^{-1} A P Q$. 取 $R = P Q$, 则 $C = R^{-1} A R$, 即 $A \sim C$.

矩阵在相似关系下的不变量称为**相似不变量**. 一个线性映射虽然可以有众多表示矩阵, 但是这些表示矩阵应该有共同的, 与基的选择无关的性质. 表示矩阵的这类性质可以看成是线性映射本身的属性, 这就是相似不变量的意义. 显然, 矩阵相似是矩阵等价的一种特殊情况, 所以**矩阵的秩是相似不变量**. 另外, 利用行列式的性质容易证明, **矩阵的行列式也是相似不变量**. 其背后的含义是, **线性映射对体积的缩放比例是线性映射的一个属性, 与基的选择无关**. 因此, 我们完全可以越过矩阵, 直接谈论线性映射的秩 $\text{rank}(\mathcal{A})$ 和线性变换的行列式 $\det \mathcal{A}$. $\det \mathcal{A}$ 这种记法是有实用性的, 但实际一般不采用 $\text{rank}(\mathcal{A})$ 这种记法, 因为 $\dim \text{Im } \mathcal{A}$ 显得更加明确. 在讲义第六章中, 将对相似不变量进行更深入的讨论.

根据“相似关系是等价关系”的思想，我们希望给出相似关系的完全不变量，或者以某种算法找到每个相似类的代表元，从而完成对矩阵作为线性映射表示矩阵的分类工作。所谓找“代表元”，是希望对于任意给定的 n 阶方阵，都能找到一个与之相似且形式尽量简单的方阵。换句话说，对于 n 维线性空间 V 上任意给定的线性变换 A ，去找 V 上的一组基，使得 A 在这组基下的表示矩阵尽量简单。上述那种“最简单”的表示矩阵称为**相似标准型**。

什么样的矩阵算是“最简单”的矩阵？最容易想到的是对角矩阵。可惜事实上，并非所有方阵都一定相似于某个对角矩阵。这样的话，该选择什么类型的矩阵作为相似标准型，又该如何计算一个任意矩阵的相似标准型？这提出了一个较大的课题。在线性代数课程中，我们只会解决这个课题的一小部分。

（注：为了方便，我们将一直采用被动观点处理矩阵的相似。当然，用主动观点来理解也是可行，而且完全等价的。）

考察以下两个 4 阶方阵：

$$A = \begin{pmatrix} 0 & \sqrt{2} & 0 & -\sqrt{2} \\ \frac{\sqrt{2}}{2} & -\sqrt{2} & -\frac{\sqrt{2}}{2} & \sqrt{2} \\ 0 & 2\sqrt{2} & \sqrt{2} & -\sqrt{2} \\ \sqrt{2} & -2\sqrt{2} & -\frac{\sqrt{2}}{2} & 2\sqrt{2} \end{pmatrix} \quad B = \begin{pmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} & 0 & 0 \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 & 0 \\ 0 & 0 & \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ 0 & 0 & -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix}$$

取过渡矩阵 P ：

$$P = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \\ 2 & 0 & 0 & 1 \end{pmatrix}$$

可以验证：

$$A = P^{-1}BP$$

即矩阵 A 与 B 相似，它们是同一个线性映射 φ 在不同基下的表示矩阵。

观察表示矩阵 A ，很难看出个所以然来： A 的矩阵元很杂乱，而且 4 维空间的几何图像本来就无法想象。然而， B 作为一个**分块对角矩阵**却容易理解得多。设被 φ 变换前后（与 B 相同的基下）的向量坐标为 $\mathbf{X} = (x_1, x_2, x_3, x_4)^T$ 和 $\mathbf{Y} = (y_1, y_2, y_3, y_4)^T$ 。根据矩阵乘法的规则， $\mathbf{Y} = B\mathbf{X}$ 的表达式可以写为以下两部分：

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \begin{pmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad \begin{pmatrix} y_3 \\ y_4 \end{pmatrix} = \begin{pmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix} \begin{pmatrix} x_3 \\ x_4 \end{pmatrix}$$

这实际上是两个 2 维空间的旋转变换，且这两个 2 阶方阵恰是原来 4 阶方阵的两个非零的**矩阵块**. 于是， B 的作用被分解成两部分：一是对 $x_1 - x_2$ 平面施加了逆时针旋转 45° 的变换；二是对 $x_3 - x_4$ 平面施加了顺时针旋转 45° 的变换. 这样来看，线性映射 φ 的作用方式一下子就清晰可见了.

从这个例子中可以看出，**高维的线性变换可以分解到低维的线性子空间上**，从而让线性变换的结构显得更简单易懂. 这种分解方式原则上只与线性变换在 V 上的作用方式有关，与基的选取及表示矩阵的形式无关. 但是，如果把表示矩阵写成分块**对角矩阵**的形式，则能让我们一眼看出线性变换的分解. 依据这种“分解”的思想，我们希望用分块对角矩阵来构造相似标准型. 也就是说，**计算相似标准型，实质就是搞清楚线性变换如何分解**. 本章的剩余部分就将落实这个思想.

4.3.2 线性空间的直和分解

我们首先需要说明的是，对一个线性空间进行“分解”是什么意思.

设 n 维线性空间 V 有两个线性子空间 V_1 和 V_2 . V_1 与 V_2 的**和**定义为：

$$V_1 + V_2 = \{\alpha + \beta \mid \alpha \in V_1, \beta \in V_2\}$$

容易验证， $V_1 + V_2$ 也是 V 的一个线性子空间（见习题部分）. 我们自然会问， $V_1 + V_2$ 的维数如何确定？我们给出如下的维数公式：

$$\dim(V_1 + V_2) = \dim V_1 + \dim V_2 - \dim(V_1 \cap V_2)$$

这里， $V_1 \cap V_2$ 也是 V 的一个线性子空间. 该公式可以简单地用容斥原理来理解：假设先取 $V_1 \cap V_2$ 的一组基 $\{\alpha_1, \alpha_2, \dots, \alpha_m\}$ ，分别将其扩充成 V_1 的一组基 $\{\alpha_1, \dots, \alpha_m, \alpha_{m+1}, \dots, \alpha_{n_1}\}$ 和 V_2 的一组基 $\{\alpha_1, \dots, \alpha_m, \beta_{m+1}, \dots, \beta_{n_2}\}$. 这两组基的并集应是 $V_1 + V_2$ 的一组基，其向量个数为 $n_1 + n_2 - m$ （证明见教科书）.

如果 V 表示成两个线性子空间之和 $V_1 + V_2$ ，那么可以说这是对 V 的一个“分解”. 对此的一种理解方式是，**线性空间的分解规定了向量的分解**. 因为根据定义， $V = V_1 + V_2$ 意味着任取 $v \in V$ ，都存在 $v_1 \in V_1, v_2 \in V_2$ ，使得 v 被分解成 $v = v_1 + v_2$. 但坏消息是，这种向量分解的方式可能不是唯一的. 根本原因在于两个子空间的公共部分 $V_1 \cap V_2$ 可以“任意调度”：若取非零

向量 $w \in V_1 \cap V_2$, 则 $u_1 = v_1 + w \in V_1$, $u_2 = v_2 - w \in V_2$, 则 $v = v_1 + v_2 = u_1 + u_2$ 就是两个不同的分解. 为了避免这种情况, 在谈论线性空间或向量的分解时, 我们会要求 $V_1 \cap V_2$ 是平凡子空间 $\{0\}$. 由此, 引出了直和的概念.

直和的定义 设 V_1 和 V_2 是线性空间 V 的子空间. 若 $V_1 \cap V_2 = \{0\}$, 则称 $V_1 + V_2$ 为直和, 记为: $V_1 \oplus V_2$.

该定义可以自然推广至任意有限个子空间之和: 设 $V_i (i = 1, 2, \dots, m)$ 是 V 的 m 个子空间. 若对一切 i 满足

$$V_i \cap (V_1 + \dots + V_{i-1} + V_{i+1} + \dots + V_m) = \{0\}$$

则称 $V_1 + V_2 + \dots + V_m$ 为直和, 记为: $V_1 \oplus V_2 \oplus \dots \oplus V_m$.

如果 $V = V_1 \oplus V_2 \oplus \dots \oplus V_m$, 我们称 $V_1 \oplus V_2 \oplus \dots \oplus V_m$ 是对 V 的一个直和分解. 我们讨论线性空间的分解时, 默认是指直和分解. 直和分解意味着, 任取 $v \in V$, 都存在 $v_1 \in V_1, v_2 \in V_2, \dots, v_m$, 使得 v 被分解成 $v = v_1 + v_2 + \dots + v_m$, 且这种分解方式是唯一的.

一种特殊的直和分解是将 V 分解成 n 个 1 维子空间的直和: $V = \langle e_1 \rangle \oplus \langle e_2 \rangle \oplus \dots \oplus \langle e_n \rangle$, 其中 $\{e_1, e_2, \dots, e_n\}$ 是 V 的一组基. 则此时任意向量 $v \in V$ 的唯一分解就是按这组基展开. 这是一种最彻底的直和分解. 自然, 对于一个“不彻底”的直和分解 $V = V_1 \oplus V_2 \oplus \dots \oplus V_m$, 可以将每个 V_i 进一步地分解彻底, 从而使得 V 也被彻底分解. 换句话说, 将每个 V_i 的任意一组基合并在一起, 就得到了 V 的一组基.

我们将上述关于直和的讨论总结成一个定理:

设线性空间 $V = V_1 + V_2 + \dots + V_m$, 则下列命题等价:

- (1) $V = V_1 \oplus V_2 \oplus \dots \oplus V_m$ 是直和.
- (2) $\dim(V_1 + V_2 + \dots + V_m) = \dim V_1 + \dim V_2 + \dots + \dim V_m$.
- (3) $V_1, V_2, \dots, V_m$ 的一组基可以拼成 V 的一组基.
- (4) V 中的向量表示为 $V_1, V_2, \dots, V_m$ 中的向量之和时, 其表示唯一. 即若 $v \in V$ 且 $v = v_1 + v_2 + \dots + v_m = u_1 + u_2 + \dots + u_m$, 其中 $v_i, u_i \in V_i$, 则 $v_i = u_i$.

其实, 线性空间的直和分为内直和外直和两种. 我们这里所讲的直和的定义是内直和. 为了更加深刻地理解直和的意义, 这里简要介绍外直和的概念.

集合中有一种运算叫做笛卡尔积. 设 V_1 和 V_2 是两个集合, 则它们的笛卡尔积定义为 $V_1 \times V_2 = \{(v_1, v_2) \mid v_i \in V_i\}$. 即: 把两个集合的元素各取一个并排放在一起, 组成有序对, 有序对的集合就是笛卡尔积. 可以说, 笛卡尔积是一种“什么都不做”的运算——它不过是把两个集合并排放

在一起，形式上组成了一个更大的集合而已。对于线性空间，是否有类似的运算？一个自然的想法是在笛卡尔积 $V_1 \times V_2$ 上定义加法和数乘：

$$\begin{aligned}(v_1, v_2) + (u_1, u_2) &= (v_1 + u_1, v_2 + u_2) \\ k \cdot (v_1, v_2) &= (k \cdot v_1, k \cdot v_2)\end{aligned}$$

这使得 $V_1 \times V_2$ 升级为线性空间，我们把它称为 V_1 和 V_2 的外直和，也记作 $V_1 \oplus V_2$ 。如果 V_1 和 V_2 是同一个线性空间 V 的子空间，那么它们的外直和与内直和是同构的，因此没有必要区分二者，只说直和即可。然而，从外直和的视角来看， V_1 和 V_2 的联系显得很弱。因为加法和数乘都是 V_1 和 V_2 “各管各的”，二者互不干涉。因此，正如刚才所形容的，直和无非是把两个线性空间并排放在一起，形式上看成一个更大的线性空间而已。所谓直和分解，也就是把一个大的线性空间“拆分”成几个小的线性空间。

4.3.3 不变子空间直和分解

给定 V 上的一个线性变换 φ 。现在我们要做的是“顺着”线性变换 φ 的结构，找一个合适的 V 的分解，然后进一步找到 V 的一组基，使得 φ 在这组基下的表示矩阵成为分块对角矩阵。何谓“顺着 φ 的结构做分解”？我们提出以下的概念：

不变子空间的定义 设 φ 是线性空间 V 上的线性变换， U 是 V 的一个子空间。若 U 满足 $\varphi(U) \subset U$ ，则称 U 是 φ 的不变子空间。换句话说，如果 U 中每一个向量被 φ 映射之后依然在 U 中，那么 U 是 φ 的不变子空间。

这时，把 φ 的定义域限制在 U 上，则 φ 在 U 上定义了一个线性变换，称为 φ 在 U 上的限制，记作 $\varphi|_U$ 。

（注：对于一般的线性映射 φ 和定义域的子空间 U ，总是可以用同样的方式定义线性映射 $\varphi|_U$ 。但当 U 不是线性变换的不变子空间时， $\varphi|_U$ 不是线性变换。）

对于给定的线性变换 φ ，我们要找的是这样一种直和分解 $V = V_1 \oplus V_2 \oplus \cdots \oplus V_m$ ，其中每个 V_i 都是 φ 的不变子空间。这种分解称为 φ 的不变子空间直和分解。在这种分解下， φ 在 V 上的作用就可以看成各个 $\varphi|_{V_i}$ 分别独立地在 V_i 上作用。

“顺着” φ 的不变子空间直和分解来选择基，可以把表示矩阵写成分块对角矩阵。叙述为以下的定理：

定理 4.3.1 设 φ 是 n 维线性空间 V 上的一个线性变换， $V = V_1 \oplus V_2 \oplus \cdots \oplus V_m$ 是 V 的一个不变子空间直和分解。那么存在 V 的一组基，由每个 V_i 的各一组基合并而成，使 φ 在这组

基下的表示矩阵为分块对角矩阵：

$$\begin{pmatrix} A_1 & & & \\ & A_2 & & \\ & & \ddots & \\ & & & A_m \end{pmatrix}$$

其中 A_i 是 $\varphi|_{V_i}$ 的表示矩阵，为 r_i 阶方阵， $r_i = \dim V_i$.

证明 取每个 V_i 的一组基 $\{e_{i1}, e_{i2}, \dots, e_{ir_i}\}$ ，它们按 i 从小到大的顺序合并起来组成 V 的一组基. 写出 φ 在这组基下的表示矩阵 A . 在 A 中， e_{ij} 对应位置的列向量是 $\varphi(e_{ij})$ 的坐标. 因为 V_i 是不变子空间， $\varphi(e_{ij}) \in V_i$ ，所以其坐标只有 $\{e_{i1}, e_{i2}, \dots, e_{ir_i}\}$ 对应的分量可能是非零的，其余分量皆为零. $\square$

4.3.4 特征值与特征向量

通过不变子空间直和分解，我们可以把表示矩阵简化成分块对角矩阵. 但这离建立相似标准型理论还有较远的距离. 在线性代数课程中，我们只关注最简单的一类情况：给定一个 n 维线性空间 V 上的线性变换 φ ，是否能把 V 分解成 n 个 1 维不变子空间的直和，从而把表示矩阵写成对角矩阵？

先来分析 1 维不变子空间的特点. 设 V 是数域 $\mathbb{K}^n$ 上的 n 维线性空间， U 是 V 的一个 1 维不变子空间，则 $\varphi|_U$ 是 1 维线性变换，即存在常数 $\lambda \in \mathbb{K}$ ，对于任意的 $x \in U$ ，则有：

$$\varphi(x) = \lambda x$$

满足上式的非零向量 x 称为 φ (属于 λ 的) 一个特征向量，常数 λ 称为 φ 的一个特征值.

对于数域 $\mathbb{K}$ 上的 n 阶方阵 A ，我们也有完全相同的定义：若存在 $\lambda \in \mathbb{K}$ ，和非零向量 $X \in \mathbb{K}^n$ ，使得 $AX = \lambda X$ ，则称 X 是 A 的一个特征向量， λ 是 A 的一个特征值. 这里 A 可以理解为某个 φ 的表示矩阵， X 可以理解为属于特征值 λ 的特征向量 x 的坐标. 为了便于衔接具体的计算相关问题，之后默认使用矩阵的特征值和特征向量概念进行讨论.

A 的一个特征值 λ 所对应的全部特征向量，连同零向量一起，组成一个线性子空间，称为属于特征值 λ 的特征子空间. 显然特征子空间对应了 φ 的一个不变子空间. φ 在其上的作用是将所有向量伸缩 λ 倍，而不改变其方向.

我们可以直接了当地计算某个方阵 A 的特征值与特征向量，并计算出一个与之相似的对角矩阵 (若存在) $D = P^{-1}AP$. 通过过渡矩阵 P 将 A 相似变换成对角矩阵 D 的操作称为相似对角

化. 如果这样的对角矩阵 D 确实存在, 则称 A 是**可相似对角化的**. 按照定义, 我们只需处理线性方程组 $A\mathbf{X} = \lambda\mathbf{X}$, 即 $(\lambda I_n - A)\mathbf{X} = \mathbf{0}$. 计算流程如下:

(1) 寻找使得线性方程组 $(\lambda I_n - A)\mathbf{X} = \mathbf{0}$ 有非零解的 λ , 这样的 λ 就是 A 的特征值. 具体办法是计算行列式 $|\lambda I_n - A|$ 的值, 它是一个关于 λ 的 n 次多项式, 称为 A 的**特征多项式**. 线性方程组有非零解的条件是 $|\lambda I - A| = 0$, 这个方程称为**特征方程**. 特征多项式的根, 或者说特征方程的解, 即是**特征值**.

(2) 对于每个特征值 λ_i , 去解线性方程组 $(\lambda_i I_n - A)\mathbf{X} = \mathbf{0}$. 解空间即是属于 λ_i 的特征子空间.

(3) 检查特征多项式中 λ_i 这个根的重数 (称为**代数重数**), 以及属于 λ_i 的特征子空间的维数 (称为**几何重数**). A 可相似对角化当且仅当所有特征值 λ_i 的几何重数等于代数重数.

(4) 若 A 可对角化, 取每个特征子空间的一组基, 合并成 $\mathbb{R}^n$ 的一组基, 它们以列向量组的形式拼成的矩阵 P 就是过渡矩阵. P 的列向量组实质上就是 n 个线性无关的特征向量. 它们所对应的特征值 (可能有重复) 依次按序排列在矩阵的对角线上, 形成的对角矩阵 D 即满足 $D = P^{-1}AP$.

矩阵可对角化是我们乐于见到的情形. 一般来说, 矩阵运算的分量是“纠缠在一起的”, 即向量 $\mathbf{x}$ 的所有 n 个分量都对映射后 $\mathbf{y}$ 的所有 n 个分量有空间. 但如果矩阵可对角化, 就说明它所对应的线性变换本质上是一个伸缩变换, 只需选取一组线性无关的特征向量为基, 就能把矩阵写成对角矩阵. 从不变子空间分解的角度来看, 这种线性映射只不过是把 n 个 1 维线性映射, 也就是正比例函数并排放在了一起, 装模做样地表现出 n 维映射的样子而已. 在讲义的第六章, 我们会进一步讨论相似变换的性质, 以及可对角化的条件.

4.4 习题

关于线性空间与线性映射的话题, 由于许多概念和记号都是抽象化得到的, 刚开始运用它们也不容易. 本章的重点不在于解决很难的问题, 而是在于熟练使用概念和记号完成基本的证明. 因此, 不能犯眼高手低的毛病, 即便是简单的问题也要动笔尝试写出完整的证明. 本章的部分习题就是要对前文中那些看似简单的结论补上证明.

4.4.1 线性空间的概念

“证明某个集合是线性空间”是最基本的一类题目. 具体分为以下几个步骤:

1. 明确要证的是哪个集合, 数域是什么, 其上定义的加法和数乘是什么.

2. 证明集合对于加法和数乘的运算是封闭的.
3. 验证线性空间的 8 条规则.

如果要求线性空间的维数, 则需要构造一组基, 其向量个数就是线性空间的维数. 可以按定义证明所给出的构造确实是一组基, 即:

1. 它能线性表示空间里的所有向量.
2. 它是线性无关的.

例 4.1. 证明 $\mathbb{R}$ 上全体小于 n 次的多项式组成的集合 $\mathbb{R}_n[x]$ 构成 n 维线性空间.

分析. 题目中并未指定 $\mathbb{R}_n[x]$ 的加法和数乘是什么, 那是因为多项式本身就自带加法和数乘的运算. 尽管多项式是大家十分熟悉的东西, 但是在证明题的要求下, 还是应该明确地指出加法和数乘的定义是什么. 在验证线性空间中的 8 条规则时, 也不能想当然地下结论, 例如, 要是说“多项式的加法显然满足加法交换律”, 这样就失去证明的意义了. 事实上, 多项式的加法交换律是在多项式加法定义的基础之上, 数域 $\mathbb{R}$ 中的加法交换律所带来的. 证明中应体现这一点.

证明. $\mathbb{R}_n[x] = \{a_0 + a_1x + \cdots + a_{n-1}x^{n-1} \mid a_0, a_1, \cdots, a_{n-1} \in \mathbb{R}\}$. 其中的加法和数乘就是通常的多项式加法和数乘. 任取: $f(x) = a_0 + a_1x + \cdots + a_{n-1}x^{n-1}, g(x) = b_0 + b_1x + \cdots + b_{n-1}x^{n-1}$, 又任取 $k \in \mathbb{R}$. 则加法和数乘的定义为:

$$\begin{aligned} f(x) + g(x) &= (a_0 + b_0) + (a_1 + b_1)x + \cdots + (a_{n-1} + b_{n-1})x^{n-1} \in \mathbb{R}_n[x] \\ kf(x) &= ka_0 + ka_1x + \cdots + ka_{n-1}x^{n-1} \in \mathbb{R}_n[x] \end{aligned}$$

这也同时说明了 $\mathbb{R}_n[x]$ 对于多项式加法和数乘封闭.

下面逐条验证线性空间定义中的 8 条规则.

- (1) 加法单位元: 零多项式 $0 \in \mathbb{R}_n[x]$. 对任意 $f(x) \in \mathbb{R}_n[x]$, 有: $0 + f(x) = f(x)$.
- (2) 加法结合律: 对任意 $f(x), g(x), h(x) \in \mathbb{R}_n[x]$, 利用 $\mathbb{R}$ 满足加法结合律的事实, 有:

$$\begin{aligned} &f(x) + (g(x) + h(x)) \\ &= (a_0 + a_1x + \cdots + a_{n-1}x^{n-1}) + [(b_0 + c_0) + (b_1 + c_1)x + \cdots + (b_{n-1} + c_{n-1})x^{n-1}] \\ &= (a_0 + (b_0 + c_0)) + (a_1 + (b_1 + c_1))x + \cdots + (a_{n-1} + (b_{n-1} + c_{n-1}))x^{n-1} \\ &= ((a_0 + b_0) + c_0) + ((a_1 + b_1) + c_1)x + \cdots + ((a_{n-1} + b_{n-1}) + c_{n-1})x^{n-1} \\ &= [(a_0 + b_0) + (a_1 + b_1)x + \cdots + (a_{n-1} + b_{n-1})x^{n-1}] + (c_0 + c_1x + \cdots + c_{n-1}x^{n-1}) \\ &= (f(x) + g(x)) + h(x). \end{aligned}$$

- (3) 加法的逆: 对任意 $f(x) = a_0 + a_1x + \cdots + a_{n-1}x^{n-1} \in \mathbb{R}_n[x]$, 利用 $\mathbb{R}$ 中元素 a_i 有加法逆元 $-a_i$ 的事实, 定义相反多项式 $-f(x) = -a_0 - a_1x - \cdots - a_{n-1}x^{n-1}$, 仍属于 $\mathbb{R}_n[x]$, 它满足

$$f(x) + (-f(x)) = 0.$$

(4) 加法交换律：对任意 $f(x), g(x) \in \mathbb{R}_n[x]$ ，利用 $\mathbb{R}$ 满足加法交换律的事实，有：

$$\begin{aligned} f(x) + g(x) &= (a_0 + b_0) + (a_1 + b_1)x + \cdots + (a_{n-1} + b_{n-1})x^{n-1} \\ &= (b_0 + a_0) + (b_1 + a_1)x + \cdots + (b_{n-1} + a_{n-1})x^{n-1} \\ &= g(x) + f(x) \end{aligned}$$

(5) 数乘单位：对任意 $f(x) \in \mathbb{R}_n[x]$ ，有：

$$1 \cdot f(x) = 1 \cdot a_0 + 1 \cdot a_1x + \cdots + 1 \cdot a_{n-1}x^{n-1} = f(x).$$

(6) 数乘结合律：对任意 $k, l \in \mathbb{R}$ ， $f(x) \in \mathbb{R}_n[x]$ ，利用 $\mathbb{R}$ 满足乘法结合律的事实，有：

$$\begin{aligned} k(lf(x)) &= kla_0 + kla_1x + \cdots + kla_{n-1}x^{n-1} \\ &= (kl)a_0 + (kl)a_1x + \cdots + (kl)a_{n-1}x^{n-1} \\ &= (kl)f(x) \end{aligned}$$

(7) 数乘分配律 I：对任意 $k \in \mathbb{R}$ ， $f(x), g(x) \in \mathbb{R}_n[x]$ ，利用 $\mathbb{R}$ 满足乘法分配律的事实，有：

$$\begin{aligned} k(f(x) + g(x)) &= k((a_0 + b_0) + (a_1 + b_1)x + \cdots + (a_{n-1} + b_{n-1})x^{n-1}) \\ &= k(a_0 + b_0) + k(a_1 + b_1)x + \cdots + k(a_{n-1} + b_{n-1})x^{n-1} \\ &= (ka_0 + kb_0) + (ka_1 + kb_1)x + \cdots + (ka_{n-1} + kb_{n-1})x^{n-1} \\ &= [(ka_0) + (ka_1)x + \cdots + (ka_{n-1})x^{n-1}] + [(kb_0) + (kb_1)x + \cdots + (kb_{n-1})x^{n-1}] \\ &= kf(x) + kg(x) \end{aligned}$$

(8) 数乘分配律 II：对任意 $k, l \in \mathbb{R}$ ， $f(x) \in \mathbb{R}_n[x]$ ，利用 $\mathbb{R}$ 满足乘法分配律的事实，有：

$$\begin{aligned} (k + l)f(x) &= (k + l)a_0 + (k + l)a_1x + \cdots + (k + l)a_{n-1}x^{n-1} \\ &= (ka_0 + la_0) + (ka_1 + la_1)x + \cdots + (ka_{n-1} + la_{n-1})x^{n-1} \\ &= [(ka_0) + (ka_1)x + \cdots + (ka_{n-1})x^{n-1}] + [(la_0) + (la_1)x + \cdots + (la_{n-1})x^{n-1}] \\ &= kf(x) + lf(x) \end{aligned}$$

综上， $\mathbb{R}_n[x]$ 在通常的多项式加法和数乘下满足线性空间定义中的 8 条规则（感谢 ai 帮助我写完了这一段，考试手写证明的话就没这么幸运了哈哈）。

下面给出 $\mathbb{R}^n$ 的一组基。考虑 $\{1, x, x^2, \dots, x^{n-1}\}$ ，我们证明它就是一组基。任取 $f(x) \in \mathbb{R}_n[x]$ ，有

$$f(x) = a_0 + a_1x + \cdots + a_{n-1}x^{n-1}$$

所以 $f(x)$ 可以由 $1, x, x^2, \dots, x^{n-1}$ 线性表示.

再证明它们线性无关. 按线性无关的定义, 若

$$c_0 + c_1x + \dots + c_{n-1}x^{n-1} = 0$$

其中右边的 0 表示零多项式, 则由多项式相等的定义可知

$$c_0 = c_1 = \dots = c_{n-1} = 0$$

因此 $1, x, x^2, \dots, x^{n-1}$ 线性无关.

综上, $\{1, x, x^2, \dots, x^{n-1}\}$ 是 $\mathbb{R}_n[x]$ 的一组基, 所以 $\dim \mathbb{R}_n[x] = n$. □

例 4.2. 设 V 是 n 维线性空间, W 是 m 维线性空间, 记 $\text{Hom}(V, W)$ 是全体 $V \rightarrow W$ 的线性映射的集合. 证明: $\text{Hom}(V, W)$ 是 mn 维线性空间.

分析. 教材上提及了这个结论, 并说是“容易验证”的. 让我们看看是否真的容易验证 (真的). 注意运用两个线性映射相等的定义: 作用于任何向量得到的像均相等. 因此, 证明线性映射的等式, 需要先喂进去一个任意向量 $x \in V$.

证明. 设 $\mathcal{A}, \mathcal{B}$ 都是 $V \rightarrow W$ 的线性映射, $k \in \mathbb{K}$. 线性映射的加法和数乘按如下定义:

$$\begin{aligned} (\mathcal{A} + \mathcal{B})x &= \mathcal{A}x + \mathcal{B}x \\ (k\mathcal{A})x &= k(\mathcal{A}x) \end{aligned}$$

先证明 $\text{Hom}(V, W)$ 对线性映射的加法和数乘封闭, 即 $\mathcal{A} + \mathcal{B}$ 和 $k\mathcal{A}$ 都是线性映射. 任取 $x_1, x_2 \in V$, $l \in \mathbb{K}$. 有:

$$\begin{aligned} (\mathcal{A} + \mathcal{B})(x_1 + x_2) &= \mathcal{A}(x_1 + x_2) + \mathcal{B}(x_1 + x_2) = \mathcal{A}x_1 + \mathcal{A}x_2 + \mathcal{B}x_1 + \mathcal{B}x_2 \\ &= (\mathcal{A} + \mathcal{B})x_1 + (\mathcal{A} + \mathcal{B})x_2 \end{aligned}$$

$$\begin{aligned} (\mathcal{A} + \mathcal{B})(lx_1) &= \mathcal{A}(lx_1) + \mathcal{B}(lx_1) = l\mathcal{A}x_1 + l\mathcal{B}x_1 = l(\mathcal{A}x_1 + \mathcal{B}x_1) \\ &= l(\mathcal{A} + \mathcal{B})x_1 \end{aligned}$$

$$\begin{aligned} (k\mathcal{A})(x_1 + x_2) &= k(\mathcal{A}(x_1 + x_2)) = k(\mathcal{A}x_1 + \mathcal{A}x_2) = k\mathcal{A}x_1 + k\mathcal{A}x_2 \\ &= (k\mathcal{A})x_1 + (k\mathcal{A})x_2 \end{aligned}$$

$$\begin{aligned} (k\mathcal{A})(lx_1) &= k(\mathcal{A}(lx_1)) = k(l\mathcal{A}x_1) = kl\mathcal{A}x_1 = lk\mathcal{A}x_1 \\ &= l(k\mathcal{A})x_1 \end{aligned}$$

接下来验证线性空间的 8 条规则. 设 x 是 V 中任意的向量. $\mathcal{A}, \mathcal{B}, \mathcal{C}$ 是 $\text{Hom}(V, W)$ 中任意的线性映射, k, l 是数域 $\mathcal{K}$ 中任意的数.

(1) 加法单位元: 零映射 $\mathbf{0}$ 满足:

$$(\mathbf{0} + \mathcal{A})x = \mathbf{0}x + \mathcal{A}x = \mathcal{A}x$$

即 $\mathbf{0} + \mathcal{A} = \mathcal{A}$.

(2) 加法结合律:

$$(\mathcal{A} + (\mathcal{B} + \mathcal{C}))x = \mathcal{A}x + (\mathcal{B} + \mathcal{C})x = \mathcal{A}x + \mathcal{B}x + \mathcal{C}x = (\mathcal{A} + \mathcal{B})x + \mathcal{C}x = ((\mathcal{A} + \mathcal{B}) + \mathcal{C})x$$

即 $(\mathcal{A} + (\mathcal{B} + \mathcal{C})) = (\mathcal{A} + \mathcal{B}) + \mathcal{C}$.

(3) 加法的逆: 定义 $\mathcal{A}$ 的负映射 $-\mathcal{A}$ 满足 $(-\mathcal{A})x = -\mathcal{A}x$. 则:

$$(\mathcal{A} + (-\mathcal{A}))x = \mathcal{A}x + (-\mathcal{A})x = \mathcal{A}x - \mathcal{A}x = 0$$

即 $\mathcal{A} + (-\mathcal{A}) = \mathbf{0}$.

(4) 加法交换律:

$$(\mathcal{A} + \mathcal{B})x = \mathcal{A}x + \mathcal{B}x = \mathcal{B}x + \mathcal{A}x = (\mathcal{B} + \mathcal{A})x$$

即 $\mathcal{A} + \mathcal{B} = \mathcal{B} + \mathcal{A}$.

(5) 乘法单位元:

$$(1\mathcal{A})x = 1 \cdot \mathcal{A}x = \mathcal{A}x$$

即 $1\mathcal{A} = \mathcal{A}$.

(6) 数乘结合律:

$$k(l\mathcal{A})x = kl\mathcal{A}x = ((kl)\mathcal{A})x$$

即 $k(l\mathcal{A}) = (kl)\mathcal{A}$.

(7) 数乘分配律 I:

$$\begin{aligned} (k(\mathcal{A} + \mathcal{B}))x &= k \cdot (\mathcal{A} + \mathcal{B})x = k(\mathcal{A}x + \mathcal{B}x) = k\mathcal{A}x + k\mathcal{B}x = (k\mathcal{A})x + (k\mathcal{B})x \\ &= (k\mathcal{A} + k\mathcal{B})x \end{aligned}$$

即 $k(\mathcal{A} + \mathcal{B}) = k\mathcal{A} + k\mathcal{B}$.

(8) 数乘分配律 II:

$$((k + l)\mathcal{A})x = (k + l)\mathcal{A}x = k\mathcal{A}x + l\mathcal{A}x = (k\mathcal{A})x + (l\mathcal{A})x = (k\mathcal{A} + l\mathcal{A})x$$

即 $(k + l)\mathcal{A} = k\mathcal{A} + l\mathcal{A}$.

至此证明了 $\text{Hom}(V, W)$ 对线性映射的加法和数乘构成线性空间. 现在构造 $\text{Hom}(V, W)$ 的一组基. 设 V 的一组基 $\{e_1, e_2, \dots, e_n\}$, W 的一组基 $\{f_1, f_2, \dots, f_m\}$. 通过线性映射在 e_i 上的作用, 我们可以确定出如下 mn 个线性映射 $\mathcal{E}_{ij}$, 其中 $i = 1, 2, \dots, n$, $j = 1, 2, \dots, m$. 定义式为:

$$\mathcal{E}_{ij}\mathbf{e}_k = \delta_{ik}\mathbf{f}_j$$

用大白话来说, $\mathcal{E}_{ij}$ 把 $\mathbf{e}_i$ 映为 $\mathbf{f}_j$, 把其余的 $\mathbf{e}_k$ 映为 $\mathbf{0}$. 这个定义可以通过基本矩阵想到. 首先证明 $\{\mathcal{E}_{ij}\}$ 是线性无关的. 假设存在一组系数 $c_{ij} \in \mathbb{K}$ 使得:

$$\sum_{i=1}^n \sum_{j=1}^m c_{ij} \mathcal{E}_{ij} = \mathbf{0}$$

任取向量 $\mathbf{v} = a_1\mathbf{e}_1 + a_2\mathbf{e}_2 + \cdots + a_n\mathbf{e}_n$. 则:

$$\begin{aligned} \mathbf{0} &= \left(\sum_{i=1}^n \sum_{j=1}^m c_{ij} \mathcal{E}_{ij} \right) \mathbf{v} = \left(\sum_{i=1}^n \sum_{j=1}^m c_{ij} \mathcal{E}_{ij} \right) \left(\sum_{k=1}^n a_k \mathbf{e}_k \right) \\ &= \sum_{i=1}^n \sum_{j=1}^m \sum_{k=1}^n c_{ij} a_k \mathcal{E}_{ij} \mathbf{e}_k = \sum_{i=1}^n \sum_{j=1}^m \sum_{k=1}^n c_{ij} a_k \delta_{ik} \mathbf{f}_j \\ &= \sum_{i=1}^n \sum_{j=1}^m c_{ij} a_i \mathbf{f}_j = \sum_{j=1}^m \left(\sum_{i=1}^n c_{ij} a_i \right) \mathbf{f}_j \end{aligned}$$

这说明对任意的 j 和任意的 $a_i \in \mathbb{K}$, 有:

$$\sum_{i=1}^n c_{ij} a_i = 0$$

因此 $c_{ij} = 0$ 对任意的指标 i, j 成立. 这就证明了线性无关性.

再证明 $\{\mathcal{E}_{ij}\}$ 能线性表示任意的 $\mathcal{A} \in \text{Hom}(V, W)$. 设 $\mathcal{A}$ 在 V 的基 $\{\mathbf{e}_i\}$ 上的作用:

$$\begin{aligned} \mathcal{A}\mathbf{e}_1 &= a_{11}\mathbf{f}_1 + a_{21}\mathbf{f}_2 + \cdots + a_{m1}\mathbf{f}_m \\ \mathcal{A}\mathbf{e}_2 &= a_{12}\mathbf{f}_1 + a_{22}\mathbf{f}_2 + \cdots + a_{m2}\mathbf{f}_m \\ &\vdots \\ \mathcal{A}\mathbf{e}_n &= a_{1n}\mathbf{f}_1 + a_{2n}\mathbf{f}_2 + \cdots + a_{mn}\mathbf{f}_m \end{aligned}$$

可以验证, 线性映射 $\sum_{i=1}^n \sum_{j=1}^m a_{ji} \mathcal{E}_{ij}$ 在基 $\{\mathbf{e}_i\}$ 上的作用与之相同, 因此 $\mathcal{A} = \sum_{i=1}^n \sum_{j=1}^m a_{ji} \mathcal{E}_{ij}$.

综上, $\{\mathcal{E}_{ij}\}$ 是 $\text{Hom}(V, W)$ 的一组基, 其中包含 mn 个元素, 因此 $\dim \text{Hom}(V, W) = mn$. $\square$

例 4.3. 全体 2 维实向量集合 V 按如下的方式规定了加法和数乘:

$$(a, b) \oplus (c, d) = (a + c, b + d + ac)$$

$$k \circ (a, b) = \left(ka, kb + \frac{k(k-1)}{2}a^2 \right)$$

(i) 证明: V 是线性空间.

(ii) 讨论向量组 α_1, α_2 的线性相关性.

分析. 此题需注意新定义的加法和数乘与 $\mathbb{R}^2$ 中通常的加法和数乘有很大的区别.

证明. (i) V 对加法和数乘的封闭性显然. 下面验证线性空间的 8 条规则. 设 a, b, c, d, m, n, k, l 是任意的实数.

(1) 加法单位元: 设 (x, y) 满足: $(x, y) \oplus (a, b) = (a, b)$, 即 $(x + a, y + b + xa) = (a, b)$, 解得 $(x, y) = (0, 0)$, 即 $(0, 0)$ 是零元.

(2) 加法结合律:

$$\begin{aligned} (a, b) \oplus ((c, d) \oplus (m, n)) &= (a, b) \oplus (c + m, d + n + cm) \\ &= (a + c + m, b + d + n + cm + a(c + m)) \\ &= ((a + c) + m, (b + d + ac) + n + m(a + c)) \\ &= (a + c, b + d + ac) \oplus (m, n) \\ &= ((a, b) \oplus (c, d)) \oplus (m, n) \end{aligned}$$

(3) 加法的逆: 设 (x, y) 满足: $(x, y) \oplus (a, b) = (0, 0)$, 即 $(x + a, y + b + xa) = (0, 0)$, 解得 $(x, y) = (-a, -b + a^2)$. 因此可以定义 (a, b) 的负元素 $-(a, b) = (-a, -b + a^2)$.

(4) 加法交换律:

$$(a, b) \oplus (c, d) = (a + c, b + d + ac) = (c + a, d + b + ca) = (c, d) \oplus (a, b)$$

(5) 乘法单位元: $1 \circ (a, b) = (a, b)$.

(6) 乘法结合律:

$$\begin{aligned} k \circ l \circ (a, b) &= k \circ \left(la, lb + \frac{l(l-1)}{2}a^2 \right) \\ &= \left(kla, klb + k \frac{l(l-1)}{2}a^2 + \frac{k(k-1)}{2}l^2a^2 \right) \\ &= \left(kla, klb + \frac{kl(l-1) + kl(kl-l)}{2}a^2 \right) \\ &= \left(kla, klb + \frac{kl(kl-1)}{2}a^2 \right) \\ &= (kl) \circ (a, b) \end{aligned}$$

(7) 乘法分配律 I:

$$\begin{aligned}
k \circ ((a, b) \oplus (c, d)) &= k \circ (a + c, b + d + ac) \\
&= \left(k(a + c), k(b + d + ac) + \frac{k(k-1)}{2}(a + c)^2 \right) \\
&= \left(ka + kc, (kb + \frac{k(k-1)}{2}a^2) + (kd + \frac{k(k-1)}{2}c^2) + ka \cdot kc \right) \\
&= \left(ka, kb + \frac{k(k-1)}{2}a^2 \right) \oplus \left(kc, kd + \frac{k(k-1)}{2}c^2 \right) \\
&= k \circ (a, b) \oplus k \circ (c, d)
\end{aligned}$$

(8) 乘法分配律 II:

$$\begin{aligned}
(k + l) \circ (a, b) &= \left((k + l)a, (k + l)b + \frac{(k + l)(k + l - 1)}{2}a^2 \right) \\
&= \left(ka + la, (kb + \frac{k(k-1)}{2}a^2) + (lb + \frac{l(l-1)}{2}a^2) + ka \cdot la \right) \\
&= \left(ka, kb + \frac{k(k-1)}{2}a^2 \right) \oplus \left(la, lb + \frac{l(l-1)}{2}a^2 \right) \\
&= k \circ (a, b) \oplus l \circ (a, b)
\end{aligned}$$

这样就证明了 V 关于加法 $\oplus$ 和数乘 $\circ$ 是线性空间.

(2) 设 $k_1, k_2 \in \mathbb{R}$, 使得 $k_1 \circ \alpha_1 \oplus k_2 \circ \alpha_2 = \mathbf{0} = (0, 0)$, 即:

$$\left(k_1, k_1 + \frac{k_1(k_1-1)}{2} \right) \oplus \left(k_2a, k_2b + \frac{k_2(k_2-1)}{2}a^2 \right) = (0, 0)$$

亦即:

$$\left(k_1 + k_2a, k_1 + \frac{k_1(k_1-1)}{2} + k_2b + \frac{k_2(k_2-1)}{2}a^2 + k_1k_2a \right) = (0, 0)$$

因此有:

$$\begin{cases} k_1 + k_2a = 0 \\ k_1 + \frac{k_1(k_1-1)}{2} + k_2b + \frac{k_2(k_2-1)}{2}a^2 + k_1k_2a = 0 \end{cases}$$

将第一个方程代入第二个方程, 整理得到:

$$\left(b - \frac{a(a+1)}{2} \right) k_2 = 0$$

因此, 当 $b \neq \frac{a(a+1)}{2}$ 时, 必有 $k_2 = 0$, $k_1 = 0$, α_1, α_2 线性无关. 否则, α_1, α_2 线性相关. □

在上述的 V 中, $(1, 1)$ 和 $(2, 2)$ 是线性无关的, $(1, 1)$ 和 $(2, 3)$ 是线性相关的, 这个通常的 $\mathbb{R}^2$ 很不一样. 可见加法和数乘的定义方式并不是唯一的, 而且不同的定义可能导致元素之间的线性关系不同.

例 4.4. 证明以下结论:

(1) 设 V 和 W 是线性空间, 给定线性映射 $\varphi: V \rightarrow W$. 记 $\text{Ker } \varphi = \{\mathbf{x} \in V \mid \varphi(\mathbf{x}) = \mathbf{0}\}$, $\text{Im } \varphi = \{\mathbf{y} \in W \mid \mathbf{y} = \varphi(\mathbf{x})\}$. 证明 $\text{Ker } \varphi$, $\text{Im } \varphi$ 分别是 V 和 W 的子空间.

(2) 设 V 是线性空间, V_1 和 V_2 是其线性子空间. 证明 $V_1 + V_2$ 和 $V_1 \cap V_2$ 都是子空间. 另外, 为什么 $V_1 \cup V_2$ 不是子空间?

(3*) 设 V 是线性空间, φ 是 V 上的一个线性变换. 证明: φ 的不变子空间是 V 的子空间. 特别地, 特征子空间也是 V 的子空间.

分析. 子空间要求继承原来线性空间的加法和数乘运算. 因此, 对于“证明 V_0 是线性空间 V 的子空间”这类题目, 线性空间的 8 条规则在子空间 V_0 中是自然满足的, 不需要再验证了. 只需要验证 V_0 对加法和数乘封闭即可.

证明. (1) 任取 $\mathbf{x}_1, \mathbf{x}_2 \in \text{Ker } \varphi$, 即 $\varphi(\mathbf{x}_1) = \varphi(\mathbf{x}_2) = \mathbf{0}$, 则 $\varphi(\mathbf{x}_1 + \mathbf{x}_2) = \varphi(\mathbf{x}_1) + \varphi(\mathbf{x}_2) = \mathbf{0}$, 即 $\mathbf{x}_1 + \mathbf{x}_2 \in \text{Ker } \varphi$. 再任取 $k \in \mathbb{K}$, 则 $\varphi(k\mathbf{x}_1) = k\varphi(\mathbf{x}_1) = \mathbf{0}$. 可见 $\text{Ker } \varphi$ 对加法和数乘封闭, 因此 $\text{Ker } \varphi$ 是 V 的子空间.

任取 $\mathbf{y}_1, \mathbf{y}_2 \in \text{Im } \varphi$, 即存在 $\mathbf{x}_1, \mathbf{x}_2$ 使得 $\mathbf{y}_1 = \varphi(\mathbf{x}_1), \mathbf{y}_2 = \varphi(\mathbf{x}_2)$, 则 $\mathbf{y}_1 + \mathbf{y}_2 = \varphi(\mathbf{x}_1) + \varphi(\mathbf{x}_2) = \varphi(\mathbf{x}_1 + \mathbf{x}_2) \in \text{Im } \varphi$. 再任取 $k \in \mathbb{K}$, 则 $k\mathbf{y}_1 = k\varphi(\mathbf{x}_1) = \varphi(k\mathbf{x}_1) \in \text{Im } \varphi$. 可见 $\text{Im } \varphi$ 对加法和数乘封闭, 因此 $\text{Im } \varphi$ 是 V 的子空间.

(2) 任取 $V_1 + V_2$ 中的两个向量 $\alpha = \mathbf{v}_1 + \mathbf{v}_2$ 和 $\beta = \mathbf{w}_1 + \mathbf{w}_2$, 其中 $\mathbf{v}_1, \mathbf{w}_1 \in V_1, \mathbf{v}_2, \mathbf{w}_2 \in V_2$. 则 $\alpha + \beta = (\mathbf{v}_1 + \mathbf{v}_2) + (\mathbf{w}_1 + \mathbf{w}_2) = (\mathbf{v}_1 + \mathbf{w}_1) + (\mathbf{v}_2 + \mathbf{w}_2)$. 其中 $\mathbf{v}_1 + \mathbf{w}_1 \in V_1, \mathbf{v}_2 + \mathbf{w}_2 \in V_2$, 故 $\alpha + \beta \in V_1 + V_2$. 再任取 $k \in \mathbb{K}$, 则 $k\alpha = k(\mathbf{v}_1 + \mathbf{v}_2) = k\mathbf{v}_1 + k\mathbf{v}_2 \in V_1 + V_2$. 可见 $V_1 + V_2$ 对加法和数乘封闭, 因此 $V_1 + V_2$ 是 V 的子空间.

任取 $\mathbf{v}, \mathbf{w} \in V_1 \cap V_2, k \in \mathbb{K}$, 即 $\mathbf{v}, \mathbf{w}$ 既在 V_1 中又在 V_2 中, 那么 $\mathbf{v} + \mathbf{w}, k\mathbf{v}$ 也既在 V_1 中又在 V_2 中, 即 $\mathbf{v} + \mathbf{w}, k\mathbf{v} \in V_1 \cap V_2$. 可见 $V_1 \cap V_2$ 对加法和数乘封闭, 因此 $V_1 \cap V_2$ 是 V 的子空间.

(3) 设 U 是 φ 的不变子空间, 则 $\varphi(U) \subset U$. 任取 $\mathbf{u}_1, \mathbf{u}_2 \in U$, 即 $\varphi(\mathbf{u}_1), \varphi(\mathbf{u}_2) \in U$. 则 $\varphi(\mathbf{u}_1 + \mathbf{u}_2) = \varphi(\mathbf{u}_1) + \varphi(\mathbf{u}_2) \in U$, 即 $\mathbf{u}_1 + \mathbf{u}_2 \in U$. 再任取 $k \in \mathbb{K}$, $\varphi(k\mathbf{u}_1) = k\varphi(\mathbf{u}_1) \in U$, 即 $k\mathbf{u}_1 \in U$. 可见 U 对加法和数乘封闭, 因此 U 是 V 的子空间. $\square$

4.4.2 线性映射与矩阵

本节强调一些概念问题. 坐标是向量在某一组基下的表示, 表示矩阵是线性映射在某两组基(映射前后的空间中各有一组, 如果是线性变换则只需要用同一组基)下的表示. 如果基的选取发生变化, 同一向量的坐标会发生变化, 同一线性映射的表示矩阵也会发生变化. 两者的规律都与过渡矩阵 P 有关. 过渡矩阵的本质是把一组基 e_i 映为另一组基 f_i 的线性映射在基 e_i 下的表示矩阵, 简而言之是描述基变换方式的矩阵. 在这一基变换下, 向量的坐标变换遵从 $\mathbf{X} \mapsto P^{-1}\mathbf{X}$, 线性变换的表示矩阵遵从相似变换 $A \mapsto P^{-1}AP$.

要写一个线性映射的表示矩阵时, 明确变换前后分别是采用哪组基, 然后把定义域空间中的基在映射下的像写出来, 用值域中的基展开写出坐标, 以列向量的形式拼成矩阵.

例 4.5. 对 $\mathbb{R}$ 上的线性空间 $V = \langle \sin x, \cos x \rangle$, 定义映射 $\mathcal{D}$ 是求导变换, 即 $\mathcal{D}(f(x)) = \frac{d}{dx}f(x)$.

(1) 证明 $\mathcal{D}$ 是 V 上的线性变换.

(2) 写出 $\mathcal{D}$ 在基 $\{\sin x, \cos x\}$ 下的表示矩阵.

解答. (1) 显然 $\sin x$ 与 $\cos x$ 线性无关, 故 $\{\sin x, \cos x\}$ 是 V 的一组基. 任取 V 中元素 $f(x) = C_1 \sin x + C_2 \cos x$, 则 $\mathcal{D}(f(x)) = \frac{d}{dx}f(x) = C_1 \cos x - C_2 \sin x \in V$, 因此 $\mathcal{D}$ 是 $V \rightarrow V$ 的映射.

由高等数学的知识知道, 因为 $\frac{d}{dx}(f(x) + g(x)) = \frac{d}{dx}f(x) + \frac{d}{dx}g(x)$, $\frac{d}{dx}(kf(x)) = k\frac{d}{dx}f(x)$, 因此 $\mathcal{D}$ 是线性映射.

综上, $\mathcal{D}$ 是 V 上的线性变换.

(2) $\mathcal{D}(\sin x) = \cos x$, 在基 $\{\sin x, \cos x\}$ 下的坐标为 $(0, 1)^T$; $\mathcal{D}(\cos x) = -\sin x$, 在基 $\{\sin x, \cos x\}$ 下的坐标为 $(-1, 0)^T$. 将它们按序拼在一起即是 $\mathcal{D}$ 在基 $\{\sin x, \cos x\}$ 下的表示矩阵:

$$D = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$$

例 4.6. 给定 $\mathbb{R}^3$ 的两组基:

$$\begin{cases} \alpha_1 = (1, 0, 1) \\ \alpha_2 = (2, 1, 0) \\ \alpha_3 = (1, 1, 1) \end{cases} \quad \begin{cases} \beta_1 = (1, 2, -1) \\ \beta_2 = (2, 2, -1) \\ \beta_3 = (2, -1, -1) \end{cases}$$

线性变换 σ 满足 $\sigma(\alpha_i) = \beta_i$ ($i = 1, 2, 3$).

(1) 写出基 $\{\alpha_i\}$ 到基 $\{\beta_i\}$ 的过渡矩阵.

(2) 写出 σ 在基 $\{\alpha_i\}$ 下的表示矩阵.

(3) 写出 σ 在基 $\{\beta_i\}$ 下的表示矩阵.

分析. $\mathbb{R}^n$ 空间虽然简单, 但概念也容易混淆. $\mathbb{R}^n$ 作为线性空间, 其元素本身是 n 维数组, 而在某一组基下的坐标也是数组. 因此, “向量”和“坐标”需要严格地区分. 如题目中给出的 α_i 和 β_i 是两组基, 因此给出的是 $\mathbb{R}^n$ 中的元素, 而非坐标.

解答.

(1) 请注意, 第 (1) 问和第 (2) 问只是同一概念的两种不同叙述, 因此直接做第 (2) 问.

(2) 我们只需要写出每个 β_j 在基 $\{\alpha_i\}$ 下的坐标. 也就是说, σ 在 $\{\alpha_i\}$ 下的表示矩阵 (过渡矩阵) P 的第 j 个列向量 $p_i = (p_{1j}, p_{2j}, p_{3j})$ 满足:

$$p_{1j}\alpha_1 + p_{2j}\alpha_2 + p_{3j}\alpha_3 = \beta_j$$

这其实就是要解矩阵方程 $AP = B$ (待求解矩阵 P 按列分块即可看出), 其中 A 和 B 分别由 α_i 和 β 这两组基拼出:

$$A = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{pmatrix} \quad B = \begin{pmatrix} 1 & 2 & 2 \\ 2 & 2 & -1 \\ -1 & -1 & -1 \end{pmatrix}$$

解得:

$$P = \begin{pmatrix} -2 & -\frac{3}{2} & \frac{3}{2} \\ 1 & \frac{3}{2} & \frac{3}{2} \\ 1 & \frac{1}{2} & -\frac{5}{2} \end{pmatrix}$$

(3) σ 在 $\{\beta_i\}$ 下的矩阵为 $B = P^{-1}PP = P$.

例 4.7. 设 V 和 W 是线性空间, 线性映射 $\varphi: V \rightarrow W$. 证明:

(1) φ 是单射当且仅当 $\text{Ker } \varphi = \{0\}$.

(2) φ 是单射当且仅当它的表示矩阵列满秩.

(3) φ 是满射当且仅当它的表示矩阵行满秩.

分析. 第 (2)、(3) 问的关键是把结论 “翻译” 成矩阵语言, 然后根据矩阵的性质说明原因.

证明.

(1) “ $\implies$ ”: 若 φ 是单射, 则对任意的 $y \in \text{Im } \varphi$, 存在唯一 $x \in V$, 使得 $\varphi(x) = y$. 现在令 $y = 0$. 已知 $\varphi(0) = 0$, 则 0 是唯一使得 $\varphi(x) = 0$ 的 x , 即 $\text{Ker } \varphi = \{0\}$.

“ $\Leftarrow$ ”：设 $\mathbf{y} \in \text{Im } \varphi$, $\mathbf{y} = \varphi(\mathbf{x}_1) = \varphi(\mathbf{x}_2)$. 则 $\varphi(\mathbf{x}_1 - \mathbf{x}_2) = \varphi(\mathbf{x}_1) - \varphi(\mathbf{x}_2) = \mathbf{0}$. 因为 $\text{Ker } \varphi = \{\mathbf{0}\}$, 所以只能是 $\mathbf{x}_1 - \mathbf{x}_2 = \mathbf{0}$, 即 $\mathbf{x}_1 = \mathbf{x}_2$. 因此 φ 是单射.

(2) 设 φ 的一个表示矩阵是 A , 向量 $\mathbf{x} \in V$ 在相应基下的坐标记为 $\mathbf{X}$. 则:

$$\begin{aligned}\varphi \text{ 是单射} &\iff \text{Ker } \varphi = \{\mathbf{0}\} \iff \text{齐次线性方程组 } A\mathbf{X} = \mathbf{0} \text{ 只有零解} \\ &\iff A \text{ 列满秩}\end{aligned}$$

这里最后一步利用了线性方程组解的判定定理.

(3) 又设向量 $\mathbf{y} \in W$ 在相应基下的坐标记为 $\mathbf{Y}$. 则:

$$\begin{aligned}\varphi \text{ 是满射} &\iff \text{对任意给定的 } \mathbf{Y}, \text{ 线性方程组 } A\mathbf{X} = \mathbf{Y} \text{ 必定有解} \\ &\iff A \text{ 化成简化行阶梯型矩阵后没有零行} \\ &\iff A \text{ 行满秩}\end{aligned}$$

□

4.4.3 线性同构

例 4.8. 从线性同构的定义出发证明: 线性空间的同构是等价关系.

分析. 本题用于熟悉同构映射的概念和线性映射的记号.

证明. 需证明反身性、对称性和传递性.

(1) 反身性: 设 V 是线性空间, 要证明 V 与自身同构. 注意到 V 上的恒等变换 id_V 是 V 到自身的一个同构映射, 因为它显然是双射, 也是线性映射.

(2) 对称性: 设数域 $\mathbb{K}$ 上的线性空间 V_1 同构于 V_2 , 同构映射 $\sigma: V_1 \rightarrow V_2$. 要证明 V_2 同构于 V_1 , 即存在 $V_2 \rightarrow V_1$ 的同构映射.

考虑 σ 的逆映射 $\sigma^{-1}: V_2 \rightarrow V_1$. 显然它是双射. 只需证明它是线性映射. 对任意 $\mathbf{y}_1, \mathbf{y}_2 \in V_2$, 存在 $\mathbf{x}_1 = \sigma^{-1}(\mathbf{y}_1)$, $\mathbf{x}_2 = \sigma^{-1}(\mathbf{y}_2)$. 则由 $\sigma(\mathbf{x}_1 + \mathbf{x}_2) = \sigma(\mathbf{x}_1) + \sigma(\mathbf{x}_2) = \mathbf{y}_1 + \mathbf{y}_2$ 可以推知:

$$\sigma^{-1}(\mathbf{y}_1 + \mathbf{y}_2) = \mathbf{x}_1 + \mathbf{x}_2 = \sigma^{-1}(\mathbf{y}_1) + \sigma^{-1}(\mathbf{y}_2)$$

再任取 $k \in \mathbb{K}$, 由 $\sigma(k\mathbf{x}_1) = k\sigma(\mathbf{x}_1) = k\mathbf{y}_1$ 可知:

$$\sigma^{-1}(k\mathbf{y}_1) = k\mathbf{x}_1 = k\sigma^{-1}(\mathbf{y}_1)$$

这证明了 σ^{-1} 是线性映射. 因此 $\sigma^{-1}: V_2 \rightarrow V_1$ 是同构映射.

(3) 传递性: 设数域 $\mathbb{K}$ 上的线性空间 V_1 同构于 V_2 , 同构映射 $\sigma_1: V_1 \rightarrow V_2$; V_2 同构于 V_3 , 同构映射 $\sigma_2: V_2 \rightarrow V_3$. 要证明 V_1 同构于 V_3 , 即找到 $V_1 \rightarrow V_3$ 的同构映射.

考虑复合映射 $\sigma_1 \circ \sigma_2: V_1 \rightarrow V_3$, 两个双射的复合依然是双射, 因此 $\sigma_1 \circ \sigma_2$ 是双射. 只需证明它是线性映射.

任取 $\mathbf{x}_1, \mathbf{x}_2 \in V_1$, 则:

$$\begin{aligned}\sigma_1 \circ \sigma_2(\mathbf{x}_1 + \mathbf{x}_2) &= \sigma_1(\sigma_2(\mathbf{x}_1 + \mathbf{x}_2)) = \sigma_1(\sigma_2(\mathbf{x}_1) + \sigma_2(\mathbf{x}_2)) \\ &= \sigma_1(\sigma_2(\mathbf{x}_1)) + \sigma_1(\sigma_2(\mathbf{x}_2)) = \sigma_1 \circ \sigma_2(\mathbf{x}_1) + \sigma_1 \circ \sigma_2(\mathbf{x}_2)\end{aligned}$$

再任取 $k \in \mathbb{K}$, 则:

$$\sigma_1 \circ \sigma_2(k\mathbf{x}_1) = \sigma_1(\sigma_2(k\mathbf{x}_1)) = \sigma_1(k\sigma_2(\mathbf{x}_1)) = k\sigma_1(\sigma_2(\mathbf{x}_1)) = k \cdot \sigma_1 \circ \sigma_2(\mathbf{x}_1)$$

这证明了 $\sigma_1 \circ \sigma_2$ 是线性映射. 因此 $\sigma_1 \circ \sigma_2: V_1 \rightarrow V_3$ 是同构映射.

□

例 4.9. 设 V 是数域 $\mathbb{K}$ 上的 n 维线性空间. 全体 $V \rightarrow \mathbb{K}$ 的线性映射组成的集合 $\text{Hom}(V, \mathbb{K})$ 也记作 V^* , 称为 V 的对偶空间. 证明 V 与其对偶空间同构, 并给出一个同构映射.

分析. 按课本知识, 证明两个相同数域上的线性空间同构是很容易的——只需证明它们的维数相同即可. 参考例 4.2 的结论, V 与 V^* 的维数都是 n , 显然同构. 关键在于给出一个具体的同构映射. 最简单的方式是找到两个线性空间的各一组基, 在基之间建立一一对应关系, 就自然诱导出一个同构映射.

证明. 根据例 4.2 的结论, 如果取定了 V 的一组基 $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$, 则可以取 V^* 中的 n 个元素 $\mathbf{e}_i^*$ 为一组基, 定义方式按照:

$$\mathbf{e}_i^*(\mathbf{e}_j) = \delta_{ij}$$

即 $\mathbf{e}_i^*$ 作用于 $\mathbf{e}_i$ 输出 1, 作用于其他 $\mathbf{e}_j$ 输出 0.

建立自然的一一对应关系 $\mathbf{e}_i \mapsto \mathbf{e}_i^*$, 因为一组基在变换下的像可以唯一确定一个线性映射, 上述对应关系就确定了一个线性映射 $\sigma: V \rightarrow V^*$, 以单位矩阵 I 为表示矩阵. 这就是 $V \rightarrow V^*$ 的一个最简单的同构映射.

□

例 4.10. 设 V 和 W 分别是数域 $\mathbb{K}$ 上的 n 维和 m 维线性空间, $\mathcal{A}: V \rightarrow W$ 是线性映射. 对于 $x \in V$, 记 $\bar{x} = x + \text{Ker } \mathcal{A}$ (称为 $\text{Ker } \mathcal{A}$ 的陪集). 全体 $\text{Ker } \mathcal{A}$ 的陪集组成的集合记为 $V/\text{Ker } \mathcal{A}$, (称为商集). 在商集中的加法和数乘规定如下:

$$\begin{aligned}\bar{x}_1 + \bar{x}_2 &= \overline{x_1 + x_2}, \quad \forall x_1, x_2 \in V \\ k\bar{x}_1 &= \overline{kx_1}, \quad \forall x \in V, k \in \mathbb{K}\end{aligned}$$

- (i) 证明: $V/\text{Ker } \mathcal{A}$ 是数域 $\mathbb{K}$ 上的线性空间.
- (ii) 证明: $\dim(V/\text{Ker } \mathcal{A}) = n - \dim \text{Ker } \mathcal{A}$.
- (iii) 证明: $V/\text{Ker } \mathcal{A} \cong \text{Im } \mathcal{A}$, 从而得到维数公式 $n = \dim \text{Im } \mathcal{A} + \dim \text{Ker } \mathcal{A}$.

分析. 本题给出了一个对维数公式 $n = \dim \text{Im } \mathcal{A} + \dim \text{Ker } \mathcal{A}$ 的更自然的证明.

需要补充的一个问题是, 陪集的加法和数乘是利用代表元的加法和数乘来定义的, 那么这种定义是不是良定义? 或者说, 如果更换代表元来记同一个陪集, 陪集的加法和数乘的结果是否会因此变换? 这里给出证明 (不作为题目解答的一部分): 假设 $\bar{\alpha}_1 = \bar{\gamma}_1$, $\bar{\alpha}_2 = \bar{\gamma}_2$, 我们可以证明 $\overline{\gamma_1 + \gamma_2} = \overline{\alpha_1 + \alpha_2}$ 以及 $\overline{k\gamma_1} = \overline{k\alpha_1}$. 这是因为, 由假设可知 $\alpha_1 - \gamma_1 \in \text{Ker } \mathcal{A}$, $\alpha_2 - \gamma_2 \in \text{Ker } \mathcal{A}$. 于是:

$$\begin{aligned}(\alpha_1 + \alpha_2) - (\gamma_1 + \gamma_2) &= (\alpha_1 - \gamma_1) + (\alpha_2 - \gamma_2) \in \text{Ker } \mathcal{A} \\ k\alpha_1 - k\gamma_1 &= k(\alpha_1 - \gamma_1) \in \text{Ker } \mathcal{A}\end{aligned}$$

因此加法和数乘是良定义的.

证明.

(i) $\text{Ker } \mathcal{A}$ 的陪集做加法和数乘仍是 $\text{Ker } \mathcal{A}$ 的陪集, 因此商集 $V/\text{Ker } \mathcal{A}$ 对陪集和加法和数乘运算封闭. 以下验证线性空间的 8 条规则. 设 $\bar{\alpha}, \bar{\alpha}_1, \bar{\alpha}_2, \bar{\alpha}_3$ 是 $V/\text{Ker } \mathcal{A}$ 中任取的向量, $k, l \in \mathbb{K}$.

(1) 加法单位元: $V/\text{Ker } \mathcal{A}$ 中存在零元素 $\bar{0} = \text{Ker } \mathcal{A}$, 使得对任意 $\bar{\alpha} \in V/\text{Ker } \mathcal{A}$, $\bar{0} + \bar{\alpha} = \overline{0 + \alpha} = \bar{\alpha}$.

(2) 加法结合律:

$$\bar{\alpha}_1 + (\bar{\alpha}_2 + \bar{\alpha}_3) = \overline{\alpha_1 + \alpha_2 + \alpha_3} = \overline{\alpha_1 + \alpha_2 + \alpha_3} = \overline{\alpha_1 + \alpha_2} + \bar{\alpha}_3 = (\bar{\alpha}_1 + \bar{\alpha}_2) + \bar{\alpha}_3$$

(3) 加法的逆: $\forall \bar{\alpha} \in V/\text{Ker } \mathcal{A}$, 存在一个它的负元素 $\overline{-\alpha}$, 使得 $\bar{\alpha} + (\overline{-\alpha}) = \bar{0}$.

(4) 加法交换律:

$$\bar{\alpha}_1 + \bar{\alpha}_2 = \overline{\alpha_1 + \alpha_2} = \overline{\alpha_2 + \alpha_1} = \bar{\alpha}_2 + \bar{\alpha}_1$$

(5) 数乘单位: $1 \cdot \bar{\alpha} = \bar{\alpha}$.

(6) 数乘结合律:

$$k(l\bar{\alpha}) = k\overline{l\alpha} = \overline{kl\alpha} = (kl)\bar{\alpha}$$

(7) 数乘分配律 I:

$$k(\bar{\alpha}_1 + \bar{\alpha}_2) = k \cdot \overline{\alpha_1 + \alpha_2} = \overline{k\alpha_1 + k\alpha_2} = k\bar{\alpha}_1 + k\bar{\alpha}_2$$

(8) 数乘分配律 II:

$$(k+l)\bar{\alpha} = \overline{(k+l)\alpha} = \overline{k\alpha + l\alpha} = k\bar{\alpha} + l\bar{\alpha}$$

因此 $V/\text{Ker } \mathcal{A}$ 是一个线性空间 (商空间)。

(ii) 设 $\text{Ker } \mathcal{A}$ 有一组基 $\eta_1, \eta_2, \dots, \eta_s$. 往里面继续添加 $r = n - s$ 个线性无关的向量 $\gamma_1, \gamma_2, \dots, \gamma_r$, 可以使其扩展成 V 的一组基. 猜测额外添加的这组向量 $\gamma_1, \gamma_2, \dots, \gamma_r$ 对应于商空间 $V/\text{Ker } \mathcal{A}$ 的一组基 $\bar{\gamma}_1, \bar{\gamma}_2, \dots, \bar{\gamma}_r$.

现在证明上述 r 个陪集的确是商空间的一组基, 从而商空间的维数就是 $n - \dim \text{Ker } \mathcal{A}$. 按照基的定义, 需要做两部分的工作.

第一, 证明 $\bar{\gamma}_1, \bar{\gamma}_2, \dots, \bar{\gamma}_r$ 是线性无关的. 我们已知 $\gamma_1, \gamma_2, \dots, \gamma_r$ 线性无关, 即存在一组不全为 0 的数 $k_1, k_2, \dots, k_r$, 使得以下等式成立:

$$k_1\gamma_1 + k_2\gamma_2 + \dots + k_r\gamma_r = \mathbf{0}$$

根据陪集的加法和数乘规则, 将这个等式左右两边头顶上加一横, 变成陪集运算的等式, 仍然成立:

$$k_1\bar{\gamma}_1 + k_2\bar{\gamma}_2 + \dots + k_r\bar{\gamma}_r = \bar{\mathbf{0}}$$

于是线性无关性得证.

第二, 证明 $V/\text{Ker } \mathcal{A}$ 中每个元素都能由 $\bar{\gamma}_1, \dots, \bar{\gamma}_r$ 线性表示. 已知 $\eta_1, \eta_2, \dots, \eta_s, \gamma_1, \dots, \gamma_r$ 是 V 的一组基, 因此任意的 $x \in V$ 都能由它线性表示:

$$l_1\eta_1 + l_2\eta_2 + \dots + l_s\eta_s + l_{s+1}\gamma_1 + l_{s+2}\gamma_2 + \dots + l_n\gamma_r = x$$

将这个等式左右两边头顶上加一横, 仍然成立:

$$l_1\bar{\eta}_1 + l_2\bar{\eta}_2 + \dots + l_s\bar{\eta}_s + l_{s+1}\bar{\gamma}_1 + l_{s+2}\bar{\gamma}_2 + \dots + l_n\bar{\gamma}_r = \bar{x}$$

但注意 $\eta_1, \eta_2, \dots, \eta_s$ 是 $\text{Ker } \mathcal{A}$ 的一组基, 它们都是 $\text{Ker } \mathcal{A}$ 中的元素, 故以它们为代表元的陪集其实都是 $\text{Ker } \mathcal{A} = \bar{\mathbf{0}}$. 上式的前 s 项就可以直接划掉了:

$$l_{s+1}\overline{\gamma_1} + l_{s+2}\overline{\gamma_2} + \cdots + l_n\overline{\gamma_r} = \overline{x}$$

由 x 的任意性, $\overline{x}$ 是 $V/\text{Ker } \mathcal{A}$ 中的任意元素. 因此这就证明了 $V/\text{Ker } \mathcal{A}$ 中的任意元素都能由 $\overline{\gamma_1}, \overline{\gamma_2}, \cdots, \overline{\gamma_r}$ 线性表示.

综上所述, $\overline{\gamma_1}, \overline{\gamma_2}, \cdots, \overline{\gamma_r}$ 是 $V/\text{Ker } \mathcal{A}$ 的一组基, 因此 $\dim(V/\text{Ker } \mathcal{A}) = r = n - s$. 这就证明了商空间的维数公式:

$$n = \dim \text{Ker } \mathcal{A} + \dim(V/\text{Ker } \mathcal{A})$$

(iii) 我们通过建立 $\text{Im } \mathcal{A} \rightarrow V/\text{Ker } \mathcal{A}$ 的线性同构映射来说明 $\dim(V/\text{Ker } \mathcal{A}) = \dim \text{Im } \mathcal{A}$. 对于 $\beta \in \text{Im } \mathcal{A}$, 记 $\phi(\beta)$ 是 β 的原像集, 即 $\phi(\beta) = \mathcal{A}^{-1}(\{\beta\})$. (回忆线性方程组解的结构, 可以自然地想到这个构造方法.)

首先证明 ϕ 是 $\text{Im } \mathcal{A} \rightarrow V/\text{Ker } \mathcal{A}$ 的映射, 即对任意的 $\beta \in \text{Im } \mathcal{A}$, 必定有 $\phi(\beta) \in V/\text{Ker } \mathcal{A}$. 设 $\beta = \mathcal{A}(x)$. 则对任意 $x_0 \in \text{Ker } \mathcal{A}$, $\mathcal{A}(x + x_0) = \beta$, 因此 $x + \text{Ker } \mathcal{A} = \overline{x} \subset \phi(\beta)$. 反之, 如果 $y \notin \overline{x}$, 则 $\mathcal{A}(x) - \mathcal{A}(y) = \mathcal{A}(x - y) \neq 0$, 即 $\mathcal{A}(y) \neq \beta$, 因此 $\phi(\beta) = \overline{x} \in V/\text{Ker } \mathcal{A}$. 也就证明了 ϕ 是 $\text{Im } \mathcal{A} \rightarrow V/\text{Ker } \mathcal{A}$ 的映射, 同时也证明了是单射.

另外, 根据 ϕ 的定义, 对任意 $\overline{x} \in V/\text{Ker } \mathcal{A}$, 有 $\phi(\mathcal{A}(x)) = \overline{x}$, 因此 ϕ 是满射. 这就证明了 ϕ 是双射.

最后再证明 ϕ 是线性映射. 任取 $\beta_1, \beta_2 \in \text{Im } \mathcal{A}$. 则存在 $x_1, x_2 \in V$, 使得 $\beta_1 = \mathcal{A}(x_1)$, $\beta_2 = \mathcal{A}(x_2)$. 则 $\beta_1 + \beta_2 = \mathcal{A}(x_1 + x_2)$, 因此:

$$\phi(\beta_1) + \phi(\beta_2) = \overline{x_1} + \overline{x_2} = \overline{x_1 + x_2} = \phi(\beta_1 + \beta_2)$$

再任取 $k \in \mathbb{K}$, $k\beta_1 = \mathcal{A}(kx_1)$, 则:

$$k \cdot \phi(\beta_1) = k \cdot \overline{x_1} = \overline{kx_1} = \phi(k \cdot x_1)$$

这就证明了 ϕ 是线性映射. 综上, $\phi: \text{Im } \mathcal{A} \rightarrow V/\text{Ker } \mathcal{A}$ 是同构映射, 因此 $\dim(V/\text{Ker } \mathcal{A}) = \dim \text{Im } \mathcal{A}$. 代入 (2) 的结论, 即得到维数公式:

$$n = \dim \text{Ker } \mathcal{A} + \dim \text{Im } \mathcal{A}$$

□

5 矩阵的运算

5.1 矩阵的加法、数乘和乘法

5.1.1 基本性质

本节我们讨论矩阵加法、数乘和矩阵乘法三种运算. 掌握这三种运算规则本身并不困难, 关键是要理解它与线性映射的加法、数乘和复合运算之间的联系. 本节不涉及线性空间的基变换, 因此在这里讨论矩阵运算和线性映射运算原则上没什么区别. 但为了显示这两个概念的区分, 我们把线性映射用大写花体字母表示 (如 $\mathcal{A}, \mathcal{B}$), 其表示矩阵仍用普通的大写字母表示 (如 A, B). 考虑到相同数域上 n 维线性空间皆同构, 方便起见, 本节用 $\mathbb{K}^n$ 代替数域 $\mathbb{K}$ 上一般的 n 维线性空间.

矩阵乘法是对线性映射复合的表示. 首先要注意不是任意两个矩阵之间都允许做乘法, 必须是前一个矩阵的列数等于后一个矩阵的行数, 即 $m \times n$ 矩阵与 $n \times s$ 矩阵可以做乘法. 这是因为在映射的复合中, 前一个映射的陪域应当等于后一个映射的定义域, 即 $\mathbb{K}^s \rightarrow \mathbb{K}^n$ 的线性映射复合一个 $\mathbb{K}^n \rightarrow \mathbb{K}^m$ 的线性映射是允许的.

映射的复合满足结合律, 但是一般不可交换——即使交换复合顺序之后依然是合法的, 它与换序之前也未必相同. 因此, 可以断言**矩阵乘法满足结合律**, 即 $A(BC) = (AB)C$ 总是成立; 但**矩阵乘法不满足交换律**. 即 $AB \neq BA$ 是很有可能发生的 (即使 A 和 B 是同阶的方阵).

在做矩阵计算时, 如果不知道 A 和 B 的确切身份, 应当默认 AB 不能转化成 BA . 初学者在这里常常会犯错. 例如计算 $(A+B)^2$, 或许顺手就把它展开成 $A^2 + 2AB + B^2$, 但实际上 $(A+B)^2 = (A+B)(A+B) = A^2 + AB + BA + B^2$, 一般不等于 $A^2 + 2AB + B^2$. 又如 $(AB)^2$, 应当是 $ABAB$ 而不等写成 A^2B^2 .

但是, $AB \neq BA$ 也不是任何情况下都不对. 最简单的例子就是单位矩阵 I_n . 我们曾介绍过, 它是代表恒等映射的矩阵, 它在矩阵乘法中的作用如同 “1” 在实数乘法中的作用, 即满足:

$$I_n A_n = A_n I_n = A_n$$

由此还发现, 对任意的 $k \in \mathbb{K}$, 有:

$$(kI_n)A_n = A_n(kI_n) = kA_n$$

即单位矩阵的 k 倍 kI_n 也与任何同阶方阵可交换, 且乘法的效果等同于数乘 k . 因此 kI_n 也称为**数量矩阵**. 处理只涉及数乘、单位矩阵和一个未知矩阵 A 的矩阵代数式时, 就不必畏手畏脚, 可以验证我们熟知的一些代数恒等式代入矩阵后依然成立, 例如运用立方差公式有:

$$I - A^3 = (I - A)(I + A + A^2)$$

初学者有时会因为太害怕交换律不成立而做不出这种最简单的因式分解. 这种极端也要通过练习尽量地避免.

讲到这里, 你可能想问: “一般情况下, 两个矩阵的乘法到底什么时候可以互换?” 很遗憾, 凭借线性代数的课内知识是回答不了这个问题的. 我也没有在讲义中解答这个问题的计划. 不过随着学习的深入我们将有能力给出矩阵乘法交换的一些充分条件. 目前, 我们只要对矩阵乘法的交换保持足够的警惕就可以了.

最后, 因为矩阵的行列式表示线性映射的体积伸缩比例, 连续两个线性映射的伸缩比例相乘, 应该得到总的伸缩比例. 因此, 自然地有行列式在矩阵乘法下的公式: $|AB| = |A||B|$.

5.1.2 矩阵运算与秩

本节我们讨论矩阵的秩在矩阵运算下的变换规律. 主要关注矩阵加法和矩阵乘法. 请注意, 我们不是要从矩阵本身的计算来看待这些规律, 而是要从线性空间和线性映射的角度提供一个更本质的理解. 要想真正取得这种理解 (或者你希望在解题时灵活运用这种理解), 必须牢记以下的基本事实. 首先, 一个线性映射的像空间的维数即是其表示矩阵的秩, 即 $\text{rank}(A) = \dim \text{Im } A$. 这一点在讲义第二章中是以定义的方式提出来的. 另外, 对于 $A: \mathbb{K}^n \rightarrow \mathbb{K}^m$, 有维数公式 $n = \text{rank}(A) + \dim W$, 其中 W 是指齐次线性方程组 $AX = 0$ 的解空间. 用线性映射的语言, 维数公式可以改写成 $n = \dim \text{Im } A + \dim \text{Ker } A$.

对于矩阵加法的秩, 有一个重要的不等式:

$$\text{rank}(A + B) \leq \text{rank}(A) + \text{rank}(B)$$

换言之:

$$\dim \text{Im}(A + B) \leq \dim \text{Im } A + \dim \text{Im } B$$

从这个角度来看, 上述秩不等式是在讨论 $\text{Im}(A + B)$ 与 $\text{Im } A, \text{Im } B$ 这三个线性子空间的维数关系. 它们之间有一个直接的关系是:

$$\text{Im}(A + B) \subset \text{Im } A + \text{Im } B$$

这是因为 $A + B$ 中的元素必定形如 $Ax + Bx$. 于是我们立即得到:

$$\dim \text{Im}(A + B) \leq \dim(\text{Im } A + \text{Im } B) \leq \dim \text{Im } A + \dim \text{Im } B$$

其中，第一个不等号是从包含关系得到的；第二个不等号是从子空间加法的维数公式得到的。不妨在此回忆一下这个公式：

$$\dim(V_1) + \dim(V_2) = \dim(V_1 + V_2) + \dim(V_1 \cap V_2)$$

这个不等式到此就证明完毕了。对于不熟悉线性映射语言的同学，可能更期望一种纯矩阵运算的证明。为此我们稍微多做一些讨论。在维数公式中， $\dim(V_1) + \dim(V_2)$ 也是有一定意义的，它其实就是直和空间 $V_1 \oplus V_2$ 的维数。回到刚才的不等式，所谓 $\text{rank}(A) + \text{rank}(B)$ ，或者 $\dim \text{Im } A + \dim \text{Im } B$ ，实际上是指 $\dim(\text{Im } A \oplus \text{Im } B)$ 。我们知道这其实是一个分块对角矩阵的秩：

$$\begin{pmatrix} A & O \\ O & B \end{pmatrix}$$

它代表一个 $\mathbb{K}^n \oplus \mathbb{K}^n \rightarrow \mathbb{K}^m \oplus \mathbb{K}^m$ 的线性映射， A 是它在第一个 $\mathbb{K}^n$ 上的限制， B 是它在第二个 $\mathbb{K}^n$ 上的限制。 $\text{Im } A \oplus \text{Im } B$ 即是它的像空间。当然，也不难用纯矩阵的方法证明（见习题部分）：

$$\text{rank} \begin{pmatrix} A & O \\ O & B \end{pmatrix} = \text{rank}(A) + \text{rank}(B)$$

利用分块矩阵的初等变换，（后文将会提及），我们将能证明：

$$\text{rank} \begin{pmatrix} A & O \\ O & B \end{pmatrix} = \text{rank} \begin{pmatrix} A & O \\ B & B \end{pmatrix} = \text{rank} \begin{pmatrix} A+B & B \\ B & B \end{pmatrix} \geq \text{rank}(A+B)$$

于是，通过分块矩阵处理两个矩阵秩的相加，我们用纯矩阵的方式再次证明了这个不等式。出于考试的目的，同学们应该熟悉这两种思路中的至少一种。

对于矩阵乘法的秩，也有一个重要的不等式：

$$\text{rank}(AB) \leq \min\{\text{rank}(A), \text{rank}(B)\}$$

从矩阵运算的角度讲，这意义已经很明确：**矩阵乘法不会使得矩阵的秩增大**。现在从线性映射的角度给予证明，并揭示更深刻的意义。设 A 和 B 分别是 $m \times n$ 和 $n \times s$ 矩阵，对应的线性映射 $A: \mathbb{K}^n \rightarrow \mathbb{K}^m$ 和 $B: \mathbb{K}^s \rightarrow \mathbb{K}^n$ 。其复合映射 $A \circ B: \mathbb{K}^s \rightarrow \mathbb{K}^m$ ， AB 即是它的表示矩阵。

先证明 $\text{rank}(AB) \leq \text{rank}(A)$ 。即 $\dim \text{Im}(A \circ B) \leq \dim \text{Im } A$ 。这其实是很简单的事实。如图所示， $A \circ B$ 实质上是对 $\mathbb{K}^s$ 先作用 B ，映射到像空间 $\text{Im } B$ 上，再被 A 作用得到的。因此，所谓

$\text{Im}(\mathcal{A} \circ \mathcal{B})$, 其实就是 $\mathcal{A}$ 在 $\text{Im } \mathcal{B}$ 上的限制的像空间, 即 $\text{Im}(\mathcal{A}|_{\text{Im } \mathcal{B}})$. 这显然包含于未限制定义域的像空间 $\text{Im } \mathcal{A}$, 维数当然不会超过它.

再来证明 $\text{rank}(AB) \leq \text{rank}(B)$. 即 $\dim \text{Im}(\mathcal{A}|_{\text{Im } \mathcal{B}}) \leq \dim \text{Im } \mathcal{B}$. 对 $\mathcal{A}|_{\text{Im } \mathcal{B}}$ 列出维数公式 (注意定义域是 $\text{Im } \mathcal{B}$), 便会发现这是显然的:

$$\dim \text{Im } \mathcal{B} = \dim \text{Im}(\mathcal{A}|_{\text{Im } \mathcal{B}}) + \dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B}})$$

你可以看到, 这个证明过程中并不涉及一丁点真正的计算, 只是对复合映射 $\mathcal{A} \circ \mathcal{B}$ 中涉及的子空间维数进行了粗浅的分析而已. 这个不等式实际上蕴含两条关于线性映射的知识: 第一, 复合映射 $\mathcal{A} \circ \mathcal{B}$ 的像空间即是 $\mathcal{A}$ 限制在 $\text{Im } \mathcal{B}$ 上的像空间. 第二, 一个线性映射的像空间维数不能超过其定义域的维数.

5.2 可逆矩阵与初等变换

5.2.1 可逆矩阵的性质

可逆矩阵所表示的线性映射的双射, 即线性同构映射. 在前几章中已经充分讨论了可逆矩阵的性质, 这里只举几点最重要的. 一个矩阵可逆当且仅当它满秩. 关于行列式, 则有 $|A^{-1}| = |A|^{-1}$. 最后, 一个矩阵与可逆矩阵相乘不改变秩. 具体来说, 设 $P_{m \times m}$ 和 $Q_{n \times n}$ 是可逆矩阵, $A_{m \times n}$ 的秩为 r , 则有:

$$\text{rank}(PA) = \text{rank}(AQ) = \text{rank}(PAQ) = r$$

5.2.2 初等变换与初等矩阵

回顾矩阵等价的性质. 我们知道, $A_{m \times n}$ 与 $B_{m \times n}$ 等价, 当且仅当 $\text{rank}(A) = \text{rank}(B)$. 对于等价变换的理解有两种. 第一种正如上一小节所说, 如果 A 的左右各乘一个可逆矩阵之后得到 B , 则 A 与 B 等价. 第二种是, 如果 A 能通过初等行变换和初等列变换得到 B , 则 A 与 B 等价. 我们不免会想, 可逆矩阵乘法与初等变换之间一定存在某种关联.

我们定义, 由单位矩阵 I 经过一次初等行 (列) 变换得到的矩阵称为**初等矩阵**. 分为三种:

(1) 把 I 的第 i 行的 k 倍加到第 j 行上 (或者等价地, 第 j 列的 k 倍加到第 i 行上), 得到的初等矩阵记为 $P(j, i(k))$.

(2) 交换 I 的第 i 行和第 j 行 (或者等价地, 交换第 i 列和第 j 列), 得到的初等矩阵记为 $P(i, j)$.

(3) 把 I 的第 i 行乘以非零常数 c (或者等价地, 把第 i 列乘以非零常数 c), 得到的初等矩阵记为 $P(i(c))$.

可以直接验证, 全部三种初等矩阵都一定是可逆的. 而且, 用初等矩阵左乘一个任意矩阵 A , 相当于对 A 进行了一次相应的初等行变换; 用初等矩阵右乘一个任意矩阵 A , 相当于对 A 进行了一次相应的初等列变换. 这样一来, 我们就用矩阵乘法的方式实现了对矩阵的初等变换. 这一点在矩阵求逆问题中是特别实用的. 要想直接计算一个可逆矩阵 A 的逆矩阵很困难 (比如用伴随矩阵法, 需要计算 n^2 个 $n-1$ 阶代数余子式), 但是将 A 初等变换为一个单位矩阵总是可以做到的. 假如我们只使用一系列初等行变换, 将 A 变成了单位矩阵 I , 这相当于对 A 左乘了一系列初等矩阵 $P_1, P_2, \dots, P_k$:

$$(P_k P_{k-1} \cdots P_2 P_1)A = I$$

则这些初等矩阵的乘积 $P_k P_{k-1} \cdots P_2 P_1$ 就是 A^{-1} . 换句话说, 把这一系列初等行变换作用到 I 上, 就得到了 A^{-1} . 在实际操作中, 我们只需要把 A 和一个单位矩阵 I 并排放在一起 ($A | I$), 对它们同时做初等行变换. 当把左侧的 A 变为 I 时, 右侧的 I 就自动随之变为 A^{-1} 了.

注意, 类似这样的初等行变换法本身不是专为矩阵求逆服务的, 而是利用了“初等变换等价于乘可逆矩阵”的性质. 因此, 这一方法可用于求解各类矩阵方程. 例如求解 $AX = B$, 实质上是计算 $X = A^{-1}B$, 但不必先计算 A^{-1} 再与 B 做乘法, 只需把 A 和 B 并排放在一起 ($A | B$), 对它们同时做初等行变换, 当把左侧的 A 变为 I 时, 右侧的 B 就自动随之变为 $A^{-1}B$ 了.

5.2.3 分块矩阵与分块初等变换

分块矩阵无非是以矩阵为元素的矩阵, 其加法、乘法和初等变换的规则与普通的矩阵乘法一致, 只不过在进行矩阵元素的计算时, 以矩阵加法和乘法代替了数的加法和乘法. 数域中的非零元素可类比于可逆矩阵, 因此在分块初等行列变换中, 将某一块行左乘一个可逆矩阵, 或者将某一块列右乘一个可逆矩阵都是允许的, 但是乘不可逆矩阵却不允许. 而把某一块行的左 P 倍加到另一块行, 或者把某一块列的右 P 倍加到另一块列上时, P 只需让矩阵运算有定义, 而不需要 P 可逆.

一般来说, 我们不会孤立地看待分块矩阵. 为了便于研究数域 $\mathbb{K}$ 上的矩阵, 有时我们愿意把它用“切豆腐块”的方式, 看成一些小矩阵拼成的大矩阵. 这就用到了分块矩阵的概念. 它之所以好用, 基础在于: (1) 按分块矩阵的方式做加法和矩阵乘法, 与不分块是一致的. (2) 分块初等行(列)变换相当于批量地进行普通的初等行(列)变换, 因此同样有保持秩不变的性质. 5.1.2 节的例子即展示了分块矩阵的这种用法.

我们还强调过, 在矩阵运算中应当把矩阵看成行(列)向量组, 而不是仅仅看成许多矩阵元素排列成一个方块. 这也可以用分块矩阵的方式来理解. 比如, 考虑矩阵方程 $A_{m \times n} X_{n \times s} = B_{m \times s}$.

将 X 按列分块, 即是将其看成列向量组 $X = (\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_s)$. 将矩阵 B 也看成列向量组 $B = (\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_s)$. 根据分块矩阵的运算规则, 有:

$$AX = A(\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_s) = (A\mathbf{X}_1, A\mathbf{X}_2, \dots, A\mathbf{X}_s) = (\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_s)$$

即 $A\mathbf{X}_j = \mathbf{b}_j, j = 1, 2, \dots, s$. 因此, 矩阵方程 $AX = B$ 无非是 s 个线性方程组集成在一起. 或者说, 是批量地写出了线性映射 $\mathcal{A}$ 作用在 s 个向量上的表达式. 这提出了一种不同于线性映射复合的, 关于矩阵乘法的理解.

5.3 矩阵的转置

矩阵**转置**是将矩阵的行列指标互换的操作. 矩阵 A 的转置记为 A^T . 有几条显然的性质是: $(A^T)^T = A, (A + B)^T = A^T + B^T, (kA)^T = kA^T$.

在不涉及矩阵乘法时, 矩阵的行与列地位是对等的, 这在之前的章节中体现在两个方面: (1) 矩阵的行秩和列秩相等, (2) 矩阵行列式的展开式关于行指标和列指标是对称的. 这体现为矩阵转置的两个性质: $\text{rank}(A) = \text{rank}(A^T), |A| = |A^T|$.

但是, 由于矩阵乘法的规则, 在运算过程中不能随意地将矩阵转置, 这破坏了矩阵行与列的对称性. 例如, 设 A 是 $m \times n$ 矩阵, $\mathbf{X}$ 是 n 维列向量, 则 $A\mathbf{X}$ 是一个合法的矩阵乘法, 用以表示线性映射 $\mathcal{A}$ 对向量 $\mathbf{x}$ 的作用. 矩阵乘法 $A\mathbf{X}^T$ 是不合法的. 欲使矩阵乘法在转置下依然合法, 必须二者一起转置, 并且调换顺序, 即: $\mathbf{X}^T A^T$ 是合法的. 然而这运算与 $A\mathbf{X}$ 没有什么本质不同, 只不过将运算过程“翻转”过来了而已. 更一般地, 对于 $m \times n$ 矩阵 A 与 $n \times s$ 矩阵 B 的乘法, 有: $(AB)^T = B^T A^T$.

特别地, 将这个规则应用于矩阵等式 $A^{-1}A = I$, 其中 A 是可逆矩阵. 注意 I 的转置等于自身, 得到 $A^T(A^{-1})^T = I$. 这告诉我们, 矩阵的转置和取逆操作是可以交换顺序的, 即 $(A^T)^{-1} = (A^{-1})^T$.

以上, 我们从纯矩阵视角说明了转置矩阵的各个性质. 可以看到, 矩阵转置恰如其名, 无非是把矩阵转过来看而已, 并不带来什么新的数学性质. 但是, 如果把矩阵视为线性映射的表示, 转置就有了非凡的意义: $m \times n$ 矩阵表示的是 m 维到 n 维空间的线性映射, 而转置后的 $n \times m$ 矩阵表示的却是 n 维到 m 维的线性映射了. 矩阵转置前后所代表的线性映射有什么关联? 本节将回答这个问题.

5.3.1 * 对偶空间

设 V 是数域 $\mathbb{K}$ 上的 n 维线性空间, 取定一组基 $\{e_1, e_2, \dots, e_n\}$. V 中的向量在这组基下表示为 n 维列向量. 我们引入**对偶空间**的概念来严肃地安置**行向量**的地位, 而不是仅仅将它看成“横着写的向量”.

考虑 $V \rightarrow \mathbb{K}$ 的线性映射, 也就是把 V 中向量映成一个数的线性映射. 这种线性映射称为 V 上的**线性泛函**. 全体 V 上的线性泛函组成的集合, 按线性映射的记法, 应该记为 $\text{Hom}(V, \mathbb{K})$. 线性泛函的表示矩阵即为 $1 \times n$ 矩阵, 即行向量. 由此, 我们可以看出线性泛函相比于更一般的线性映射, 具有一定的特殊性. 首先, $\text{Hom}(V, \mathbb{K})$ 不但是 $\mathbb{K}$ 上的线性空间, 而且和 V 本身一样, 也是 n 维的线性空间, 也就是说与 V 是同构的. 另外, 向量在矩阵符号中表示为列向量, 而线性泛函表示为行向量, 是由某个列向量转置而来的. 这说明, 在取定 V 的一组基的条件下, V 中的向量和线性泛函有着自然的一一对应关系, 通过矩阵转置联系起来. 可以说, 线性泛函好比是向量的水中倒影, 二者虽然不同, 但是本为一体, 互为镜像.

为了更好地描述线性泛函与向量本质相同的性质, 我们把 $\text{Hom}(V, \mathbb{K})$ 称为 V 的**对偶空间**, 记作 V^* . V^* 中的元素称为**对偶向量**, 取代“线性泛函”这个名称. 将一个对偶向量 $w^* \in V^*$ 与一个向量 $v \in V$ 放在一起, 它们将相互作用“缩并”成一个数 $w^*(v)$. 以矩阵乘法表示:

$$(a_1, a_2, \dots, a_n) \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix} = a_1 b_1 + a_2 b_2 + \dots + a_n b_n$$

这正是欧氏空间中两个向量标准内积（点乘）的算法. 这也表明把线性泛函看成一种“对偶向量”是十分恰当的.

为了显示向量与对偶向量的对称性, 不妨想一个问题: 对偶空间 V^* 的对偶空间是什么? 其实, 向量本身就可以看成是“对偶对偶向量”, 即我们认为 V^{**} 其实就是 V . 以对偶向量 w^* 与向量 v 的作用来说明这一点. 注意对偶向量本质上是一种特殊的线性映射. 通常, 我们会认为这个过程是给对偶向量 $w^*(\cdot)$ 输入一个向量 v (想象括号是 w^* 的一张张嘴, 等着吃进去一个向量), 然后输出一个数 $w^*(v)$. 但是反过来想也未尝不可. 即: 给向量 v 在左侧输入一个对偶向量 w^* , 便输出一个数. 这样看来, 完全可以说**向量是将对偶向量映为一个数的线性泛函, 也就是对偶向量的对偶向量**. 从矩阵视角来看, 这表现为行向量和列向量互为对方的转置. 在水中倒影看来, 岸上的人亦是它的倒影. 向量与对偶向量固然是“输入”和“输出”的对立关系, 但究竟谁为向量, 谁为线性泛函, 只是不同立场所引入的视角问题, “彼是方生之说也”.

5.3.2 * 线性映射的转置

本小节我们要解决这样一个问题：假设我们有了 V 中的一个向量，如何找到它在 V^* 中对应的“镜像”？正如上一小节所说，这种“互为镜像”的对应关系用矩阵表示出来，就是矩阵“互为转置”的关系。

为了能够在对偶空间中也能写出表示矩阵，我们首先需要确定对偶空间中的一组基。更具体地说，需要确定 V 中的一组基 $\{e_1, e_2, \dots, e_n\}$ 在 V^* 中对应的“镜像”是什么。我们把这组基的“镜像”记为 $\{e_1^*, e_2^*, \dots, e_n^*\}$ ，它是 V^* 的一组基，称为**对偶基**。 e_i^* 的定义满足下式：

$$e_i^*(e_j) = \delta_{ij} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

注意 e_i^* 本质上是一个线性映射，该式对每个 e_i 给出了它作用到 V 中一组基上的像，因此唯一确定了线性映射 e_i^* 。在这个定义中， e_i^* 与自己的“镜像” e_i 相作用得到 1，与其余“镜像”作用得到 0。更形象地说，一组基可以通过与对偶基的作用与自己的镜像“相认”。

另外请注意，这个定义式与 $\mathbb{K}^n$ 中一组标准正交基相互之间做内积的规律是一致的。事实上，在 V 的一组基 $\{e_i\}$ 下， e_i 自身被表示成 $\mathbb{K}^n$ 标准正交基的第 i 个向量，即第 i 分量是 1，其余分量皆为 0 的列向量。而 V^* 中的对偶基 e_i^* 自身在对偶基下的展开同样是 $\mathbb{K}^n$ 标准正交基的第 i 个向量，只不过写成行向量。因此， $\{e_i^*\}$ 对 e_i 的作用确有标准正交基内积之意。

有了对偶基，我们自然地就能找到任意向量 $v \in V$ 在 V^* 中的“镜像” v^* 。只需按一组基展开，然后将基替换成对偶基即可：

$$v = x_1 e_1 + x_2 e_2 + \dots + x_n e_n \mapsto x_1 e_1^* + x_2 e_2^* + \dots + x_n e_n^* = v^*$$

这种“镜像”关系给出了一个 V 到 V^* 的一个非常自然的同构映射。但要注意，这个同构映射依赖于基的选择，并不是 V 和 V^* 之间天然存在的。

更进一步地，设 V 和 W 是两个线性空间， $\mathcal{A}$ 是 $V \rightarrow W$ 的线性映射。我们希望找到 $\mathcal{A}$ 的“镜像”。由此给出了如下的定义：

线性映射的转置 设 $\mathcal{A}: V \rightarrow W$ 是线性映射，定义 $\mathcal{A}$ 的转置映射 $\mathcal{A}^T$ 为：

$$\mathcal{A}^T: W^* \rightarrow V^*, \quad w^* \mapsto w^* \circ \mathcal{A}$$

就这样，我们把两个线性空间之间的线性映射 $\mathcal{A}$ 镜像对应地“搬到”了两个对偶空间之间当中。那么，转置映射的表示矩阵就是表示矩阵的转置。叙述为以下的定理：

定理 5.3.1 设 V, W 分别是 n 维和 m 维向量空间, 各自取定一组基 $\{v_1, v_2, \dots, v_n\}$ 和 $\{w_1, w_2, \dots, w_m\}$. 依此为 V^* 和 W^* 配备对偶基. 设线性映射 $\mathcal{A}: V \rightarrow W$ 在两组基 $\{v_i\}$ 和 w_j 下的表示矩阵为 A . 则转置映射 $\mathcal{A}^T$ 在两组对偶基下 $\{v_i^*\}$ 和 $\{w_j^*\}$ 下的表示矩阵即为 A^T .

转置映射的表示矩阵作用的对象是行向量, 并输出一个行向量, 因此“用法”应该是右乘行向量, 即依照如下形式:

$$\mathbf{Y}^T = \mathbf{X}^T A^T$$

其中 $\mathbf{X}^T, \mathbf{Y}^T$ 是行向量.

对转置映射的性质进行研究, 我们会发现与转置矩阵是完全相同的, 这正体现了转置矩阵作为转置映射的表示矩阵的意义. 比如, 设 $\mathcal{A}$ 和 $\mathcal{B}$ 都是线性映射, 可以按照定义去计算 $(\mathcal{A} \circ \mathcal{B})^T$. 任取 $w^* \in W^*$, 有:

$$\begin{aligned} (\mathcal{A} \circ \mathcal{B})^T(w^*) &= w^* \circ (\mathcal{A} \circ \mathcal{B}) = (w^* \circ \mathcal{A}) \circ \mathcal{B} \\ &= \mathcal{A}^T(w^*) \circ \mathcal{B} = \mathcal{B}^T(\mathcal{A}^T(w^*)) \\ &= \mathcal{B}^T \circ \mathcal{A}^T(w^*) \end{aligned}$$

即得到 $(\mathcal{A} \circ \mathcal{B})^T = \mathcal{B}^T \circ \mathcal{A}^T$. 可见, 线性映射的复合取转置, 等同于分别对各个线性映射去转置, 再颠倒顺序进行复合.

特别地, 取 $\mathcal{A}$ 是 V 上可逆的线性变换, $\mathcal{B} = \mathcal{A}^{-1}$, 则上式给出恒等映射 $\text{id}_{V^*} = (\mathcal{A} \circ \mathcal{A}^{-1})^T = (\mathcal{A}^{-1})^T \circ \mathcal{A}^T$. 即 $(\mathcal{A}^{-1})^T = (\mathcal{A}^T)^{-1}$, 表明线性变换的转置和取逆操作是可交换的.

当 $\mathcal{A}$ 是 V 上的线性变换, $\mathcal{A}$ 对 V 中向量 x 的作用与 $\mathcal{A}^T$ 对 V^* 中对偶向量 x^* 的作用方式是一致的. 即 $(\mathcal{A}x)^* = \mathcal{A}^T(x^*)$. 这一点可以从矩阵运算直接验证出来 (利用 $(AX)^T = X^T A^T$). 自然, $\mathcal{A}$ 在 V 上带来的有向体积缩放比例与 $\mathcal{A}^T$ 在 V^* 上带来的有向体积缩放比例是相等的, 即 $\det \mathcal{A} = \det \mathcal{A}^T$. 相应地有矩阵行列式的关系 $|A| = |A^T|$.

5.3.3 $\text{rank}(\mathcal{A}^T) = \text{rank}(\mathcal{A})$

设 $\mathcal{A}$ 是 $V \rightarrow W$ 的线性映射, 其中 V 是 n 维线性空间. 若 $\dim \text{Ker } \mathcal{A} = s$, 则可以取 $\text{Ker } \mathcal{A}$ 的一组基 $\{e_1, e_2, \dots, e_s\}$. 将其扩展成 V 的一组基 $\{e_1, e_2, \dots, e_n\}$. 现在, 让我们考虑 $\text{Ker } \mathcal{A}$ 以外那部分基 $\{e_{s+1}, e_{s+2}, \dots, e_n\}$, 它在 V^* 中的“镜像”是 $\{e_{s+1}^*, e_{s+2}^*, \dots, e_n^*\}$, 它生成了 V^* 中的一个子空间 $\langle e_{s+1}^*, e_{s+2}^*, \dots, e_n^* \rangle$. 有趣的是, 这个子空间恰是 $\text{Im}(\mathcal{A}^T)$! 这是为什么呢? 请注意 $\text{Im}(\mathcal{A}^T)$ 的性质, 它是所有形如 $w^* \circ \mathcal{A}$ 的, $V \rightarrow \mathbb{K}$ 的线性映射 (即 V^* 中的元素). 根据这里 w^* 的任意性可证 (这里省略证明), $w^* \circ \mathcal{A}$ 可以表示任意以 $\text{Ker } \mathcal{A}$ 为核的线性泛函. 换句话说,

任意拿出 $\text{Im}(\mathcal{A}^T)$ 中的一个元素, 给它喂进 $\text{Ker } \mathcal{A}$ 的一组基 $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$, 必定输出 0. 根据对偶基的定义, 这不恰好就是 $\langle \mathbf{e}_{s+1}^*, \mathbf{e}_{s+2}^*, \dots, \mathbf{e}_n^* \rangle$ 吗? 于是我们知道了, $\dim \text{Im}(\mathcal{A}^T) = n - s$. 再代入 $\mathcal{A}$ 的维数公式, 有 $\dim \text{Im}(\mathcal{A}^T) = \dim \text{Im } \mathcal{A}$. 即 $\text{rank}(\mathcal{A}^T) = \text{rank}(\mathcal{A})$.

上述的推导或许有些抽象. 如果不理解, 不妨以纯矩阵的方式代替一般的线性映射做类似的思考: 如果列向量 $\mathbf{X}$ 满足 $A\mathbf{X} = \mathbf{0}$, 意味着它与 A 的任意行向量点乘皆为 0. 若以欧氏空间 $\mathbb{R}^n$ 进行考虑, 则 $A\mathbf{X} = \mathbf{0}$ 的解空间 $\text{Ker } A$ 与 A 的行空间 $\text{Im}(A^T)$ 形成了 $\mathbb{R}^n$ 的一个直和分解 $\mathbb{R}^n = \text{Ker } A \oplus \text{Im}(A^T)$, 而且它们二者是相互正交的 (两个子空间的这种关系称为**互为正交补**. 注意在一般的线性空间中并没有此结论, 或者说这仅仅是纯矩阵的结论). 显然, 若以 A^T 替换这里的 A , 又得到 $\text{Ker}(A^T)$ 与 $\text{Im } A$ 互为正交补. 这两个结论进一步揭示了 A 与 A^T 的对称关系.

5.4 习题

5.4.1 秩相关的证明 I——分块矩阵法

秩等式与不等式的证明题是一类经典题型. 这类题一般都有两种办法可以解决: 一是利用**分块矩阵**的初等变换, 二是利用**线性映射**的语言进行“翻译”. 本小节先讲第一种方法.

首先证明两个重要结论.

例 5.1. 设 A 是 $m \times n$ 矩阵, B 是 $r \times s$ 矩阵, C 是 $r \times n$ 矩阵. 证明:

(1)

$$\text{rank} \begin{pmatrix} A & O \\ O & B \end{pmatrix} = \text{rank}(A) + \text{rank}(B)$$

(2)

$$\text{rank} \begin{pmatrix} A & O \\ C & B \end{pmatrix} \geq \text{rank}(A) + \text{rank}(B)$$

分析. 讲义前文提及了关于不变子空间直和分解的理解. 这里从矩阵秩的定义出发直接证明.

证明.

(1) 设 $A = (\alpha_1, \dots, \alpha_n)$, $B = (\beta_1, \dots, \beta_s)$, 且 $\text{rank}(A) = k$, $\text{rank}(B) = \ell$.

设 $\alpha_{i_1}, \dots, \alpha_{i_k}$ 是 A 的列向量组的一个极大线性无关组, $\beta_{j_1}, \dots, \beta_{j_\ell}$ 是 B 的列向量组的一个极大线性无关组.

分块矩阵的列向量组为:

$$\begin{pmatrix} \alpha_1 \\ 0 \end{pmatrix}, \dots, \begin{pmatrix} \alpha_n \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ \beta_1 \end{pmatrix}, \dots, \begin{pmatrix} 0 \\ \beta_s \end{pmatrix}$$

考虑向量组:

$$\begin{pmatrix} \alpha_{i_1} \\ 0 \end{pmatrix}, \dots, \begin{pmatrix} \alpha_{i_k} \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ \beta_{j_1} \end{pmatrix}, \dots, \begin{pmatrix} 0 \\ \beta_{j_\ell} \end{pmatrix}$$

这是由 $\begin{pmatrix} A \\ O \end{pmatrix}$ 和 $\begin{pmatrix} O \\ B \end{pmatrix}$ 这两个块列的极大线性无关组拼成的, 因此, 如果再往里添加别的任何列向量, 都会使其线性相关. 我们只需证明它是线性无关的, 从而它就是整个大矩阵的一个极大线性无关组. 若:

$$\sum_{t=1}^k a_t \begin{pmatrix} \alpha_{i_t} \\ 0 \end{pmatrix} + \sum_{u=1}^{\ell} b_u \begin{pmatrix} 0 \\ \beta_{j_u} \end{pmatrix} = \mathbf{0}$$

则:

$$\begin{pmatrix} \sum_{t=1}^k a_t \alpha_{i_t} \\ \sum_{u=1}^{\ell} b_u \beta_{j_u} \end{pmatrix} = \mathbf{0}$$

于是

$$\sum_{t=1}^k a_t \alpha_{i_t} = \mathbf{0}, \quad \sum_{u=1}^{\ell} b_u \beta_{j_u} = \mathbf{0}$$

由线性无关性知:

$$a_1 = \cdots = a_k = 0, \quad b_1 = \cdots = b_{\ell} = 0.$$

故上述向量组线性无关.

因此:

$$\text{rank} \begin{pmatrix} A & 0 \\ 0 & B \end{pmatrix} = k + \ell = \text{rank}(A) + \text{rank}(B)$$

(2) 对照 (1) 中的列向量组取法, 得到:

$$\begin{pmatrix} \alpha_{i_1} \\ \gamma_{i_1} \end{pmatrix}, \dots, \begin{pmatrix} \alpha_{i_k} \\ \gamma_{i_k} \end{pmatrix}, \begin{pmatrix} 0 \\ \beta_{j_1} \end{pmatrix}, \dots, \begin{pmatrix} 0 \\ \beta_{j_{\ell}} \end{pmatrix}$$

其中 γ_i 为 C 的第 i 列. 按类似 (1) 中的论证, 这个向量组同样是线性无关的. 但却不能证明它是极大线性无关组. 因为虽然 $\alpha_{i_1}, \dots, \alpha_{i_k}$ 是 A 的列向量组的一个极大线性无关组, 但 $\begin{pmatrix} \alpha_{i_1} \\ \gamma_{i_1} \end{pmatrix}, \dots, \begin{pmatrix} \alpha_{i_k} \\ \gamma_{i_k} \end{pmatrix}$ 却未必是 $\begin{pmatrix} A \\ C \end{pmatrix}$ 的列向量组的一个极大线性无关组. 有可能再添加别的向量, 使得上述向量组依然线性无关. 因此, 得到的是不等式:

$$\text{rank} \begin{pmatrix} A & 0 \\ C & B \end{pmatrix} \geq k + \ell = \text{rank}(A) + \text{rank}(B)$$

□

有了这两个结论, 我们提出用分块矩阵法证明秩等式和不等式的关键点:

1. 两个矩阵秩相加 $\text{rank}(A) + \text{rank}(B)$ 这样的表达式难以直接处理, 可以写成一个分块矩阵的秩.

2. 分块初等变换不改变矩阵的秩. 在用分块矩阵表达出待证等式或不等式的一部分之后, 可以利用分块初等变换往另一部分的形式上去凑. 构造恰当的分块矩阵需要一点经验, 但找到诀窍后, 证明过程是非常简洁的.

例 5.2. 设 A 是 $m \times n$ 矩阵, B 是 $n \times s$ 矩阵, $AB = O$. 证明: $\text{rank}(A) + \text{rank}(B) \leq n$.

证明.

$$\begin{pmatrix} A & O \\ I & B \end{pmatrix} \xrightarrow{c_2 - c_1 \cdot B} \begin{pmatrix} A & O - AB \\ I & B - IB \end{pmatrix} = \begin{pmatrix} A & O \\ I & O \end{pmatrix}$$

这一初等变换不改变矩阵的秩. 对于左侧的矩阵, 有:

$$\text{rank}(A) + \text{rank}(B) \leq \text{rank} \begin{pmatrix} A & O \\ I & B \end{pmatrix}$$

对于右侧的矩阵, 有:

$$\text{rank} \begin{pmatrix} A & O \\ I & O \end{pmatrix} = \text{rank} \begin{pmatrix} A \\ I \end{pmatrix} \leq n$$

综上, 有:

$$\text{rank}(A) + \text{rank}(B) \leq \text{rank} \begin{pmatrix} A & O \\ I & B \end{pmatrix} = \text{rank} \begin{pmatrix} A & O \\ I & O \end{pmatrix} \leq n$$

□

例 5.3. 设 A 是 $m \times n$ 矩阵, B 是 $n \times r$ 矩阵, C 是 $r \times s$ 矩阵.

(1) 证明 *Sylvester* 秩不等式:

$$\text{rank}(A) + \text{rank}(B) - n \leq \text{rank}(AB)$$

(2) 证明 *Frobenius* 秩不等式:

$$\text{rank}(AB) + \text{rank}(BC) - \text{rank}(B) \leq \text{rank}(ABC)$$

证明. (1)

$$\begin{pmatrix} A & O \\ I_n & B \end{pmatrix} \xrightarrow{c_2 + c_1 \cdot B} \begin{pmatrix} A & -AB \\ I_n & O \end{pmatrix} \xrightarrow{r_1 - A \cdot r_2} \begin{pmatrix} O & -AB \\ I_n & O \end{pmatrix}$$

因此:

$$\text{rank}(A) + \text{rank}(B) \leq \text{rank} \begin{pmatrix} A & O \\ I_n & B \end{pmatrix} = \text{rank} \begin{pmatrix} O & -AB \\ I_n & O \end{pmatrix} = \text{rank}(AB) + n$$

(2)

$$\begin{pmatrix} AB & O \\ B & BC \end{pmatrix} \xrightarrow{c_2 + c_1 \cdot C} \begin{pmatrix} AB & -ABC \\ B & O \end{pmatrix} \xrightarrow{r_1 - A \cdot r_2} \begin{pmatrix} O & -ABC \\ B & O \end{pmatrix}$$

因此:

$$\begin{aligned} \text{rank}(AB) + \text{rank}(BC) &\leq \text{rank} \begin{pmatrix} AB & O \\ B & BC \end{pmatrix} = \text{rank} \begin{pmatrix} O & -ABC \\ B & O \end{pmatrix} \\ &= \text{rank}(ABC) + \text{rank}(B) \end{aligned}$$

□

例 5.4.

(1) 求证: n 阶方阵 A 是幂等矩阵 ($A^2 = A$) 的充要条件是 $\text{rank}(A) + \text{rank}(I_n - A) = n$.

(2) 求证: n 阶方阵 A 是对合矩阵 ($A^2 = I_n$) 的充要条件是 $\text{rank}(I_n + A) + \text{rank}(I_n - A) = n$.

证明.

(1)

$$\begin{aligned} \begin{pmatrix} A & O \\ O & I_n - A \end{pmatrix} &\xrightarrow{r_2+r_1} \begin{pmatrix} A & O \\ A & I_n - A \end{pmatrix} \xrightarrow{c_2+c_1} \begin{pmatrix} A & A \\ A & I_n \end{pmatrix} \\ &\xrightarrow{r_1-r_2} \begin{pmatrix} O & A - I_n \\ A & I_n \end{pmatrix} \xrightarrow{c_1-c_2 \cdot A} \begin{pmatrix} A(A - I_n) & A - I_n \\ O & I_n \end{pmatrix} \end{aligned}$$

即我们知道:

$$\text{rank}(A) + \text{rank}(I_n - A) = \text{rank} \begin{pmatrix} A & O \\ O & I_n - A \end{pmatrix} = \text{rank} \begin{pmatrix} A(A - I_n) & A - I_n \\ O & I_n \end{pmatrix}$$

“ $\implies$ ”: 若 A 是幂等矩阵, 则 $A(A - I_n) = O$. 则:

$$\begin{pmatrix} A(A - I_n) & A - I_n \\ O & I_n \end{pmatrix} = \begin{pmatrix} O & A - I_n \\ O & I_n \end{pmatrix} \xrightarrow{r_1 - (A - I_n) \cdot r_2} \begin{pmatrix} O & O \\ O & I_n \end{pmatrix}$$

于是:

$$\text{rank}(A) + \text{rank}(I_n - A) = \begin{pmatrix} O & O \\ O & I_n \end{pmatrix} = n$$

“ $\impliedby$ ”: 若已知:

$$\text{rank}(A) + \text{rank}(I_n - A) = \text{rank} \begin{pmatrix} A(A - I_n) & A - I_n \\ O & I_n \end{pmatrix} = n$$

根据例 5.1(2) 的结论, 我们知道:

$$\text{rank} \begin{pmatrix} A(A - I_n) & A - I_n \\ O & I_n \end{pmatrix} \geq \text{rank}(A(A - I_n)) + \text{rank}(I_n) = \text{rank}(A(A - I_n)) + n$$

因此只能有 $\text{rank}(A(A - I_n)) = 0$, 即 $A(A - I_n) = O$, A 是幂等矩阵.

(2) (将第 (1) 问的过程复刻一遍, 只不过是 A 和 $I_n - A$ 分别替换成 $I_n + A$ 和 $I_n - A$.)

$$\begin{aligned} \begin{pmatrix} I_n + A & O \\ O & I_n - A \end{pmatrix} &\xrightarrow{r_2+r_1} \begin{pmatrix} I_n + A & O \\ I_n + A & I_n - A \end{pmatrix} \xrightarrow{c_2+c_1} \begin{pmatrix} I_n + A & I_n + A \\ I_n + A & 2I_n \end{pmatrix} \\ &\xrightarrow{r_1-r_2} \begin{pmatrix} O & A - I_n \\ I_n + A & 2I_n \end{pmatrix} \xrightarrow{c_1 - c_2 \cdot 1/2 \cdot (I_n + A)} \begin{pmatrix} 1/2 \cdot (I_n + A)(A - I_n) & A - I_n \\ O & 2I_n \end{pmatrix} \end{aligned}$$

即我们知道:

$$\text{rank}(I_n + A) + \text{rank}(I_n - A) = \text{rank} \begin{pmatrix} I_n + A & O \\ O & I_n - A \end{pmatrix} = \text{rank} \begin{pmatrix} 1/2 \cdot (I_n + A)(A - I_n) & A - I_n \\ O & 2I_n \end{pmatrix}$$

“ $\Rightarrow$ ”：若 A 是对合矩阵，则 $(I_n + A)(A - I_n) = O$ 。则：

$$\begin{pmatrix} 1/2 \cdot (I_n + A)(A - I_n) & A - I_n \\ O & 2I_n \end{pmatrix} = \begin{pmatrix} O & A - I_n \\ O & 2I_n \end{pmatrix} \xrightarrow{1/2 \cdot r_2, r_1 - (A - I_n) \cdot r_2} \begin{pmatrix} O & O \\ O & I_n \end{pmatrix}$$

于是：

$$\text{rank}(I_n + A) + \text{rank}(I_n - A) = \begin{pmatrix} O & O \\ O & I_n \end{pmatrix} = n$$

“ $\Leftarrow$ ”：若已知：

$$\text{rank}(I_n + A) + \text{rank}(I_n - A) = \text{rank} \begin{pmatrix} 1/2 \cdot (I_n + A)(A - I_n) & A - I_n \\ O & 2I_n \end{pmatrix} = n$$

根据例 5.1(2) 的结论，我们知道：

$$\begin{aligned} \text{rank} \begin{pmatrix} 1/2 \cdot (I_n + A)(A - I_n) & A - I_n \\ O & 2I_n \end{pmatrix} &\geq \text{rank}(1/2 \cdot (I_n + A)(A - I_n)) + \text{rank}(2I_n) \\ &= \text{rank}((I_n + A)(A - I_n)) + n \end{aligned}$$

因此只能有 $\text{rank}((I_n + A)(A - I_n)) = 0$ ，即 $(I_n + A)(A - I_n) = O$ ， A 是对合矩阵。□

例 5.5. 设 A 为 $m \times n$ 矩阵。证明：

$$\text{rank}(I_m - AA^T) - \text{rank}(I_n - A^T A) = m - n$$

分析. 为了方便用分块矩阵，把等式理解成 $\text{rank}(I_m - AA^T) + n = \text{rank}(I_n - A^T A) + m$ 。于是我们只需要考虑如何做到：

$$\begin{pmatrix} I_m - AA^T & \\ & I_n \end{pmatrix} \xrightarrow{\text{初等变换}} \begin{pmatrix} I_n - A^T A & \\ & I_m \end{pmatrix}$$

证明. 考虑如下的分块矩阵：

$$\begin{pmatrix} I_m & A \\ A^T & I_n \end{pmatrix}$$

一方面：

$$\begin{pmatrix} I_m & A \\ A^T & I_n \end{pmatrix} \xrightarrow{r_2 - A^T \cdot r_1} \begin{pmatrix} I_m & A \\ O & I_n - A^T A \end{pmatrix} \xrightarrow{c_2 - c_1 \cdot A} \begin{pmatrix} I_m & O \\ O & I_n - A^T A \end{pmatrix}$$

另一方面：

$$\begin{pmatrix} I_m & A \\ A^T & I_n \end{pmatrix} \xrightarrow{c_1 - c_2 \cdot A^T} \begin{pmatrix} I_m - AA^T & A \\ O & I_n \end{pmatrix} \xrightarrow{r_1 + A \cdot r_2} \begin{pmatrix} I_m - AA^T & O \\ O & I_n \end{pmatrix}$$

可见：

$$\text{rank} \begin{pmatrix} I_m & O \\ O & I_n - A^T A \end{pmatrix} = \text{rank} \begin{pmatrix} I_m & A \\ A^T & I_n \end{pmatrix} = \text{rank} \begin{pmatrix} I_m - AA^T & O \\ O & I_n \end{pmatrix}$$

即 $\text{rank}(I_m - AA^T) + n = \text{rank}(I_n - A^T A) + m$ 。□

例 5.6. 设 A, B 是 n 阶方阵, $AB = BA$, 证明: $\text{rank}(A+B) \leq \text{rank}(A) + \text{rank}(B) - \text{rank}(AB)$.

分析. 本题分块矩阵的构造较为特殊, 将在后面的例题中解释这种构造背后的原理.

证明.

$$\begin{aligned} \begin{pmatrix} A & O & O \\ O & B & O \end{pmatrix} &\xrightarrow{c_3+c_1 \cdot B, c_3+c_2 \cdot A} \begin{pmatrix} A & O & AB \\ O & B & BA \end{pmatrix} \xrightarrow{r_2-r_1} \begin{pmatrix} A & O & AB \\ -A & B & BA-AB \end{pmatrix} \\ &\xrightarrow{c_1-c_2} \begin{pmatrix} A & O & AB \\ -A-B & B & O \end{pmatrix} \xrightarrow{(-I) \cdot r_2} \begin{pmatrix} A & O & \boxed{AB} \\ \boxed{A+B} & -B & O \end{pmatrix} \end{aligned}$$

因此有:

$$\begin{aligned} \text{rank}(A) + \text{rank}(B) &= \text{rank} \begin{pmatrix} A & O & O \\ O & B & O \end{pmatrix} = \text{rank} \begin{pmatrix} A & O & AB \\ A+B & -B & O \end{pmatrix} \\ &\geq \text{rank}(A+B) + \text{rank}(AB) \end{aligned}$$

□

5.4.2 秩相关的证明 II——线性映射法

本小节中, 我们将用线性映射的角度重新做上一小节的所有题目. 跟上一小节类似的, 我们通过一组练习题建立这套方法的基础.

例 5.7. 记矩阵 A, B 表示的线性映射为 $\mathcal{A}, \mathcal{B}$. 将以下矩阵表达式用线性映射的语言进行“翻译”

. (可用的概念: 像空间 Im 、核空间 Ker 、线性子空间的维数、子空间的运算)

$$(1) \text{rank} A. \quad (2) \text{rank} A + \text{rank} B. \quad (3) \text{rank}(A|B).$$

$$(4) \text{rank}(AB). \quad (5) AB = O.$$

解答. (1) $\dim \text{Im } \mathcal{A}$. (2) $\dim(\text{Im } \mathcal{A} \oplus \text{Im } \mathcal{B})$.

(3) $\dim(\text{Im } \mathcal{A} + \text{Im } \mathcal{B})$. 理由: 分块矩阵 $(A|B)$ 的列向量组即 A 与 B 的列向量组的并集. 两个向量组生成的子空间的和即是两个向量组之并生成的子空间.

$$(4) \dim \text{Im}(\mathcal{A} \circ \mathcal{B}) \text{ 或 } \dim \text{Im}(\mathcal{A}|_{\text{Im } \mathcal{B}})$$

$$(5) \mathcal{A} \circ \mathcal{B} \text{ 是零映射, 或 } \text{Im } \mathcal{B} \subset \text{Ker } \mathcal{A}. \text{ 理由: } \mathcal{B} \text{ 输出的任何向量再输入进 } \mathcal{A}, \text{ 都输出 } \mathbf{0}.$$

如果对于上一题中的“翻译”方式熟练, 就已经拥有了运用线性映射语言解决矩阵问题的基础. 拿到一道关于矩阵秩的题目, 可以先尝试用上述方法进行“翻译”. 关于秩的不等式中, 通常蕴含着空间的包含关系; 关于秩的等式中, 通常蕴含着线性映射的维数公式. 运用好上述的工具, 所需的结论会自然地“流出来”. 这种方法的优势是比较自然和深刻, 不需要构造技巧; 代价是需要对线性映射的相关概念比较熟悉.

例 5.8. (例 5.2) 设 A 是 $m \times n$ 矩阵, B 是 $n \times s$ 矩阵, $AB = O$. 证明: $\text{rank}(A) + \text{rank}(B) \leq n$.

分析. 画图可以帮助理清线性映射的关系.

证明. 设矩阵 A 表示线性映射 $\mathcal{A}: \mathbb{K}^n \rightarrow \mathbb{K}^m$, 矩阵 B 表示线性映射 $\mathcal{B}: \mathbb{K}^s \rightarrow \mathbb{K}^n$. $AB = O$ 的“翻译”为 $\text{Im } \mathcal{B} \subset \text{Ker } \mathcal{A}$ (图5.1). 由此可知 $\dim \text{Im } \mathcal{B} \leq \dim \text{Ker } \mathcal{A}$. 对 $\mathcal{A}$ 用维数公式: $\dim \text{Im } \mathcal{A} + \dim \text{Ker } \mathcal{A} = n$. 代入上述不等式有: $\dim \text{Im } \mathcal{B} \leq n - \dim \text{Im } \mathcal{A}$. $\square$




图 5.1: 例 5.8 图

例 5.9. (例 5.3) 设 A 是 $m \times n$ 矩阵, B 是 $n \times r$ 矩阵, C 是 $r \times s$ 矩阵.

(1) 证明 *Sylvester* 秩不等式:

$$\text{rank}(A) + \text{rank}(B) - n \leq \text{rank}(AB)$$

(2) 证明 *Frobenius* 秩不等式:

$$\text{rank}(AB) + \text{rank}(BC) - \text{rank}(B) \leq \text{rank}(ABC)$$

证明.

(1) 设矩阵 A 表示线性映射 $\mathcal{A}: \mathbb{K}^n \rightarrow \mathbb{K}^m$, 矩阵 B 表示线性映射 $\mathcal{B}: \mathbb{K}^s \rightarrow \mathbb{K}^n$. 考察复合映射 $\mathcal{A} \circ \mathcal{B}$ 的结构. 设 $\mathcal{A}$ 在 $\text{Im } \mathcal{B}$ 上的限制为 $\mathcal{A}|_{\text{Im } \mathcal{B}}$. 则 $\mathcal{A} \circ \mathcal{B}$ 与 $\mathcal{A}|_{\text{Im } \mathcal{B}} \circ \mathcal{B}$ 是等同的 (图5.2).

列出映射 $\mathcal{A}|_{\text{Im } \mathcal{B}}$ 的维数公式:

$$\dim \text{Im } \mathcal{B} = \dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B}}) + \dim \text{Im}(\mathcal{A}|_{\text{Im } \mathcal{B}})$$

即:

$$\text{rank}(B) = \dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B}}) + \text{rank}(AB) \quad (*)$$

将该式对照待证的不等式, 发现我们只需要搞清楚 $\dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B}})$ 与 $n - \text{rank}(A)$ 的关系. 再对 $\mathcal{A}$ 列维数公式可知, $n - \text{rank}(A) = n - \dim \text{Im } \mathcal{A} = \dim \text{Ker } \mathcal{A}$. 因此我们只要比较 $\dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B}})$ 与 $\dim \text{Ker } \mathcal{A}$ 的大小.

注意 $\mathcal{A}|_{\text{Im } \mathcal{B}}$ 相比于 $\mathcal{A}$ 缩小了定义域, 因此 $\text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B}}) \subset \text{Ker } \mathcal{A}$. 从而 $\dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B}}) \leq \dim \text{Ker } \mathcal{A} = n - \text{rank}(\mathcal{A})$. 代入 (*) 式, 就得到了待证的不等式.




图 5.2: 例 5.9(1) 图

(2) 与 (1) 没有实质的不同, 只是映射变了, 映射之间的关系没变, 参考图5.3. 这里设矩阵 C 表示线性映射 $\mathcal{C}: \mathbb{K}^r \rightarrow \mathbb{K}^s$.

列出映射 $\mathcal{A}|_{\text{Im } \mathcal{B} \circ \mathcal{C}}$ 的维数公式:

$$\dim \text{Im}(\mathcal{B} \circ \mathcal{C}) = \dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B} \circ \mathcal{C}}) + \dim \text{Im}(\mathcal{A}|_{\text{Im } \mathcal{B} \circ \mathcal{C}})$$

即:

$$\text{rank}(BC) = \dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B} \circ \mathcal{C}}) + \text{rank}(ABC) \quad (*)$$

将该式对照待证的不等式, 发现我们只需要搞清楚 $\dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B} \circ \mathcal{C}})$ 与 $\text{rank}(B) - \text{rank}(AB)$ 的关系. 再对 $\mathcal{A}|_{\text{Im } \mathcal{B}}$ 列维数公式可知, $\text{rank}(B) - \text{rank}(AB) = \dim \text{Im } \mathcal{B} - \dim \text{Im } \mathcal{A}|_{\text{Im } \mathcal{B}} = \dim \text{Ker } \mathcal{A}|_{\text{Im } \mathcal{B}}$. 因此我们只要比较 $\dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B} \circ \mathcal{C}})$ 与 $\dim \text{Ker } \mathcal{A}|_{\text{Im } \mathcal{B}}$ 的大小.

注意 $\text{Im } \mathcal{B} \circ \mathcal{C} \subset \text{Im } \mathcal{B}$, 因此 $\text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B} \circ \mathcal{C}}) \subset \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B}})$. 从而 $\dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B} \circ \mathcal{C}}) \leq \dim \text{Ker}(\mathcal{A}|_{\text{Im } \mathcal{B}}) = \text{rank}(B) - \text{rank}(AB)$. 代入 (*) 式, 就得到了待证的不等式.




图 5.3: 例 5.9(2) 图

□

例 5.10. (例 5.4)

- (1) 求证: n 阶方阵 A 是幂等矩阵 ($A^2 = A$) 的充要条件是 $\text{rank}(A) + \text{rank}(I_n - A) = n$.
 (2) 求证: n 阶方阵 A 是对合矩阵 ($A^2 = I_n$) 的充要条件是 $\text{rank}(I_n + A) + \text{rank}(I_n - A) = n$.

证明.

(1) “ $\implies$ ”: 若 $A^2 = A$, 则 $A(I_n - A) = O$. 根据例 5.8 的结论, $\text{rank}(A) + \text{rank}(I_n - A) \leq n$. 再根据讲义前文提及的秩不等式, $\text{rank}(A) + \text{rank}(I_n - A) \geq \text{rank}(A + I_n - A) = n$. 二者结合得到 $\text{rank}(A) + \text{rank}(I_n - A) = n$.

“ $\impliedby$ ”: 若 $\text{rank}(A) + \text{rank}(I_n - A) = n$. 记矩阵 A 表示线性变换 $\mathcal{A}: \mathbb{K}^n \rightarrow \mathbb{K}^n$, 恒等映射记为 $\mathcal{I}$. 则 $\dim \text{Im } \mathcal{A} + \dim \text{Im } (\mathcal{I} - \mathcal{A}) = n$. 根据维数公式, 这等价于 $\dim \text{Ker } \mathcal{A} + \dim \text{Ker } (\mathcal{I} - \mathcal{A}) = n$.

之所以这样考虑, 是想要借助线性子空间求和的维数公式. 注意到若非零向量 $\mathbf{x} \in \text{Ker } \mathcal{A}$, 则它必然不属于 $\text{Ker } (\mathcal{I} - \mathcal{A})$. 这是因为当 $\mathcal{A}\mathbf{x} = \mathbf{0}$ 时, $(\mathcal{I} - \mathcal{A})\mathbf{x} = \mathbf{x}$. 同理, 非零向量 $\mathbf{x} \in \text{Ker } (\mathcal{I} - \mathcal{A})$, 则 $\mathbf{x} \notin \text{Ker } \mathcal{A}$. 因此 $\text{Ker } \mathcal{A} \cap \text{Ker } (\mathcal{I} - \mathcal{A}) = \{\mathbf{0}\}$. 此时 $\text{Ker } \mathcal{A} + \text{Ker } (\mathcal{I} - \mathcal{A})$ 是直和, 且 $\dim(\text{Ker } \mathcal{A} \oplus \text{Ker } (\mathcal{I} - \mathcal{A})) = \dim \text{Ker } \mathcal{A} + \dim \text{Ker } (\mathcal{I} - \mathcal{A}) = n$ 表明 $\text{Ker } \mathcal{A} \oplus \text{Ker } (\mathcal{I} - \mathcal{A})$ 是 $\mathbb{K}^n$ 的直和分解. 因此, 任取列向量 $\mathbf{x} \in \mathbb{K}^n$, 存在唯一分解 $\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_2$, 使得 $\mathcal{A}\mathbf{x}_1 = \mathbf{0}$, $(I_n - A)\mathbf{x}_2 = \mathbf{0}$. 则 $A(I_n - A)\mathbf{x} = (I_n - A)\mathcal{A}\mathbf{x}_1 + A(I_n - A)\mathbf{x}_2 = \mathbf{0}$. 由 $\mathbf{x}$ 的任意性可知 $A(I_n - A) = O$.

- (2) 模仿 (1) 的证明. 证明 “ $\impliedby$ ” 时, 去证 $\mathbb{K}^n = \text{Ker } (\mathcal{I} + \mathcal{A}) \oplus \text{Ker } (\mathcal{I} - \mathcal{A})$. □

例 5.11. (例 5.5) 设 A 为 $m \times n$ 矩阵. 证明:

$$\text{rank}(I_m - AA^T) - \text{rank}(I_n - A^T A) = m - n$$

证明. 方便起见, 记 $I_m - AA^T = M$, $I_n - A^T A = N$, 不区分矩阵与线性映射的记号. A 和 A^T 分别是 $\mathbb{K}^n \rightarrow \mathbb{K}^m$ 和 $\mathbb{K}^m \rightarrow \mathbb{K}^n$ 的线性映射. 分析待证的式子, 可用维数公式简化为 $\dim \text{Ker } M = \dim \text{Ker } N$. 为此我们来分析 $\text{Ker } M$ 与 $\text{Ker } N$ 的关系.

所谓 $\text{Ker } M$, 是指所有满足 $(I_m - AA^T)\mathbf{x} = \mathbf{0}$ 的向量 $\mathbf{x} \in \mathbb{K}^m$ 组成的集合. 该式等同于 $AA^T\mathbf{x} = \mathbf{x}$. 考虑到题中 AA^T 与 $A^T A$ 的对称性, 将该式两侧左乘 A^T , 得到 $(A^T A)(A^T \mathbf{x}) = A^T \mathbf{x}$, 即 $(I_n - A^T A)(A^T \mathbf{x}) = N(A^T \mathbf{x}) = \mathbf{0}$. 可见, 若 $\mathbf{x} \in \text{Ker } M$, 则 $A^T \mathbf{x} \in \text{Ker } N$. 换句话说, 线性映射 A^T 在 $\text{Ker } M$ 上的限制 $A^T|_{\text{Ker } M}$ 是 $\text{Ker } M \rightarrow \text{Ker } N$ 的映射.

类似地, 可以证明 A 在 $\text{Ker } N$ 上的限制 $A|_{\text{Ker } N}$ 是 $\text{Ker } N \rightarrow \text{Ker } M$ 的映射.

这里再次强调, 上述结论意味着, 任取 $\mathbf{x} \in \text{Ker } M$, 有 $(AA^T)\mathbf{x} = \mathbf{x}$; 而任取 $\mathbf{y} \in \text{Ker } N$, 有 $(A^T A)\mathbf{y} = \mathbf{y}$. 这说明 $A^T|_{\text{Ker } M}$ 与 $A|_{\text{Ker } N}$ 互为逆映射. 因此它们都是 $\text{Ker } M$ 与 $\text{Ker } N$ 之间的同构映射. 而 $\text{Ker } M$ 与 $\text{Ker } N$ 同构就说明 $\dim \text{Ker } M = \dim \text{Ker } N$. □

在上一题中, 需要通过巧妙地利用 AA^T 和 $A^T A$ 的对称关系来研究 $\text{Ker } M$ 和 $\text{Ker } N$ 的关系, 并不容易想到. 相比之下, 例 5.11 所讲的分块矩阵法, 在此题中构造目标是很明确的, 相对比较容易想到. 接下来给出一个分块矩阵构造不容易想到, 而用线性映射很方便的例子.

例 5.12. (例 5.6) 设 A, B 是 n 阶方阵, $AB = BA$, 证明: $\text{rank}(A+B) \leq \text{rank}(A) + \text{rank}(B) - \text{rank}(AB)$.

分析. 本题的关键在于正确翻译 $AB = BA$ 这个条件.

证明. 设矩阵 A, B 分别表示 $\mathbb{K}^n$ 上的线性变换 $\mathcal{A}, \mathcal{B}$. 我们知道 $\text{Im}(\mathcal{A} \circ \mathcal{B}) = \text{Im}(\mathcal{A}|_{\text{Im } \mathcal{B}}) \subset \text{Im } \mathcal{A}$. 同理, $\text{Im}(\mathcal{B} \circ \mathcal{A}) \subset \text{Im } \mathcal{B}$. 现在 $\mathcal{A} \circ \mathcal{B} = \mathcal{B} \circ \mathcal{A}$, 于是 $\text{Im}(\mathcal{A} \circ \mathcal{B}) \subset \text{Im } \mathcal{A} \cap \text{Im } \mathcal{B}$, 因此:

$$\dim \text{Im}(\mathcal{A} \circ \mathcal{B}) \leq \dim \text{Im } \mathcal{A} \cap \text{Im } \mathcal{B}$$

现在涉及两个子空间的交集, 待证的不等式中又有两个子空间的维数之和, 想到用维数公式:

$$\dim(\text{Im } \mathcal{A} + \text{Im } \mathcal{B}) = \dim \text{Im } \mathcal{A} + \dim \text{Im } \mathcal{B} - \dim(\text{Im } \mathcal{A} \cap \text{Im } \mathcal{B})$$

代入上面的不等式, 并代入“秩即像空间维数”的关系, 得到:

$$\dim(\text{Im } \mathcal{A} + \text{Im } \mathcal{B}) \leq \text{rank}(A) + \text{rank}(B) - \text{rank}(AB)$$

对照待证的不等式, 我们只需要证明 $\text{rank}(A+B) = \dim \text{Im}(\mathcal{A} + \mathcal{B}) \leq \dim(\text{Im } \mathcal{A} + \text{Im } \mathcal{B})$ 即可. 任取 $\mathbf{x} \in \mathbb{K}^n$, $(\mathcal{A} + \mathcal{B})\mathbf{x} = \mathcal{A}\mathbf{x} + \mathcal{B}\mathbf{x} \in \text{Im } \mathcal{A} + \text{Im } \mathcal{B}$, 因此 $\text{Im}(\mathcal{A} + \mathcal{B}) \subset \text{Im } \mathcal{A} + \text{Im } \mathcal{B}$, 从而 $\dim \text{Im}(\mathcal{A} + \mathcal{B}) \leq \dim(\text{Im } \mathcal{A} + \text{Im } \mathcal{B})$ 成立. $\square$

本题最后证明了不等式 $\dim \text{Im}(\mathcal{A} + \mathcal{B}) \leq \dim(\text{Im } \mathcal{A} + \text{Im } \mathcal{B})$. 而 $\dim(\text{Im } \mathcal{A} + \text{Im } \mathcal{B})$ 正是分块矩阵 $(A \mid B)$ 的秩. 用该式替换掉待证的不等式之后, 如果再考虑使用分块矩阵法, 则能想到如下的构造思路:

$$\begin{pmatrix} * & * & AB \\ A & B & O \end{pmatrix} \xleftarrow{\text{初等变换}} \begin{pmatrix} A & O & O \\ O & B & O \end{pmatrix}$$

直接凭空想到这个构造是比较困难的. 而从 $AB = BA$ 的条件入手, 联系到像空间交集和维数公式的运用, 这个思路则比较自然.

5.4.3 特殊矩阵的性质分析

本小节的题目涉及一些形式比较特殊的矩阵. 我们先通过下面这道题目摸一摸门道.

例 5.13. 设 $A_{n \times n}$ 是对角线全为 0 的上三角矩阵. 证明: $A^n = O$.

分析. 一个比较寻常的思路是尝试去计算 $A^2, A^3, \dots$, 发现随着幂次的升高, 矩阵 0 元素与非零元素的“界限”不断抬高. 只需要通过直接计算描述出这个规律.

如果把矩阵当作线性映射看待, 能提供一个不同的思路. 我们要计算 A^n , 也就是要考察线性变换 A 对任意向量 $\mathbf{x}$ 连续作用 n 次结果将会如何. 为此, 只需要考察 A 对标准正交基的作用.

证明. (方法 1: 直接计算)

设 $M_{n \times n}$ 的 (i, j) 元是 m_{ij} . 我们证明一个结论: 如果矩阵 M 的一条反斜线 $j - i = k$ ($0 \leq k \leq n - 1$) 及其下方部分的元素全为 0, 则 AM 的反斜线 $j - i = k + 1$ 及其下方部分的元素全为 0. 即: M 乘 A 之后, 分割零元素与非零元素的反斜线会“升高一格”.

设矩阵 AM 的 (i, j) 元为 b_{ij} , 按照矩阵乘法的规则有:

$$b_{ij} = \sum_{p=1}^n a_{ip} m_{pj}$$

考察求和式中的各项何时非零. 由 A 的定义, 当 $p - i \leq 0$ 时, $a_{ip} = 0$. 由 M 的定义, 当 $j - p \leq k$ 时, $m_{pj} = 0$. 因此, 如果 $a_{ip} m_{pj} \neq 0$, 只可能是 $p - i > 0$ 和 $j - p > k$ 同时满足. 两式相加, 可知必须要 $j - i > k$. 因此, 当 $j - i \leq k + 1$ 时, 无论 p 取 1 到 n 的何值, 都有 $a_{ip} m_{pj} = 0$. 此时 $b_{ij} = 0$. 根据此结论, A^k 中满足 $j - i \leq k - 1$ 的元素皆为 0. 对于 $k = n$, 即是说 A^n 满足 $j - i \leq n - 1$ 的元素皆为 0, 但这是任何指标 (i, j) 都满足的. 因此 A^n 是零矩阵. $\square$

证明. (方法 2: 线性变换)

设 $\mathbf{e}_j$ 是 $\mathbb{K}^n$ 的第 j 个标准正交基, 即第 j 分量是 1, 其余分量为 0 的向量. A 在 $\mathbf{e}_j$ 上作用的结果 $A\mathbf{e}_j$ 正是 A 的第 j 个列向量 α_j . 根据 A 的定义, α_j 的第 j 个分量及之后的分量全为 0. 换句话说, $A\mathbf{e}_j = \alpha_j \in \langle \mathbf{e}_1, \dots, \mathbf{e}_{j-1} \rangle$. 对任意的 $\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + \dots + x_r \mathbf{e}_r \in \langle \mathbf{e}_1, \dots, \mathbf{e}_r \rangle$, 有:

$$A\mathbf{x} = A(x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + \dots + x_r \mathbf{e}_r) \in \langle \mathbf{e}_1, \dots, \mathbf{e}_{r-1} \rangle$$

可见将 A 限制在定义域 $\langle \mathbf{e}_1, \dots, \mathbf{e}_r \rangle$ 上时, 像空间是 $\langle \mathbf{e}_1, \dots, \mathbf{e}_{r-1} \rangle$ (直观地说, A 的作用是从定义域中丢掉角标最大的基向量, 从而把空间压缩一个维度). 因此, A 对整个 $\mathbb{K}^n = \langle \mathbf{e}_1, \dots, \mathbf{e}_n \rangle$ 作用 n 次之后 (即压缩 n 个维度之后), 得到平凡子空间 $\{0\}$. 即对任意的 $\mathbf{x} \in \mathbb{K}^n$, 有 $A^n \mathbf{x} = \mathbf{0}$. 这样的 A^n 只能是零矩阵. $\square$

在本题中, A 是个很有特点的矩阵, 我们要利用它的特点去解决问题. 第一种方法的思路是直接计算矩阵乘法, 将 A 的特点转化为代数运算中的规律性. 而第二种方法则是先追问“ A 的这种特殊性意味着什么”. 求助于矩阵的本质 (即线性变换) 进行探索, 发现所谓“对角线全为 0 的上三角矩阵”表示的是一种可以不断压缩空间维数的线性变换. 发现这一点之后, 要证的结论就很显然了.

例 5.14. 设 n 阶方阵 A 的每一行和每一列都只有一个元素是 1, 其余元素都是 0 (这种矩阵称为置换矩阵). 证明: 存在正整数 m , 使得 $A^m = I$.

证明. 设 e_j 是 $\mathbb{K}^n$ 的第 j 个标准正交基, 即第 j 分量是 1, 其余分量为 0 的向量. 按照置换矩阵的定义, A 的列向量组 $\alpha_1, \dots, \alpha_n$ 其实就是一组标准正交基, 只不过重排了顺序. 依次记 $\alpha_1, \dots, \alpha_n$ 为 $e_{i_1}, e_{i_2}, \dots, e_{i_n}$, 其中 $i_1 i_2 \dots i_n$ 是 1 到 n 某一个排列. $Ae_j = e_{i_j}$ 这一事实意味着 A 在一组标准正交基上的作用仅仅是重排了它们的顺序. A^m 在一组标准正交基上的作用就是重排了 n 次, 则 A^m 必定也是置换矩阵. 但是 1 到 n 的排列方式是有限的 (共 $n!$ 种), 根据抽屉原理, 如果对标准正交基进行 $n! + 1$ 次重排, 在 $n! + 1$ 种排列中必定存在两个相同的排列, 即 $A^1, A^2, \dots, A^{n!}, A^{n!+1}$ 中必有两个相同的. 不妨设 $A^r = A^{r+m}$, 则 A^m 就是单位矩阵. $\square$

例 5.15. 设 a, b, c, d 是非零实数, 求下列矩阵的逆:

$$A = \begin{pmatrix} a & b & c & d \\ -b & a & -d & c \\ -c & d & a & -b \\ -d & -c & b & a \end{pmatrix}$$

分析. 本题的矩阵有一定对称性, “看法”是不唯一的. 方法 1 的“看法”是注意到 A 是正交矩阵. 方法 2 的“看法”是利用上一题中的置换矩阵.

证明. (方法 1)

观察矩阵的列向量组 $\alpha_1, \dots, \alpha_4$, 发现它们两两正交, 即满足 $\alpha_i^T \alpha_j = 0$. 从这个表达式就可以看出 $A^T A$ 是对角矩阵. 通过计算发现 $A^T A = (a^2 + b^2 + c^2 + d^2)I$. 则 $A^{-1} = \frac{1}{a^2 + b^2 + c^2 + d^2} A^T$. $\square$

证明. (方法 2)

将矩阵元素排列的规律用置换矩阵来描述. 分别按照 a, b, c, d 去定义以下 4 个置换矩阵:

$$E_1 = I, E_2 = \begin{pmatrix} 0 & 1 & 0 & 0 \\ -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & -1 \\ 0 & 0 & 1 & 0 \end{pmatrix}, E_3 = \begin{pmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ -1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \end{pmatrix}, E_4 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0 \\ -1 & 0 & 0 & 0 \end{pmatrix}$$

置换矩阵的乘积依然是置换矩阵,我们考察这些置换矩阵之间的代数关系. 重点关注 E_2, E_3, E_4 . 通过计算得到以下的乘法表【矩阵 A 与四元数 $a + bi + cj + dk$ 有何联系?】:

$$E_2 \cdot E_2 = E_3 \cdot E_3 = E_4 \cdot E_4 = -E_1$$

$$E_2 \cdot E_3 = -E_3 \cdot E_2 = E_4$$

$$E_3 \cdot E_4 = -E_4 \cdot E_3 = E_2$$

$$E_4 \cdot E_2 = -E_2 \cdot E_4 = E_3$$

可见 E_1, E_2, E_3, E_4 构成了一个封闭的代数体系. $A = aE_1 + bE_2 + cE_3 + dE_4$. 我们寻找一个同样具有形式 $pE_1 + qE_2 + rE_3 + sE_4$ 的矩阵 B , 使得 AB 是数量矩阵 $= \lambda E_1$. 考察矩阵乘法:

$$(aE_1 + bE_2 + cE_3 + dE_4)(pE_1 + qE_2 + rE_3 + sE_4)$$

在乘法代数展开式中, 所有的平方项实质都是 E_1 的倍数, 而所有的交叉项实质都是 E_2, E_3 或 E_4 , 是我们所不要的. 因此一个简单的想法是取 p, q, r, s 让所有的交叉项抵消. 最方便的是让 $(p, q, r, s) = (a, -b, -c, -d)$. 此时有:

$$(aE_1 + bE_2 + cE_3 + dE_4)(aE_1 - bE_2 - cE_3 - dE_4) = (a^2 + b^2 + c^2 + d^2)E_1$$

$$\text{所以 } A^{-1} = \frac{1}{a^2 + b^2 + c^2 + d^2}(aE_1 - bE_2 - cE_3 - dE_4).$$

□

例 5.16.

(1) 设 A 是 n 阶方阵, 满足 $A^k = O$, k 是正整数. 证明: $I - A$ 可逆.

(2) 设 A 是 n 阶方阵, 满足 $A^2 = A$, 证明: $A - 2I$ 可逆.

(3) 设矩阵:

$$A = \begin{pmatrix} -1 & 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & 1 & 1 \\ 1 & 1 & -1 & 1 & 1 \\ 1 & 1 & 1 & -1 & 1 \\ 1 & 1 & 1 & 1 & -1 \end{pmatrix}$$

求 A 的逆.

分析. 证明矩阵可逆的一种特殊的方法是, 通过矩阵的代数计算直接找到逆矩阵. 第 (3) 问直接用初等变换法求逆当然是可以的, 不过参考第 (2) 问, 可以开发出一种巧妙的新思路.

解答.

(1) $I = I - A^k = (I - A)(I + A + A^2 + \cdots + A^{k-1})$, 因此 $I + A + A^2 + \cdots + A^{k-1}$ 就是 $I - A$ 的逆矩阵.

(2) 用待定系数法, 设 $A - 2I$ 的逆矩阵形如 $pA + qI$, 即 $(A - 2I)(pA + qI) = I$. 计算左侧得到:

$$(A - 2I)(pA + qI) = pA^2 + (q - 2p)A - 2qI = (q - p)A - 2qI$$

解得 $p = -\frac{1}{2}$, $q = -\frac{1}{2}$. 因此 $A - 2I$ 的逆矩阵是 $-\frac{1}{2}A - \frac{1}{2}I$.

(3) 记 5 阶单位矩阵为 I , 元素全为 1 的 5 阶方阵为 J , 则 $A = J - 2I$. 通过直接计算可知 J 具有性质 $J^2 = 5J$. 猜测 $A = J - 2I$ 的逆矩阵形如 $pJ + qI$. 即 $(J - 2I)(pJ + qI) = I$. 计算左侧得到:

$$(J - 2I)(pJ + qI) = pJ^2 + (q - 2p)J - 2qI = (q + 3p)J - 2qI$$

解得 $p = \frac{1}{6}$, $q = -\frac{1}{2}$, 因此 $J - 2I$ 的逆矩阵是 $\frac{1}{6}J - \frac{1}{2}I$, 即:

$$A^{-1} = \frac{1}{6} \begin{pmatrix} -2 & 1 & 1 & 1 & 1 \\ 1 & -2 & 1 & 1 & 1 \\ 1 & 1 & -2 & 1 & 1 \\ 1 & 1 & 1 & -2 & 1 \\ 1 & 1 & 1 & 1 & -2 \end{pmatrix}$$

5.4.4 伴随矩阵

例 5.17. 设 A 是 n 阶方阵. A^* 是 A 的伴随矩阵.

(1) 证明:

$$\text{rank}(A^*) = \begin{cases} n, & \text{rank}(A) = n \\ 1, & \text{rank}(A) = n - 1 \\ 0, & \text{rank}(A) \leq n - 2 \end{cases}$$

(2) 若已知 $|A|$, 如何计算 $|A^*|$?

分析. 虽然伴随矩阵的一个重要功能是求逆, 但是讨论伴随矩阵时并不总是默认 A 是可逆的, 此时求逆公式就用不上了. 需要知道伴随矩阵的重要性质 $AA^* = |A|I_n$. 这条公式在 A 不可逆时也适用, 此时 $AA^* = O$.

第 (2) 问的易错点在于 $|kA| = k^n|A|$, 注意不要以为 $|kA| = k|A|$.

解答. (1) 分三种情况讨论.

(i) 当 $\text{rank}(A) = n$ 时, 因此 A 可逆, 此时有 $A^* = |A|A^{-1}$, 且 $|A| \neq 0$. 所以 $\text{rank}(A^*) = \text{rank}(A^{-1}) = n$

(ii) 当 $\text{rank}(A) = n - 1$ 时, $|A| = 0$, 但存在至少一个 A 的 $(n - 1)$ 阶子式不为零, 即 A^* 不是零矩阵. 但由伴随矩阵性质, $AA^* = O$, 于是 A^* 的每一列都属于齐次方程组 $A\mathbf{x} = \mathbf{0}$ 的解空间. 根据维数公式, 解空间的维数为 $n - \text{rank}(A) = 1$. 因此 A^* 的所有列向量都属于同一个一维空间, 故所有列向量线性相关, 并且至少有一列非零. 因此 $\text{rank}(A^*) = 1$.

(iii) 当 $\text{rank}(A) \leq n - 2$ 时, A 的所有 $(n - 1)$ 阶子式全部为零, 根据伴随矩阵的定义, A^* 是零矩阵, 故 $\text{rank}(A^*) = 0$.

综上:

$$\text{rank}(A^*) = \begin{cases} n, & \text{rank}(A) = n, \\ 1, & \text{rank}(A) = n - 1, \\ 0, & \text{rank}(A) \leq n - 2. \end{cases}$$

(2) 由伴随矩阵性质 $AA^* = |A|I_n$, 两边取行列式: $\det(AA^*) = \det(\det(A)I_n)$. 等号左侧为 $|A| \cdot |A^*|$, 等号右侧为 $|A|^n$.

若 $|A| \neq 0$, 则两边除以 $|A|$, 得到 $|A^*| = (|A|)^{n-1}$.

当 $|A| = 0$, 由 (1) 的结论知 $|A^*| = 0$.

上面两种情形下的公式可以统一写成: $|A^*| = (|A|)^{n-1}$.

在有关伴随矩阵的问题中, 例 5.18 的结论是基础性的. 到目前为止, 矩阵的证明题无非是围绕秩和行列式这些基础概念展开的. 而例 5.18 就搞清楚了伴随矩阵的秩和行列式. 下面给出两个简单的应用作为示范.

例 5.18. 设 $n(n \geq 2)$ 阶方阵 A 恰有 k 个 $n - 1$ 阶子式等于 0, 其中 $1 \leq k \leq n - 1$. 证明: $|A| \neq 0$.

证明. 反证法. 假设 $|A| = 0$. 则 $\text{rank}(A) \leq n - 1$. 由于 $k \leq n - 1$, 所以 $A^* \neq O$. 根据例 5.18 的结论, 可知 $\text{rank}(A^*) = 1$.

A 有 k 个 $n - 1$ 阶子式, 即 A^* 中有 k 个元素为 0. $k \leq n - 1$ 表明 A^* 的每一行和每一列都不是零向量. 但是, 若选取 A^* 的一个含有 0 的列向量, 设其第 i 分量为 0. 由于 $\text{rank}(A^*) = 1$, 可知 A^* 的所有列向量都是它的倍数, 因此每个列向量第 i 分量都是 0, 从而 A^* 的第 i 行是零向量, 矛盾. □

例 5.19. 设 A 是 $n(n > 2)$ 阶方阵. 求 $(A^*)^*$.

解答. 如果 A 可逆, 则 A^* 也可逆. 利用公式 $A^* = |A|A^{-1}$, 有:

$$(A^*)^* = |A^*|(A^*)^{-1} = |A|^{n-1}|A|^{-1}A = |A|^{n-2}A$$

如果 A 不可逆, 即 $\text{rank}(A) \leq n-1$, 则 $\text{rank}(A^*) \leq 1$, 而 $\text{rank}(A^*)^* = 0$, 即 $A^* = O$.

5.4.5 降阶公式

例 5.20. 设 A 是 m 阶方阵, D 是 n 阶方阵, B 是 $m \times n$ 矩阵, C 是 $n \times m$ 矩阵.

(1) 如果 A 可逆, 证明:

$$\begin{vmatrix} A & B \\ C & D \end{vmatrix} = |A||D - CA^{-1}B|$$

(2) 如果 D 可逆, 是否能得到类似的结论?

分析. 求分块矩阵的行列式, 根据 Laplace 展开公式, 只需要化成分块上三角或者分块下三角.

证明. (1)

$$\det \begin{pmatrix} A & B \\ C & D \end{pmatrix} \xrightarrow{r_2 + CA^{-1} \cdot r_1} \det \begin{pmatrix} A & B \\ O & D - CA^{-1}B \end{pmatrix} = \det(A) \cdot \det(D - CA^{-1}B)$$

(2)

$$\det \begin{pmatrix} A & B \\ C & D \end{pmatrix} \xrightarrow{r_1 + BD^{-1} \cdot r_2} \det \begin{pmatrix} A - BD^{-1}C & O \\ C & D \end{pmatrix} = \det(D) \cdot \det(A - BD^{-1}C)$$

□

在上一题的设定中, 如果 A, D 都可逆, 结合两个小问的结论, 我们得到一个公式:

$$|A||D - CA^{-1}B| = |D||A - BD^{-1}C|$$

这个公式称为 **降阶公式**. 之所以“降阶”, 是关注到 m 和 n 可能不同, 也就是等号两侧分别是一些 m 和 n 阶矩阵的行列式. 因此, 利用这个公式可以将高阶的行列式化成低阶的行列式. 接下来通过两个例子展示具体做法.

例 5.21. 计算下列矩阵行列式的值:

$$M = \begin{pmatrix} a_1^2 & a_1 a_2 + 1 & \cdots & a_1 a_n + 1 \\ a_2 a_1 + 1 & a_2^2 & \cdots & a_2 a_n + 1 \\ \vdots & \vdots & \ddots & \vdots \\ a_n a_1 + 1 & a_n a_2 + 1 & \cdots & a_n^2 \end{pmatrix}$$

分析. M 的特点是关于 $a_i a_j$ 的规律, 但是对角线的规律相对特殊, 缺少 “+1”. 这是可以用降阶公式的信号. 诀窍是尝试把 M 看成降阶公式中的 $A - BD^{-1}C$. 其中 D 取成单位矩阵, 而 A 是对角矩阵, 负责分离出对角线的特征. 最后按照矩阵整体的规律, 设法将其分解成 BC 即可.

解答. 将 M 化为:

$$M = -I_n + \begin{pmatrix} a_1 & 1 \\ a_2 & 1 \\ \vdots & \vdots \\ a_n & 1 \end{pmatrix} I_2^{-1} \begin{pmatrix} a_1 & a_2 & \cdots & a_n \\ 1 & 1 & \cdots & 1 \end{pmatrix}$$

由降阶公式得到:

$$\begin{aligned} |M| &= |I_2|^{-1} - I_n \left| I_2 + \begin{pmatrix} a_1 & a_2 & \cdots & a_n \\ 1 & 1 & \cdots & 1 \end{pmatrix} (-I_n)^{-1} \begin{pmatrix} a_1 & 1 \\ a_2 & 1 \\ \vdots & \vdots \\ a_n & 1 \end{pmatrix} \right| \\ &= (-1)^n \left| I_2 - \begin{pmatrix} \sum_{i=1}^n a_i^2 & \sum_{i=1}^n a_i \\ \sum_{i=1}^n a_i & n \end{pmatrix} \right| \\ &= (-1)^n \left((1-n) \left(1 - \sum_{i=1}^n a_i^2 \right) - \left(\sum_{i=1}^n a_i \right)^2 \right) \end{aligned}$$

例 5.22. 计算下列矩阵行列式的值:

$$M = \begin{pmatrix} 0 & 2 & 3 & \cdots & n \\ 1 & 0 & 3 & \cdots & n \\ 1 & 2 & 0 & \cdots & n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 2 & 3 & \cdots & 0 \end{pmatrix}$$

分析. 技巧同上.

解答. 将 M 化为:

$$M = \begin{pmatrix} -1 & 0 & \cdots & 0 \\ 0 & -2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & -n \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \end{pmatrix} I_2^{-1} \begin{pmatrix} 1 & 2 & \cdots & n \\ 0 & 0 & \cdots & 0 \end{pmatrix}$$

由降阶公式得到 $|M|$ 的值为:

$$\begin{aligned} & |I_2|^{-1} \cdot \det \begin{pmatrix} -1 & 0 & \cdots & 0 \\ 0 & -2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & -n \end{pmatrix} \cdot \det \left(I_2 + \begin{pmatrix} 1 & \cdots & n \\ 0 & \cdots & 0 \end{pmatrix} \begin{pmatrix} -1 & 0 & \cdots & 0 \\ 0 & -2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & -n \end{pmatrix}^{-1} \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \end{pmatrix} \right) \\ &= (-1)^n n! \cdot \det \left(I_2 + \begin{pmatrix} 1 & \cdots & n \\ 0 & \cdots & 0 \end{pmatrix} \begin{pmatrix} -1 & 0 & \cdots & 0 \\ 0 & -1/2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & -1/n \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \end{pmatrix} \right) \\ &= (-1)^n n! \cdot \det \left(I_2 + \begin{pmatrix} 1 & \cdots & n \\ 0 & \cdots & 0 \end{pmatrix} \begin{pmatrix} -1 & 0 & \cdots & 0 \\ 0 & -1/2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & -1/n \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \end{pmatrix} \right) \\ &= (-1)^n n! \cdot \det \left(\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} -n & 0 \\ 0 & 0 \end{pmatrix} \right) = (-1)^{n+1} n! (n-1) \end{aligned}$$

5.4.6 摄动法

例 5.23. 设 A 是不可逆的 n 阶方阵. 证明: 存在 $\lambda = 0$ 的去心邻域, 使得 $A + \lambda I_n$ 可逆.

证明. $|A + \lambda I_n|$ 是关于 λ 的 n 次多项式, 至多有 n 个零点, $\lambda = 0$ 是其中之一. 除了 $\lambda = 0$ 之外, 其余 $n-1$ 的零点的绝对值最小者记为 λ_0 . 则当 λ 属于半径为 $|\lambda_0|$ 的去心邻域 $U(0, |\lambda_0|)$ 时, $|A + \lambda I_n| \neq 0$, 即 $A + \lambda I_n$ 可逆. $\square$

这一题的结论给我们很大的启发: 对于不可逆矩阵 A , 对其施加一个很小的扰动 λI_n , 就能使其成为可逆矩阵. 通过这个手法, 我们就可以把不可逆的矩阵当作可逆矩阵来处理. 这种方法称为摄动法.

例 5.24. 设 A, B, C, D 都是 n 阶实方阵, 且满足 $AC = CA$. 证明:

$$\begin{vmatrix} A & B \\ C & D \end{vmatrix} = |AD - CB|$$

分析. 本题中没有说 A, B, C, D 可逆, 阻止了我们做初等行变换. 使用摄动法就可以绕过这个阻碍.

证明. 如果 A 可逆, 可以做分块初等变换, 推导出降阶公式:

$$\det \begin{pmatrix} A & B \\ C & D \end{pmatrix} = \det \begin{pmatrix} A & B \\ O & D - CA^{-1}B \end{pmatrix} = |A||D - CA^{-1}B|$$

利用 $AC = CA$, 可以进一步得到:

$$\det \begin{pmatrix} A & B \\ C & D \end{pmatrix} = |AD - ACA^{-1}B| = |AD - CAA^{-1}B| = |AD - CB|$$

若 A 不可逆, 使用摄动法. 存在 0 的一个小去心邻域 U , 使得 $\lambda \in U$ 时, 有 $A + \lambda I_n$ 可逆. 用 $A + \lambda I_n$ 代替 A , 有:

$$\det \begin{pmatrix} A + \lambda I_n & B \\ C & D \end{pmatrix} = |(A + \lambda I_n)D - CB|$$

注意等号两边都是关于 λ 的 n 次多项式. 现在这两个多项式在 $\lambda \in U$ 时处处成立, 即有无穷多个 λ 使得这两个多项式相等, 意味着它对于 $\lambda \in \mathbb{R}$ 是恒等式, 因此也对 $\lambda = 0$ 成立. $\square$

例 5.25. 设 A, B 是 n 阶矩阵, $n \geq 2$. 证明: $(AB)^* = B^*A^*$.

证明. 若 A, B 均可逆, 则利用公式 $A^* = |A|A^{-1}$, 可得:

$$(AB)^* = |AB|(AB)^{-1} = |B|B^{-1} \cdot |A|A^{-1} = B^*A^*$$

若 A, B 其中之一不可逆, 使用摄动法. 考虑矩阵 $A(\lambda) = A + \lambda I_n$, $B(\lambda) = B + \lambda I_n$. 则存在 0 的去心邻域 U , 使得 $\lambda \in U$ 时, $A(\lambda), B(\lambda)$ 均可逆. 则有:

$$(A(\lambda)B(\lambda))^* = B(\lambda)^*A(\lambda)^*$$

该等式左右两侧每个矩阵元都是关于 λ 的有限阶多项式. 但是等式对 $\lambda \in U$ 成立, 即有无穷多个 λ 使得等式成立. 因此该式是关于 λ 的恒等式, 对于 $\lambda = 0$ 也成立, 即 $(AB)^* = B^*A^*$. $\square$

6 矩阵的相抵与相似

6.1 基本概念提要

矩阵的相抵与相似是矩阵的两种重要的等价关系.

矩阵 $A_{m \times n}$ 与 $B_{m \times n}$ 相抵, 当且仅当存在可逆矩阵 $P_{m \times m}$ 和 $Q_{n \times n}$, 使得 $A = PBQ$. 由于左乘可逆矩阵 P 相当于进行一系列初等行变换, 由于右乘可逆矩阵 Q 相当于进行一系列初等列变换, “矩阵 A 与 B 相抵”也可以描述为“ A 与 B 可以通过初等变化互相转化”, 即“矩阵 A 与 B 的秩相同”.

方阵 $A_{n \times n}$ 与 $B_{m \times m}$ 相似, 当且仅当存在可逆矩阵 $P_{n \times n}$, 使得 $A = P^{-1}BP$. 对于给定的方阵 A , 如果存在可逆矩阵 P , 使得 A 相似变换成一个对角矩阵 $D = P^{-1}AP$, 那么称 A 是可对角化的. 此时 D 也称为 A 的相似标准型.

寻求相似标准型的过程引向了特征值和特征向量的概念. 若 A 可对角化:

$$D = \text{diag}(\lambda_1, \dots, \lambda_n) = P^{-1}AP \quad \text{即} \quad PD = AP$$

则按照矩阵乘法的规则, P 的第 i 个列向量 $\mathbf{X}_i$ 满足方程 $\lambda_i \mathbf{X}_i = A\mathbf{X}_i$. 从直观上, 这个方程表明 A 对向量 $\mathbf{X}_i$ 的作用仅仅是伸缩, 而不改变其方向, λ_i 是伸缩比例. 这样的数 λ_i 和向量 $\mathbf{X}_i$ 分别称为 A 的特征值和特征向量. 对 A 做相似对角化也就是求解 A 的所有特征值和特征向量. 让我们简单地回顾计算流程:

- (1) 求解特征多项式 $|\lambda I - A|$ 的所有根 λ_i , 这些根即是特征值.
- (2) 对每个特征值 λ_i , 解线性方程组 $(\lambda_i I_n - A)\mathbf{X} = \mathbf{0}$. 解空间即是属于 λ_i 的特征子空间.
- (3) 判断 A 是否可对角化: 检查特征多项式中 λ_i 这个根的重数 (称为代数重数), 以及属于 λ_i 的特征子空间的维数 (称为几何重数). A 可相似对角化当且仅当所有特征值 λ_i 的几何重数等于代数重数.
- (4) 若 A 可对角化, 取每个特征子空间的一组基, 合并成 $\mathbb{K}^n$ 的一组基 (n 个线性无关的特征向量), 它们以列向量组的形式拼成矩阵 P .

相抵和相似都是在研究同一个线性映射在不同基下的表示矩阵. 在线性代数中, 我们研究矩阵的性质, 其实是为了线性映射的性质. 但是, 同一个线性映射在不同的基下可以表示成不同的矩阵. 从这个角度来看, 矩阵只是一种表象. 在本章中, 我们要通过研究表象之间的转换, 来破除表象, 逐渐回归线性映射的本质.

6.2 相似不变量

矩阵的相似是同一线性变换的不同表示矩阵之间的关系. 因此, **相似不变量实质上是指线性变换反映在矩阵上的性质, 或者干脆认为是线性变换本身的性质.**

在前几章中, 我们学习了矩阵的**秩和行列式**. 这两个概念之所以重要, 就在于它们都是相似不变量: 秩是线性变换的像空间维数, 行列式是线性变换的有向体积缩放因子. 这样的表述其实就反映了秩和行列式是属于线性变换本身的性质, 源于矩阵而高于矩阵.

证明秩和行列式是相似不变量并不困难:

(1) 矩阵的相似是一种特殊的相抵关系, 因此秩也是相似不变量.

(2) 若 $A_{n \times n} \sim B_{n \times n}$, 则存在可逆矩阵 P 使得 $A = P^{-1}BP$. 两边取行列式得到 $|A| = |P^{-1}||B||P|$. 注意 $|P^{-1}| = |P|^{-1}$, 因此 $|A| = |B|$, 即行列式是相似不变量.

当然, 还有很多别的相似不变量. 但这里我们先指出, 特征多项式是一个重要的相似不变量. 它来源于相似对角化的计算过程. 以下给出证明:

(*) 若 $A \sim B$, 则存在可逆矩阵 P 使得 $A = P^{-1}BP$. 我们有:

$$|\lambda I - A| = |P^{-1}(\lambda I)P - P^{-1}BP| = |P^{-1}(\lambda I - B)P| = |P^{-1}||\lambda I - B||P| = |\lambda I - B|$$

因此**特征多项式**是一个相似不变量. “多项式”形式上看起来抽象, 但是蕴含的信息量很大. 许多相似不变量都可以由它衍生出来. 比如, **矩阵的秩其实就是特征值 0 的代数重数**; 特征多项式的常数项是 $(-1)^n|A|$. 更一般地, 从特征多项式可以知道, **特征多项式的根 (也就是特征值) 及其代数重数都是相似不变量, 特征多项式的各项系数也都是相似不变量.**

另一个特例是矩阵的**迹**, 它是指矩阵的所有对角线元素之和. 实际上这就是特征多项式的一次项系数的相反数. 如果 A 有 n 个特征值, 那么矩阵的迹也可以看成 n 个特征值之和.

请注意, 虽然特征多项式包含的信息量很大, 但是**两个矩阵的特征多项式相同远远不是两个矩阵相似的充分条件**. 在线性代数的学习范围内, 重点要知道的例子是, 特征子空间的维数 (几何重数) 也是相似不变量, 就不在特征多项式的管辖范围之内. 比如以下两个矩阵:

$$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

它们有共同的特征多项式 $(\lambda - 1)^2$, 但它们并不相似. 事实上后一个矩阵是不可对角化的.

6.3 矩阵可对角化的一般条件

本节的主要任务是提出几条矩阵可对角化的**充要条件**.

首先要提醒的是, 矩阵可对角化有一条很显然但容易被忽略的必要条件: **矩阵必须存在 n 个特征值**, 换言之, **特征多项式必须有 n 个根 (计重数)**. 对这一条件的检查是判断矩阵是否可对角化的第一步. 而且, 由于多项式根的数量与数域有关, 因此在这一步, **必须先明确讨论的是哪个数域**. 比如, 考察以下的矩阵:

$$\begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$$

它可以对角化吗? 正确的回答是不知道, 因为这个矩阵既可以理解为 $\mathbb{R}$ 上的矩阵, 也可以理解为 $\mathbb{C}$ 上矩阵, 这会导致不一样的回答. 可以计算出这个矩阵的特征多项式是 $\lambda^2 + 2\lambda + 2$. 它在 $\mathbb{R}$ 中没有根, 但在 $\mathbb{C}$ 中有 2 个根. 结果, 这个矩阵在 $\mathbb{R}$ 中不可对角化, 但在 $\mathbb{C}$ 中可对角化.

根据代数基本定理, 一个 n 次多项式总有 n 个复根. 因此复矩阵必定有 n 个特征值 (计重数). 对于实矩阵 (或者一般数域 $\mathbb{K}$ 上的矩阵) 则没有这样的结论.

考虑矩阵对角化的意义. 对角矩阵代表的是一类最简单的线性变换——**伸缩变换**. 一个矩阵若能对角化, 说明它实质上代表的就是最简单的伸缩变换, 只不过选取的基不太合适, 使得表示矩阵比较复杂, 一眼看不出是个伸缩变换. 若能找出 n 个特征向量构成一组基, 那么这个线性变换在这组基下的表示矩阵就是对角矩阵了. 根据这一思想, 下述的定理是不证自明的:

定理 6.3.1 n 阶矩阵 A 可对角化的充要条件是 A 有 n 个线性无关的特征向量.

直接从定义也很好理解这一点. 之前讨论过, 在 A 的对角化 $D = P^{-1}AP$ 中, P 的列向量组实质上就是 n 个特征向量. 我们要求 P 是可逆矩阵, 就相当于说这 n 个特征向量是线性无关的.

我们要把这条“废话”定理转换成一个切实可行的判断准则——在计算过程中, 如何判断总共有几个线性无关的特征向量呢? 其实我们是先计算特征子空间, 即 $(\lambda I - A)\mathbf{X} = \mathbf{0}$ 的解空间, 它的一组基就是一组线性无关的特征向量. 这样一来, 每个不同的特征值 λ_i 都能提供 n_i 个线性无关的特征向量, 其中 n_i 是特征子空间 V_{λ_i} 的维数. 如果 A 有 m 个不同的特征值 $\lambda_1, \dots, \lambda_m$, 那么总共会提供 $n_1 + n_2 + \dots + n_m$ 个线性无关的特征向量——想一想这是为什么? 请注意一个简单的事实: **属于不同特征值的特征子空间交集为 $\{\mathbf{0}\}$** (一个特征向量不可能同时属于两个不同的特征值), 不同的特征子空间的和是直和. 从这个角度给出证明是非常简单的:

定理 6.3.2 设 $\{\alpha_1, \dots, \alpha_s\}$ 和 $\{\beta_1, \dots, \beta_r\}$ 分别是矩阵 A 的属于 λ_1, λ_2 的线性无关的特征向量, 则合并之后的向量组 $\{\alpha_1, \dots, \alpha_s, \beta_1, \dots, \beta_r\}$ 也线性无关.

证明 由两个向量组的线性无关性可知 $\dim\langle\alpha_1, \dots, \alpha_s\rangle = s, \dim\langle\beta_1, \dots, \beta_r\rangle = r$. 则有:

$$\dim\langle\alpha_1, \dots, \alpha_s, \beta_1, \dots, \beta_r\rangle = \dim\langle\alpha_1, \dots, \alpha_s\rangle + \dim\langle\beta_1, \dots, \beta_r\rangle = s + r$$

这里第一个等号使用了线性子空间直和的维数公式. 这个式子直接表明合并之后的向量组是线性无关的. $\square$

我们据此改进定理 6.3.1 的表述, 就得到了以下定理:

定理 6.3.3 n 阶矩阵 A 可对角化的充要条件是 A 的属于不同特征值的特征子空间维数之和等于 n .

以上总结了教材上的叙述的定理, 我们在此基础上略微多做一些讨论. 我们把特征值 λ_i 作为特征多项式的根的重数称为**代数重数**, 把相应的特征子空间维数称为**几何重数**. 探究矩阵可对角化的问题可以从代数重数和几何重数的关系入手, 这个想法是源自于我们具体计算矩阵对角化的过程. 就“对角化”的目标而言, 代数重数可以说是我们“预期” λ_i 这个特征值能提供的线性无关特征向量的个数, 而几何重数就是实际上得到的个数. 本节开头讲过, 所有代数重数之和为 n 是矩阵可对角化的一个最基本的前提条件. 在此条件之下, “可对角化”其实就是一个“现实符合预期”的故事. 一般情况下, 几何重数有可能小于代数重数, 但不可能大于代数重数, 即“现实有可能不符合预期, 但决不会超出预期”. 这里简述一下理由: 设 n 阶方阵 A 有特征值 λ_i , 其几何重数为 r , 于是取到 λ_i 的 r 个线性无关的特征向量 $\mathbf{X}_1, \dots, \mathbf{X}_r$. 将其扩充成 $\mathbb{K}^n$ 的一组基 $\mathbf{X}_1, \dots, \mathbf{X}_r, \mathbf{X}_{r+1}, \dots, \mathbf{X}_n$. 并将其拼成一个可逆矩阵 P . 这可以把 A 相似变换成一个分块上三角矩阵:

$$P^{-1}AP = \begin{pmatrix} \lambda_i I_r & C \\ O & D \end{pmatrix}$$

显然其特征多项式中 λ_i 是至少 r 重根, 即 A 的代数重数至少是 r .

定理 6.3.4 任意特征值的几何重数不超过代数重数

结合定理 6.3.3, 我们就知道:

定理 6.3.5 数域 $\mathbb{K}$ 上的 n 阶矩阵 A 可对角化的充要条件是: A 在 $\mathbb{K}$ 中有 n 个特征值, 且每个特征值的代数重数等于几何重数.

根据这个定理, 只要出现某个特征值的几何重数小于代数重数, 就可以直接判断该矩阵不可对角化了.

以上我们讨论的都是矩阵可对角化的充要条件. 灵活利用定理 6.3.2 及其推论, 如果我们发现矩阵 A 有 n 个不同的特征值, 那么可以直接判断它是可对角化的. 这是教材上额外提及的一个可对角化的充分条件.

6.4 实对称矩阵的性质

实对称矩阵有以下特殊的性质:

定理 6.4.1 实对称矩阵的每个复特征值都是实数.

推论 实对称矩阵必有 n 个实特征值 (计重数)

定理 6.4.2 实对称矩阵的属于不同特征值的特征向量是正交的.

定理 6.4.3 实对称矩阵一定正交相似于对角矩阵.

至于为什么要特别关注实对称矩阵, 以及为什么实对称矩阵“恰好”就有这么多良好的性质, 需要引入内积结构之后才能看得明白. 不过这已经超出了线性代数的课程范围. 在讲义的第七章 (二次型), 我们会从复内积的视角解释实对称矩阵的特殊意义, 作为选读内容. 如果对此不感兴趣, 直接把这几条结论背下来即可.

6.5 习题

6.5.1 相抵标准型的计算

例 6.1. 求下列矩阵的相抵标准型:

$$\begin{pmatrix} 1 & -1 & -3 & 1 \\ 1 & -1 & 2 & -1 \\ 4 & -4 & 3 & -2 \end{pmatrix}$$

分析. 求秩即可.

解答. 做初等行变换:

$$\begin{pmatrix} 1 & -1 & -3 & 1 \\ 1 & -1 & 2 & -1 \\ 4 & -4 & 3 & -2 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & -1 & -3 & 1 \\ 0 & 0 & 5 & -2 \\ 0 & 0 & 15 & -6 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & -1 & -3 & 1 \\ 0 & 0 & 5 & -2 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

该矩阵的秩为 2. 因此相抵标准型是:

$$\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

例 6.2. 判断下列两个矩阵是否相抵？

$$A = \begin{pmatrix} 1 & -1 & -3 & 1 \\ 1 & -1 & 2 & -1 \\ 4 & -4 & 3 & -2 \end{pmatrix} \quad B = \begin{pmatrix} 1 & 3 & -2 & 0 \\ 3 & -2 & 0 & 1 \\ 4 & 1 & -2 & 1 \end{pmatrix}$$

解答. 上一问中计算出矩阵 A 的秩为 2. 对矩阵 B 做初等行变换:

$$\begin{pmatrix} 1 & 3 & -2 & 0 \\ 3 & -2 & 0 & 1 \\ 4 & 1 & -2 & 1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 3 & -2 & 0 \\ 0 & -11 & 6 & 1 \\ 0 & -11 & 6 & 1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 3 & -2 & 0 \\ 0 & -11 & 6 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

B 的秩也是 2. 因此 A 与 B 相抵.

例 6.3. 给定矩阵 A :

$$A = \begin{pmatrix} 1 & -1 & -3 & 1 \\ 1 & -1 & 2 & -1 \\ 4 & -4 & 3 & -2 \end{pmatrix}$$

设 A 的相抵标准型为 A_0 . 求可逆矩阵 C_1, C_2 , 使得 $A_0 = C_1 A C_2$.

分析. 等式 $P = C_1 A C_2$ 可以理解为“对 A 做一系列行变换, 再做一系列列变换, 得到 P ”. 这些行变换和列变换分别化身为矩阵 C_1 和 C_2 . 因此, 所要做的是用初等变换把 A 老老实实在地一步步化成相抵标准型, 但同时要利用单位矩阵把你所做的每一步操作“记录”下来. 以求 C_1 为例, 把一个 3 阶单位矩阵放在 A 的右侧, 对 A 做初等行变换时, 这个 3 阶矩阵也做相应的初等行变换, 直至 A 化成了简化行阶梯形矩阵. 此时在右侧得到的行变换后的 3 阶矩阵就是 C_1 .

解答. 先做初等行变换, 通过右侧放置单位矩阵来记录所做的行变换, 得到 C_1 :

$$\begin{pmatrix} 1 & -1 & -3 & 1 & | & 1 & 0 & 0 \\ 1 & -1 & 2 & -1 & | & 0 & 1 & 0 \\ 4 & -4 & 3 & -2 & | & 0 & 0 & 1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & -1 & -3 & 1 & | & 1 & 0 & 0 \\ 0 & 0 & 5 & -2 & | & -1 & 1 & 0 \\ 0 & 0 & 15 & -6 & | & -4 & 0 & 1 \end{pmatrix}$$

$$\rightarrow \begin{pmatrix} 2 & -2 & -6 & 2 & | & 2 & 0 & 0 \\ 0 & 0 & 5 & -2 & | & -1 & 1 & 0 \\ 0 & 0 & 0 & 0 & | & -1 & -3 & 1 \end{pmatrix} \rightarrow \begin{pmatrix} 2 & -2 & -1 & 0 & | & 1 & 1 & 0 \\ 0 & 0 & 5 & -2 & | & -1 & 1 & 0 \\ 0 & 0 & 0 & 0 & | & -1 & -3 & 1 \end{pmatrix}$$

再做初等行变换, 通过下侧放置单位矩阵来记录所做的列变换, 得到 C_2 :

$$\begin{pmatrix} 2 & -2 & -1 & 0 \\ 0 & 0 & 5 & -2 \\ 0 & 0 & 0 & 0 \\ -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{pmatrix} \rightarrow \begin{pmatrix} 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & -2 \\ 0 & 0 & 0 & 0 \\ -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{pmatrix}$$

$$\rightarrow \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

因此:

$$C_1 = \begin{pmatrix} 1 & 1 & 0 \\ -1 & 1 & 0 \\ -1 & -3 & 1 \end{pmatrix} \quad C_2 = \begin{pmatrix} 1/2 & 0 & 1/2 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & -1/2 & 5/2 & 0 \end{pmatrix}$$

6.5.2 相抵标准型的应用

例 6.4. (满秩分解定理) 设 $A_{m \times n}$ 的秩为 r . 证明: 存在秩为 r 的矩阵 $B_{m \times r}$ 和秩为 r 的矩阵 $C_{r \times n}$, 使得 $A = BC$.

分析. 如果 A 本身是相抵标准型, 你能按题意做出这个分解吗?

解答. 存在可逆矩阵 $P_{m \times m}$ 和 $Q_{n \times n}$, 使得:

$$PAQ = \begin{pmatrix} I_r & O \\ O & O \end{pmatrix}$$

而这个相抵标准型可以直接分解成秩为 r 的 $m \times r$ 矩阵和 $r \times n$ 矩阵相乘:

$$\begin{pmatrix} I_r & O \\ O & O \end{pmatrix} = \begin{pmatrix} I_r \\ O \end{pmatrix} (I_r \ O)$$

将上述两式整理成 A 的分解式:

$$A = P^{-1} \begin{pmatrix} I_r \\ O \end{pmatrix} (I_r \ O) Q^{-1}$$

则题目所要求的矩阵 B 和 C 即为:

$$B = P^{-1} \begin{pmatrix} I_r \\ O \end{pmatrix} \quad C = (I_r \ O) Q^{-1}$$

例 6.5. (1) 设 n 阶方阵 A 的秩为 r ($r < n$). 证明: 存在秩为 $n - r$ 的 n 阶非零矩阵 B 和 C , 使得 $AB = O$, $CA = O$.

(2) 设 n 阶方阵 A 的秩为 r ($r < n$). 证明: 存在 n 阶非零方阵 B , 使得 $AB = BA = O$.

证明. 直接做第 (2) 问. 存在可逆矩阵 $P_{m \times m}$ 和 $Q_{n \times n}$, 使得:

$$PAQ = \begin{pmatrix} I_r & O \\ O & O \end{pmatrix}$$

对于这个相抵标准型, 可以直接找到一个秩为 $n - r$ 的矩阵 $R = \text{diag}(O, I_{n-r})$, 左乘或右乘的结果都是零矩阵:

$$\begin{pmatrix} I_r & O \\ O & O \end{pmatrix} \begin{pmatrix} O & O \\ O & I_{n-r} \end{pmatrix} = \begin{pmatrix} O & O \\ O & I_{n-r} \end{pmatrix} \begin{pmatrix} I_r & O \\ O & O \end{pmatrix} = O$$

即:

$$PAQR = RPAQ = O$$

因为 P 和 Q 可逆, 上式推出:

$$A \boxed{QR} = \boxed{RP} A = O$$

这样就足以解答第 (1) 问了. 为了凑出第 (2) 问所要求的矩阵 B , 只需要在保持等式的条件下, 把两个方框里的矩阵形式凑成一样的:

$$A \boxed{QRP} = \boxed{QRP} A = O$$

则 QRP 就是题目所要求的矩阵 B . □

例 6.6. 设矩阵 A, B, C 分别是 $m \times n, r \times s, m \times s$ 矩阵. 证明: 矩阵方程 $AX - YB = C$ 有解 X, Y 的充要条件是:

$$\text{rank} \begin{pmatrix} A & O \\ O & B \end{pmatrix} = \text{rank} \begin{pmatrix} A & C \\ O & B \end{pmatrix}$$

分析. 两个矩阵的秩相等, 意味着可以通过初等行列变换从左侧变换到右侧. 如果能写出初等变换对应的矩阵, 就等于是解出了方程.

证明. (1) 必要性. 已知存在 $n \times s$ 矩阵 X 和 $m \times r$ 矩阵 Y , 使得 $AX - YB = C$. 这个等式告诉我们, 可以做如下的初等变换:

$$\begin{pmatrix} A & O \\ O & B \end{pmatrix} \rightarrow \begin{pmatrix} A & AX \\ O & B \end{pmatrix} \rightarrow \begin{pmatrix} A & AX - YB \\ O & B \end{pmatrix} = \begin{pmatrix} A & C \\ O & B \end{pmatrix}$$

这就证明了:

$$\text{rank} \begin{pmatrix} A & O \\ O & B \end{pmatrix} = \text{rank} \begin{pmatrix} A & C \\ O & B \end{pmatrix}$$

(2) 充分性. 已知上述的秩等式成立. 我们尝试去求解初等行列变换, 即求解 P 和 Q , 使得:

$$P \begin{pmatrix} A & O \\ O & B \end{pmatrix} Q = \begin{pmatrix} A & C \\ O & B \end{pmatrix}$$

我们借助相抵标准型来完成这件事. 设 A, B 的秩分别为 r, t . 则存在可逆矩阵 P_1, Q_1, P_2, Q_2 , 使得:

$$P_1 A Q_1 = \begin{pmatrix} I_r & O \\ O & O \end{pmatrix} \quad P_2 B Q_2 = \begin{pmatrix} I_t & O \\ O & O \end{pmatrix}$$

于是有:

$$\begin{pmatrix} P_1 & O \\ O & P_2 \end{pmatrix} \begin{pmatrix} A & O \\ O & B \end{pmatrix} \begin{pmatrix} Q_1 & O \\ O & Q_2 \end{pmatrix} = \begin{pmatrix} I_r & O & O & O \\ O & O & O & O \\ O & O & I_t & O \\ O & O & O & O \end{pmatrix}$$

同样的变换施加到另一个矩阵上是:

$$\begin{pmatrix} P_1 & O \\ O & P_2 \end{pmatrix} \begin{pmatrix} A & C \\ O & B \end{pmatrix} \begin{pmatrix} Q_1 & O \\ O & Q_2 \end{pmatrix} = \begin{pmatrix} P_1 A Q_1 & P_1 C Q_2 \\ O & P_2 B Q_2 \end{pmatrix} = \begin{pmatrix} I_r & O & C_1 & C_2 \\ O & O & C_3 & C_4 \\ O & O & I_t & O \\ O & O & O & O \end{pmatrix}$$

对它进一步施加初等行列变换，可以再简化：

$$\begin{pmatrix} I_r & O & C_1 & C_2 \\ O & O & C_3 & C_4 \\ O & O & I_t & O \\ O & O & O & O \end{pmatrix} \rightarrow \begin{pmatrix} I_r & O & O & C_2 \\ O & O & O & C_4 \\ O & O & I_t & O \\ O & O & O & O \end{pmatrix} \rightarrow \begin{pmatrix} I_r & O & O & O \\ O & O & O & C_4 \\ O & O & I_t & O \\ O & O & O & O \end{pmatrix}$$

也就是说存在矩阵 G_1, G_2 ，使得：

$$\begin{pmatrix} I_m & G_1 \\ O & I_r \end{pmatrix} \begin{pmatrix} I_r & O & C_1 & C_2 \\ O & O & C_3 & C_4 \\ O & O & I_t & O \\ O & O & O & O \end{pmatrix} \begin{pmatrix} I_n & G_2 \\ O & I_s \end{pmatrix} = \begin{pmatrix} I_r & O & O & O \\ O & O & O & C_4 \\ O & O & I_t & O \\ O & O & O & O \end{pmatrix}$$

事实上可以直接读出矩阵 G_1, G_2 分别是：

$$G_1 = \begin{pmatrix} -C_1 & O \\ -C_2 & O \end{pmatrix} \quad G_2 = \begin{pmatrix} O & -C_2 \\ O & O \end{pmatrix}$$

从最右侧的形式可以看出，矩阵的秩为 $r+t+\text{rank}(C_4)$ 。但由已知条件知道它的秩应该是 $r+t$ 。因此 $C_4 = O$ 。这样我们就已经做到了将两个矩阵都通过初等行列变换变成 $\text{diag}(I_r, O, I_t, O)$ ，以此为桥梁来整理上述的所有式子：

$$\text{diag}(I_r, O, I_t, O) =$$

$$\begin{pmatrix} P_1 & O \\ O & P_2 \end{pmatrix} \begin{pmatrix} A & O \\ O & B \end{pmatrix} \begin{pmatrix} Q_1 & O \\ O & Q_2 \end{pmatrix} = \begin{pmatrix} I_m & G_1 \\ O & I_r \end{pmatrix} \begin{pmatrix} P_1 & O \\ O & P_2 \end{pmatrix} \begin{pmatrix} A & C \\ O & B \end{pmatrix} \begin{pmatrix} Q_1 & O \\ O & Q_2 \end{pmatrix} \begin{pmatrix} I_n & G_2 \\ O & I_s \end{pmatrix}$$

整理并计算得到：

$$\begin{aligned} \begin{pmatrix} A & C \\ O & B \end{pmatrix} &= \begin{pmatrix} P_1^{-1} & O \\ O & P_2^{-1} \end{pmatrix} \begin{pmatrix} I_m & G_1 \\ O & I_r \end{pmatrix}^{-1} \begin{pmatrix} P_1 & O \\ O & P_2 \end{pmatrix} \begin{pmatrix} A & O \\ O & B \end{pmatrix} \begin{pmatrix} Q_1 & O \\ O & Q_2 \end{pmatrix} \begin{pmatrix} I_n & G_2 \\ O & I_s \end{pmatrix}^{-1} \begin{pmatrix} Q_1^{-1} & O \\ O & Q_2^{-1} \end{pmatrix} \\ &= \begin{pmatrix} P_1^{-1} & O \\ O & P_2^{-1} \end{pmatrix} \begin{pmatrix} I_m & -G_1 \\ O & I_r \end{pmatrix} \begin{pmatrix} P_1 A Q_1 & O \\ O & P_2 B Q_2 \end{pmatrix} \begin{pmatrix} I_n & -G_2 \\ O & I_s \end{pmatrix} \begin{pmatrix} Q_1^{-1} & O \\ O & Q_2^{-1} \end{pmatrix} \\ &= \begin{pmatrix} P_1^{-1} & O \\ O & P_2^{-1} \end{pmatrix} \begin{pmatrix} P_1 A Q_1 & -G_1 P_2 B Q_2 - P_1 A Q_1 G_2 \\ O & P_2 B Q_2 \end{pmatrix} \begin{pmatrix} Q_1^{-1} & O \\ O & Q_2^{-1} \end{pmatrix} \\ &= \begin{pmatrix} A & -P_1^{-1} G_1 P_2 B - A Q_1 G_2 Q_2^{-1} \\ O & B \end{pmatrix} \end{aligned}$$

比较左右两侧，得到：

$$C = -P_1^{-1} G_1 P_2 B - A Q_1 G_2 Q_2^{-1}$$

这样就找到了矩阵方程 $AX - YB = C$ 的解：

$$X = -Q_1 G_2 Q_2^{-1}, \quad Y = P_1^{-1} G_1 P_2$$

因此矩阵方程是有解的。

□

6.5.3 相似对角化的计算

例 6.7. 设矩阵:

$$A = \begin{pmatrix} 4 & 2 & 2 \\ 0 & 4 & 0 \\ 0 & -6 & -2 \end{pmatrix}$$

(1) 求 A 的全部特征值与特征向量.

(2) 判断 A 是否可对角化. 如果可对角化, 求可逆矩阵 U 和对角矩阵 D , 使得 $D = U^{-1}AU$; 如果不可对角化, 说明理由.

(3) 计算 A^{20} .

解答.

(1) 计算特征多项式:

$$|\lambda I - A| = \begin{vmatrix} \lambda - 4 & -2 & -2 \\ 0 & \lambda - 4 & 0 \\ 0 & 6 & \lambda + 2 \end{vmatrix} = (\lambda - 4)^2(\lambda + 2)$$

A 的特征值为: $\lambda_1 = 4$ (2 重), $\lambda_2 = -2$ (1 重).

(i) $\lambda = 4$: 解方程 $(4I - A)\mathbf{X} = \mathbf{0}$. 系数矩阵 $4I - A$ 为:

$$\begin{pmatrix} 0 & -2 & -2 \\ 0 & 0 & 0 \\ 0 & 6 & 6 \end{pmatrix}$$

它的秩为 1, 能得到 2 个线性无关的特征向量:

$$\mathbf{X}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \mathbf{X}_2 = \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}$$

构成基础解系, 即特征子空间的一组基. 因此 $\lambda = 4$ 对应的全部特征向量为 $c_1\mathbf{X}_1 + c_2\mathbf{X}_2$, 其中 c_1, c_2 不同时为 0.

(ii) $\lambda = -2$: 解方程 $(-2I - A)\mathbf{X} = \mathbf{0}$. 系数矩阵 $-2I - A$ 为:

$$\begin{pmatrix} 6 & 2 & 2 \\ 0 & 6 & 0 \\ 0 & -6 & 0 \end{pmatrix}$$

它的秩为 2, 能得到 1 个线性无关的特征向量:

$$\mathbf{X}_3 = \begin{pmatrix} 1 \\ 0 \\ -3 \end{pmatrix}$$

构成基础解系, 即特征子空间的一组基. 因此 $\lambda = -2$ 对应的全部特征向量为 $c_3\mathbf{X}_3$, 其中 $c_3 \neq 0$.

(2) 在 (1) 中, 我们已经得到了 3 个线性无关的特征向量, 因此 A 可对角化.

(3) 设矩阵:

$$P = (\mathbf{X}_1, \mathbf{X}_2, \mathbf{X}_3) = \begin{pmatrix} 1 & 0 & 1 \\ 0 & -1 & 0 \\ 0 & 1 & -3 \end{pmatrix}, \quad D = \begin{pmatrix} 4 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & -2 \end{pmatrix}$$

则有 $D = P^{-1}AP$. 于是:

$$A^{20} = (PDP^{-1})^{20} = PD^{20}P = \begin{pmatrix} 4^{20} & 2(4^{20} - 2^{20}) & 2(4^{20} - 2^{20}) \\ 0 & 4^{20} & 0 \\ 0 & -6(4^{20} - 2^{20}) & 2^{20} \end{pmatrix}$$

例 6.8. 设实矩阵:

$$A = \begin{pmatrix} -4 & 2 & 2 \\ 2 & -1 & 4 \\ 2 & 4 & a \end{pmatrix}$$

已知 -5 是 A 的一个重数为 2 的特征值. 求 a 的值.

分析. 固然可以直接去计算特征多项式. 但是注意 A 是实对称矩阵, 这应该能带来很大的方便.

解答. 注意 A 是实对称矩阵, -5 是 A 的一个重数为 2 的特征值, 意味着 -5 能对应 2 个线性无关的特征向量, 即 $-5I - A$ 的秩为 1. 计算 $-5I - A$:

$$\begin{pmatrix} -1 & -2 & -2 \\ -2 & -4 & -4 \\ -2 & -4 & -5-a \end{pmatrix}$$

由秩为 1 可知 $a = -1$.

6.5.4 对角化相关证明

例 6.9. 设 n 阶矩阵:

$$A = \begin{pmatrix} I_r & B \\ O & -I_{n-r} \end{pmatrix}$$

求证: A 可对角化.

分析. 我们所学的矩阵可对角化的理论直接来源于对角化的计算过程. 对于本题这种形式具体的矩阵, 直接去尝试计算它的对角化即可. 目标是得到代数重数和几何重数的关系.

证明. A 是上三角矩阵, 容易求得 A 的特征多项式为 $|\lambda I - A| = (\lambda - 1)^r(\lambda + 1)^{n-r}$. 可知 1 是 r 重特征值, -1 是 $n - r$ 重特征值. 只需证明它们的特征子空间的维数 (几何重数) 也分别是 r 和 $n - r$.

所谓特征子空间的维数, 就是齐次线性方程组 $(\lambda I - A)\mathbf{X} = \mathbf{0}$ 的解空间维数. 根据维数公式, 这等于 $n - \text{rank}(\lambda I - A)$. 于是我们考察矩阵 $I - A$ 和 $-I - A$ 的秩, 易见它们分别是 $n - r$ 和 r . 因此特征值 1 和 -1 的特征子空间维数分别为 r 和 $n - r$. $\square$

如果已知 λ_i 是特征值, 那么矩阵 A 的几何重数其实就是 $\dim \text{Ker}(\lambda I - A)$, 根据维数公式, 几何重数还可以写成 $n - \text{rank}(\lambda I - A)$. 如果要证明矩阵 A 可对角化, 可以考虑利用充要条件, 去证所有特征值的几何重数之和为 n 即可.

明确了这个目标之后, 问题就转化成了证明一些矩阵的秩的关系. 具体处理办法见上一章.

例 6.10.

(1) 求证: 若 n 阶方阵 A 是幂等矩阵 ($A^2 = A$), 则 A 必可对角化.

(2) 求证: 若 n 阶方阵 A 是对合矩阵 ($A^2 = I_n$), 则 A 必可对角化.

证明.

(1) 先计算特征值. 设 λ 是 A 的特征值, 对应的一个特征向量是 $\mathbf{X}$. 由 $A^2 = A$ 可知 $A^2\mathbf{X} = A\mathbf{X} = \lambda\mathbf{X}$. 但是另一方面, $A^2\mathbf{X} = A(A\mathbf{X}) = A(\lambda\mathbf{X}) = \lambda A\mathbf{X} = \lambda^2\mathbf{X}$. 比较两式可知 $\lambda = \lambda^2$, 即 A 的特征值只可能是 0 或 1. 我们只考察它们的特征子空间维数之和是否为 n , 即证明 $\dim \text{Ker}(I - A) + \dim \text{Ker} A = n$.

根据维数公式: $n = \dim \text{Ker}(I - A) + \dim \text{Im}(I - A)$, $n = \dim \text{Ker} A + \dim \text{Im} A$. 只需证明 $\dim \text{Ker}(I - A) + \dim \text{Ker} A = n$, 即 $\text{rank}(I - A) + \text{rank}(A) = n$. 这是上一章习题中证明过的结论.

(2) 先计算特征值. 设 λ 是 A 的特征值, 对应的一个特征向量是 $\mathbf{X}$. 由 $A^2 = I$ 可知 $A^2\mathbf{X} = I\mathbf{X} = \mathbf{X}$. 但是另一方面, $A^2\mathbf{X} = A(A\mathbf{X}) = A(\lambda\mathbf{X}) = \lambda A\mathbf{X} = \lambda^2\mathbf{X}$. 比较两式可知 $\lambda^2 = 1$, 即 A 的特征值只可能是 1 或 -1 . 我们只考察它们的特征子空间维数之和是否为 n , 即证明 $\dim \text{Ker}(I - A) + \dim \text{Ker}(I + A) = n$.

根据维数公式: $n = \dim \text{Ker}(I - A) + \dim \text{Im}(I - A)$, $n = \dim \text{Ker}(I + A) + \dim \text{Im}(I + A)$. 只需证明 $\dim \text{Ker}(I - A) + \dim \text{Ker}(I + A) = n$, 即 $\text{rank}(I - A) + \text{rank}(I + A) = n$. 这是上一章习题中证明过的结论. $\square$

例 6.11. 设 n 阶矩阵 A 和 B 满足 $AB + BA = O$, 且有 $\text{rank}(B) = k$ ($1 \leq k \leq n - 1$). 证明: -1 是 A 的一个特征值, 且 A 至少有 k 个属于 -1 的线性无关特征向量.

证明. 我们的目标是研究 $I + A$ 的秩. 已知 A 和 B 满足 $(A + I)B = O$. 根据上一章习题中证明过的结论, $\text{rank}(A + I) + \text{rank}(B) \leq n$. 再由维数公式: $\dim \text{Ker}(A + I) + \text{rank}(A + I) = n$. 代入可知 $\dim \text{Ker}(A + I) \geq k$, 即属于特征值 -1 的特征子空间至少是 k 维, 亦即至少有 -1 个属于 -1 的线性无关的特征向量. $\square$

例 6.12. 设 α, β 是非零的 n 维列向量 ($n \geq 2$), 且 $A = \alpha\beta^T$. 试问矩阵 A 是否相似于对角矩阵, 给出理由.

分析. 本题的切入点是注意形如 $\alpha\beta^T$ 的矩阵秩为 1.

证明. 按矩阵乘法的规则, $A = \alpha\beta^T$ 的每一个列向量都与 α 共线, 因此 $\text{rank}(A) < n$. 又因为 α, β 都是非零向量, $A = \alpha\beta^T$ 不是零矩阵. 因此 $\text{rank}(A) = 1$. 由维数公式可知 $\dim \text{Ker } A = n - 1$, 即 A 的 0 特征值的几何重数是 $n - 1$. 这表明 0 的代数重数至少是 $n - 1$.

设 $f(\lambda)$ 是 A 的特征多项式. 由上述讨论可知, λ^{n-1} 是 $f(\lambda)$ 的一个因式. 而 $f(\lambda)$ 是 n 次多项式. 因此 $f(\lambda)$ 是 λ^{n-1} 与某个一次因式 $\lambda - a$ 的乘积. 这就说明 $f(\lambda)$ 一定还有一个根 a , 即 $f(\lambda)$ 一定有 n 个特征值.

对剩下的一个特征值 a 进行分类讨论: 如果 $a = 0$, 则特征值 0 的代数重数为 n , 而几何重数是 $n - 1$. 则 A 不可对角化. 此时 $a \neq 0$, 则特征值 0 的代数重数和几何重数都是 $n - 1$, 而特征值 a 的代数重数和几何重数都是 1. 此时 A 可对角化. $\square$

例 6.13. 设 T 和 S 是数域 $\mathbb{K}$ 上的 n 阶矩阵, 已知 T 在 $\mathbb{K}$ 上有 n 个互不相同的特征值. 证明: 若 $ST = TS$, 则 S 可对角化.

证明. T 有 n 个互不相同的特征值, 则 T 可对角化, 且每个特征值的特征子空间都是 1 维的. 设 λ 是 T 的一个特征值, 对应的一个特征向量是 x . 则有:

$$T(Sx) = STx = S(\lambda x) = \lambda(Sx)$$

可见 Sx 是 T 的属于 λ 的特征向量. 因为 T 的属于 λ 的特征子空间是一维的, 即 $\langle x \rangle$, 因此存在数 $\mu \in \mathbb{K}$, 使得 $Sx = \mu x$. 因此 x 是 S 的特征向量. 由 λ 的任意性可知, T 特征向量都是 S 的特征向量, 因此 S 有 n 个线性无关的特征向量, S 可对角化. $\square$

例 6.14. 设 A, B 为 n 阶方阵. 求证: $AB - BA$ 必定不相似于 kI_n ($k \neq 0$).

分析. 只要两个矩阵的某个相似不变量不同, 那它们就一定不相似.

证明. $\text{tr}(AB - BA) = \text{tr}(AB) - \text{tr}(BA) = 0$, 但 $\text{tr}(kI_n) = nk$. $\text{tr}(AB - BA) \neq \text{tr}(kI_n)$, 因此它们必定不相似. $\square$

6.5.5 * 相似对角化的应用

例 6.15. 特征方程的概念在许多问题中都有应用.

(1) 考虑下述矩阵 A :

$$\begin{pmatrix} 2 & 3 \\ 1 & 0 \end{pmatrix}$$

求可逆矩阵 P , 使得 $P^{-1}AP$ 是对角矩阵.

(2) 数列 $\{a_n\}$ 满足递推公式: $a_n = 2a_{n-1} + 3a_{n-2}$. 若已知前两项 a_1, a_2 , 利用 (1) 的结论计算通项公式.

(3) 利用 (1) 的结论求解二阶常系数线性微分方程 $y'' = 2y' + 3y$.

解答.

(1) A 的特征多项式为 $\lambda^2 - 2\lambda - 3 = 0$. 特征值为 $\lambda_1 = 3, \lambda_2 = -1$. 解得它们分别对应的一个特征向量是 $\xi_1 = (3, 1)^T, \xi_2 = (1, -1)^T$. 因此题目所要求的矩阵 P 为:

$$\begin{pmatrix} 3 & 1 \\ 1 & -1 \end{pmatrix}$$

满足 $P^{-1}AP = D = \text{diag}(3, -1)$.

(2) 记状态向量 $\alpha_n = (a_{n+1}, a_n)^T$. 则递推公式可以表达为矩阵形式:

$$\begin{pmatrix} a_{n+2} \\ a_{n+1} \end{pmatrix} = \begin{pmatrix} 2 & 3 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} a_{n+1} \\ a_n \end{pmatrix} \quad \text{即 } \alpha_{n+1} = A\alpha_n$$

这样, 我们从形式上得到了一个类似于等比数列的线性递推公式. 容易写出 α_n 的通项公式是 $\alpha_n = A^{n-1}\alpha_1$. 利用 (1) 的结论, $A^{n-1} = (PDP^{-1})^{n-1} = PD^{n-1}P^{-1}$. 则通项公式化为:

$$\alpha_n = PD^{n-1}P^{-1}\alpha_1 \quad \text{即 } P^{-1}\alpha_n = D^{n-1}(P^{-1}\alpha_1)$$

后续的计算如下:

$$P^{-1} = -\frac{1}{4} \begin{pmatrix} -1 & -1 \\ -1 & 3 \end{pmatrix} \quad P^{-1}\alpha_1 = -\frac{1}{4} \begin{pmatrix} -1 & -1 \\ -1 & 3 \end{pmatrix} \begin{pmatrix} a_2 \\ a_1 \end{pmatrix}$$

$$\begin{aligned} \alpha_n = PD^{n-1}P^{-1}\alpha_1 &= \begin{pmatrix} 3 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 3^{n-1} & 0 \\ 0 & (-1)^{n-1} \end{pmatrix} \cdot \frac{-1}{4} \begin{pmatrix} -1 & -1 \\ -1 & 3 \end{pmatrix} \begin{pmatrix} a_2 \\ a_1 \end{pmatrix} \\ &= \frac{1}{4} \begin{pmatrix} 3^n(a_2 + a_1) + (-1)^{n-1}(a_2 - 3a_1) \\ 3^{n-1}(a_2 + a_1) - (-1)^{n-1}(a_2 - 3a_1) \end{pmatrix} \end{aligned}$$

由第 2 分量可知, a_n 的通项公式为:

$$a_n = 3^{n-1}(a_2 + a_1) - (-1)^{n-1}(a_2 - 3a_1)$$

(3) 模仿 (2) 的做法, 考虑向量函数 $\mathbf{Y}(x) = (y'(x), y(x))^T$. 则微分方程可以改写成矩阵形式:

$$\begin{pmatrix} y'' \\ y' \end{pmatrix} = \begin{pmatrix} 2 & 3 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} y' \\ y \end{pmatrix} \quad \text{即} \quad \frac{d}{dx} \mathbf{Y} = A \mathbf{Y}$$

这样, 我们得到了一个类似于二阶线性常系数齐次微分方程的形式. 我们知道, 普通的一阶齐次常系数线性方程 $\frac{d}{dx}y = ay$ 的通解是 $y = Ce^{ax}$, 其中 C 是任意常数. 受此启发, 我们猜测 $\frac{d}{dx} \mathbf{Y} = A \mathbf{Y}$ 的通解形如 $\mathbf{Y} = e^{Ax} \mathbf{C}$, 其中 $\mathbf{C}$ 是任意常数列向量.

现在我们当然要问 “ e^{Ax} ” 是什么? 我们可以利用 e^x 的泰勒展开式去计算它:

$$e^{Ax} = I + Ax + \frac{1}{2}A^2x^2 + \cdots + \frac{1}{n!}A^nx^n + \cdots$$

考虑 A 的对角化 $A = PDP^{-1}$, 则展开式可以化简:

$$\begin{aligned} e^{Ax} &= I + PDP^{-1}x + \frac{1}{2}PD^2P^{-1}x^2 + \cdots + \frac{1}{n!}PD^nP^{-1}x^n + \cdots \\ &= P \left(I + Dx + \frac{1}{2}D^2x^2 + \cdots + \frac{1}{n!}D^nx^n \cdots \right) P^{-1} \\ &= P \begin{pmatrix} e^{3x} & 0 \\ 0 & e^{-x} \end{pmatrix} P^{-1} = Pe^{Dx}P^{-1} \end{aligned}$$

因此通解为 $\mathbf{Y} = Pe^{Dx}P^{-1}\mathbf{C}$. 注意 $\mathbf{C}$ 是任意常数列向量, 则 $P^{-1}\mathbf{C}$ 也是任意常数列向量, 因此通解的形式不妨写成 $\mathbf{Y} = Pe^{Dx}\mathbf{C}$. 计算 Pe^{Dx} :

$$Pe^{Dx} = \begin{pmatrix} 3 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} e^{3x} & 0 \\ 0 & e^{-x} \end{pmatrix} = \begin{pmatrix} 3e^{3x} & e^{-x} \\ e^{3x} & -e^{-x} \end{pmatrix}$$

因此 $\frac{d}{dx} \mathbf{Y} = A \mathbf{Y}$ 通解为:

$$\mathbf{Y} = \begin{pmatrix} 3e^{3x} & e^{-x} \\ e^{3x} & -e^{-x} \end{pmatrix} \mathbf{C} = c_1 \begin{pmatrix} 3e^{3x} \\ e^{3x} \end{pmatrix} + c_2 \begin{pmatrix} e^{-x} \\ -e^{-x} \end{pmatrix}$$

其中 $\mathbf{C} = (c_1, c_2)^T$, c_1, c_2 是任意常数. 该式的第 2 分量给出了原方程的通解:

$$y = c_1e^{3x} + c_2e^{-x}$$

7 二次型

7.1 从代数到几何

目前我们已经通过线性空间的概念刻画了“向量”这一代数对象. 但是这一刻画在应用上还是有很大的不足. 回想中学时, 我们用向量来做解析几何问题, 经常要计算向量的长度、夹角等几何量. 但这些在线性空间中都还没有定义. 我们已经看到, 线性空间的概念是很泛用的, 函数、集合、量子态等等类型的元素都可以建立线性空间——如果它们也能像解析几何那样谈论“长度”、“夹角”等概念, 岂不是很方便?

那么, 在抽象的线性空间中, 我们没法直接看到“长度”、“夹角”这些东西, 如何去定义呢? 就像我们定义线性空间中的向量那样, 我们并不是直接去问“向量是什么”, 而是去问“向量满足哪些性质”. 这是代数学中非常重要的思想方法.

在欧氏空间中, **内积**可以诱导出我们想要的这些概念: 一个向量与自身的内积即是其长度的平方; 两个向量的夹角余弦也可用内积来计算. 这样看来, 与“距离”、“长度”相比, “内积”是“级别更高”的一种结构. 为了把所有这些概念一网打尽, 我们直接在线性空间的基础上去定义**内积**. 定义了内积的线性空间称为**内积空间**.

7.1.1 实内积空间概述

内积结构的定义与数域有关. 一般我们只关注两个数域: $\mathbb{R}$ 和 $\mathbb{C}$. 因此, 我们需要分别定义实线性空间和复线性空间的内积. 在线性代数中, 我们主要讨论实内积和实内积空间. 我们将在本节的最后再讨论 $\mathbb{R}$ 到 $\mathbb{C}$ 的推广.

以我们最熟悉的 $\mathbb{R}^n$ 中的标准内积 (两个数组对应分量相乘再全部相加) 为模板, 可以总结出内积“应有”的几条性质. 我们借助这些性质去叙述一般实内积的定义:

设 V 是 $\mathbb{R}$ 上的线性空间. 定义 V 上的一个二元函数 $(\cdot, \cdot) : V \times V \rightarrow \mathbb{R}$, 即: 对于任意 $x, y \in V$, (x, y) 都对应一个实数. 如果对任意的 $x, y \in V$, $\alpha \in \mathbb{R}$, 满足以下 4 条规则, 那么称 V 是实内积空间 (欧氏空间), 这个二元函数是 V 上的一个实内积:

- (1) 正定性: $(x, x) \geq 0$, 等号成立当且仅当 $x = 0$.
- (2) 对称性: $(x, y) = (y, x)$.
- (3) 线性 (数乘): $(\alpha x, y) = \alpha(x, y)$.
- (4) 线性 (加法): $(x + y, z) = (x, z) + (y, z)$.

$\mathbb{R}^n$ 中的标准内积是大家所熟悉的. 这里再举两个大家所知道的, 但可能未“如此想过”的内积空间.

例 1 全体 $m \times n$ 实矩阵构成 $\mathbb{R}$ 上的线性空间 $M_{m \times n}(\mathbb{R})$. 在其上定义二元函数 $(A, B) = \text{tr}(A^T B)$. 这就是 $M_{m \times n}(\mathbb{R})$ 上的一个内积, 称为 *Frobenius* 内积.

例 2 定义在 $[a, b]$ 上的全体平方可积函数 $L^2[a, b]$ 构成 $\mathbb{R}$ 上的线性空间. 对 $f, g \in L^2[a, b]$, 定义:

$$(f, g) = \int_a^b f(x)g(x) \, dx$$

则不难验证这是一个内积.

上面的例 2 来自于高等数学, 以此为基础建立了傅里叶级数理论.

在定义了内积之后, 便可以获得许多我们在 $\mathbb{R}^n$ 中所熟悉的概念:

长度 (范数) 设 V 是实内积空间, $\alpha \in V$, 则 α 的长度 (范数) 定义为: $\|\alpha\| = (\alpha, \alpha)^{1/2}$.

距离 (度量) 设 V 是实内积空间, $\alpha, \beta \in V$, 则 α 与 β 的距离定义为: $d(\alpha, \beta) = \|\alpha - \beta\|$.

夹角 设 V 是实内积空间, 定义非零向量 α 和 β 的夹角 θ 之余弦为 $\cos \theta = \frac{(\alpha, \beta)}{\|\alpha\| \|\beta\|}$.

定理 4.4.1 设 V 是实内积空间, $\alpha, \beta \in V$, c 是常数, 则:

$$(1) \quad \|c\alpha\| = |c| \|\alpha\|.$$

$$(2) \quad |(\alpha, \beta)| \leq \|\alpha\| \cdot \|\beta\|.$$

$$(3) \quad \|\alpha + \beta\| \leq \|\alpha\| + \|\beta\|.$$

7.1.2 内积的表示——正定实对称矩阵

对于一般的 n 维欧氏空间或酉空间, 在给定一组基 $\{e_1, e_2, \dots, e_n\}$ 之后, 其中的向量就能表示为坐标 (数组). 于是我们希望能利用坐标去计算内积.

以下设 $\alpha = x_1 e_1 + x_2 e_2 + \dots + x_n e_n$, $\beta = y_1 e_1 + y_2 e_2 + \dots + y_n e_n$. 它们在基 $\{e_1, e_2, \dots, e_n\}$ 下的坐标分别为 $\mathbf{X}$ 和 $\mathbf{Y}$. 记 $(e_i, e_j) = g_{ij}$. 因为实内积有线性性质, 所以任意两个向量 α, β 的内积可以由一组基两两之间的内积 $(e_i, e_j) = g_{ij}$ 来确定:

$$(\alpha, \beta) = \left(\sum_{i=1}^n x_i e_i, \sum_{j=1}^n y_j e_j \right) = \sum_{i=1}^n \sum_{j=1}^n g_{ij} x_i y_j$$

这个结论实际上可以写成矩阵形式:

$$(\alpha, \beta) = (x_1, x_2, \dots, x_n) \begin{pmatrix} g_{11} & g_{12} & \cdots & g_{1n} \\ g_{21} & g_{22} & \cdots & g_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ g_{n1} & g_{n2} & \cdots & g_{nn} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

其中矩阵 G :

$$G = \begin{pmatrix} g_{11} & g_{12} & \cdots & g_{1n} \\ g_{21} & g_{22} & \cdots & g_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ g_{n1} & g_{n2} & \cdots & g_{nn} \end{pmatrix} = \begin{pmatrix} (e_1, e_1) & (e_1, e_2) & \cdots & (e_1, e_n) \\ (e_2, e_1) & (e_2, e_2) & \cdots & (e_2, e_n) \\ \vdots & \vdots & \ddots & \vdots \\ (e_n, e_1) & (e_n, e_2) & \cdots & (e_n, e_n) \end{pmatrix}$$

这里的矩阵 G 也称为**度规矩阵**. α, β 在给定基下的内积即可表示为 $(\alpha, \beta) = \mathbf{X}^T G \mathbf{Y}$. 容易看出 G 是对称矩阵. 另外由内积的正定性可知, $\mathbf{X}^T G \mathbf{X} > 0$ 对于任意非零向量 $\mathbf{X}$ 成立. 满足这种性质的矩阵 G 称为**正定矩阵**. 表达式 $\mathbf{X}^T G \mathbf{X}$ 称为**二次型**, 它是关于 $\mathbf{X}$ 各分量的二次齐次多项式.

由此看出, 欧氏空间中的实内积与正定实对称矩阵之间存在一一对应.

7.1.3 广义内积的引入与表示——实对称矩阵

在我们推广内积的概念之前, 我们先对**度规矩阵** G 的意义做进一步讨论. 我们知道 G 的 (i, j) 元素是 (e_i, e_j) . 根据长度和夹角的定义, G 对角线上的元素是定义了一组基中每个 e_i 的长度, 而其他位置的元素是定义了这一组基两两之间的夹角. 因此, G 其实打包了一组基的全部几何信息, 也就代表了整个空间的几何信息. 它的作用就像是一把测量标尺. 这就是为什么我们称其为度规矩阵.

度规矩阵的另一种 (本质相同的) 看法是给出了内积空间中的基本几何定律. 比如在我们所熟悉的欧氏空间中, 建立解析几何的基本定律是勾股定理. 这与欧氏度规 (单位矩阵 I) 是等价的. 勾股定理可以表达为:

$$\|\mathbf{X}\|^2 = \mathbf{X}^T I \mathbf{X}$$

勾股定理的一个重要应用是计算曲线长. 我们把曲线微元 ds 近似为直线段, 则能得出线元 $ds^2 = (dx)^2 + (dy)^2$. 这在高等数学中有详细说明.

如果我们把欧氏度规 I 换成任意的度规 G , 我们会得到相应内积空间中的“勾股定理”

$$\|\mathbf{X}\|^2 = \mathbf{X}^T G \mathbf{X}$$

在高等数学中, 我们可以讨论如何在球坐标下计算三维曲线的长度. 这个问题其实就是取球面度规:

$$B = \begin{pmatrix} 1 & 0 & 0 \\ 0 & r^2 & 0 \\ 0 & 0 & r^2 \sin^2 \theta \end{pmatrix}$$

那么曲线的线元公式就可以写成:

$$ds^2 = (dr, d\theta, d\varphi) \begin{pmatrix} 1 & 0 & 0 \\ 0 & r^2 & 0 \\ 0 & 0 & r^2 \sin^2 \theta \end{pmatrix} \begin{pmatrix} dr \\ d\theta \\ d\varphi \end{pmatrix} = (dr)^2 + r^2 (d\theta)^2 + r^2 \sin^2 \theta (d\varphi)^2$$

有时我们也把线元称为**度规**，即通过线元可以直接“读”出度规矩阵，从而知道当前坐标系下的几何特性。给出球面度规即给出了球面几何。我们容易想象在球面上的几何与通常的平面几何（欧氏几何）有许多不同之处（例如平行线会相交），而度规则给了我们计算非欧几何的基本工具。

到目前为止，我们所讨论的度规矩阵都是正定的。这是因为实内积本身是正定的。在我们通常的观念里，虽然有球面几何这样“弯曲”的几何学，但是“距离的平方是非负数”总归是毫无争议的。然而随着科学的发展，我们渐渐发现，不满足正定性的几何学竟然也是有用的。最经典的例子就是狭义相对论中，“时空距离”并不符合 $\mathbb{R}^4$ 中的勾股定理，而是：

$$ds^2 = -(dt)^2 + (dx)^2 + (dy)^2 + (dz)^2$$

这里我们取光速 $c = 1$ 。从这个线元中“读”出的度规是**闵氏度规**：

$$\eta = \begin{pmatrix} -1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

按照定义它显然不是正定矩阵。广义相对论进一步认为，引力本质上是时空的“弯曲”，即物质通过改变时空的几何（度规）来导致运动。这使得非欧几何，而且是非正定的几何，称为描述相对论物理的基本语言。

在这一背景下，我们有必要对实内积的概念推广为**广义内积**，或称为**对称双线性形式**。推广的方式也很简单：在定义中去掉正定性即可。相应地，其表示矩阵一般也不具有正定性的要求，而是一般的实对称矩阵 A 。在 A 所规定的几何中，“勾股定理”表达为 $\|\mathbf{X}\|^2 = \mathbf{X}^T A \mathbf{X}$ 。其中，等号右边即是“斜边长的平方”的展开式，这种表达式称为**二次型**， A 也可称为**二次型矩阵**。如果写出分量式 $\mathbf{X} = (x_1, x_2, \dots, x_n)^T$ ，那么二次型可以看成是一个 n 元的 2 次齐次多项式：

$$f(x_1, x_2, \dots, x_n) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$$

线元 ds^2 也可以看成一个二次型，只不过代入了向量微分 $d\mathbf{X} = (dx_1, dx_2, \dots, dx_n)$ 。更一般地，如下形状的二次微分式也可以当作二次型来研究：

$$f(dx_1, dx_2, \dots, dx_n) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} dx_i dx_j$$

7.1.4 * 自伴算子

矩阵是对线性映射的表示。但现在我们又说，广义实内积可以表示为实对称矩阵。两种看法能不能统一起来呢？考察广义实内积的矩阵表达式：

$$(\alpha, \beta) = \mathbf{X}^T A \bar{\mathbf{Y}} = (x_1, x_2, \dots, x_n) \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

我们可以这样看待这个表达式：它无非是在一个标准内积式 $\mathbf{X}^T \mathbf{Y}$ 中间插入了一个实对称矩阵 A ，变成 $\mathbf{X}^T A \mathbf{Y}$ 。如果把 A 看成欧氏空间 V 上的一个线性变换 $\mathcal{A}$ ，那么我们会获得一个关于内积的全新理解：欧氏空间中的任意广义内积结构都可以看成该空间上的一个线性变换 $\mathcal{A}$ ，两个向量 α, β 的广义内积就是让 $\mathcal{A}$ 作用在其中一个向量上，再让二者做 $\mathbb{C}^n$ 中的标准内积。

A 是对称矩阵这一点对 $\mathcal{H}$ 提出了一个限制。如果欧氏空间中的线性变换能表示为实对称矩阵，那么称这种变换为**自伴算子**。相应的表示矩阵（实对称矩阵）称为**自伴矩阵**。注意这里实质上并没有引入新的数学概念，只是借助“自伴”的名称引入了一种对于实对称矩阵的新观点。任意的广义内积可以看成是某个自伴算子加权下的标准内积。自伴算子的性质及其与内积的关系可由下式表示：

$$(\alpha, \beta) = (\mathcal{A}\alpha, \beta)_{\mathbb{R}} = (\alpha, \mathcal{A}\beta)_{\mathbb{R}}$$

其中 $(\cdot, \cdot)$ 是欧氏空间 V 上的某个内积，它在给定基下表示为矩阵 A 。而 $(\cdot, \cdot)_{\mathbb{R}}$ 是指两个向量在给定基下的坐标下进行 $\mathbb{R}^n$ 上的标准内积。

我们借助矩阵表达式进一步地理解这一点。按矩阵的乘法结合律，表达式 $\mathbf{X}^T A \mathbf{Y}$ 有两种结合方式：

$$(x_1, x_2, \dots, x_n) \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = (x_1, x_2, \dots, x_n) \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

左式为 $\mathbf{X}^T (A \mathbf{Y})$ ，即如果让 $\mathcal{A}$ 作用在 β 上（坐标为 $\mathbf{Y}$ ），则可以看出 $\mathcal{A}$ 的表示矩阵应为 A 。右式为 $(\mathbf{X}^T A) \mathbf{Y} = (A^T \mathbf{X})^T \mathbf{Y}$ 。即如果让 $\mathcal{A}$ 作用在 α 上（坐标为 $\mathbf{X}$ ），则可以看出 $\mathcal{A}$ 的表示矩阵应为 A^T 。要求 A 是自伴矩阵，即是要求 $A = A^T$ 是 $\mathcal{A}$ 的同一个表示矩阵。

7.1.5 矩阵的合同

我们知道（广义）内积的定义是无关于坐标系（基）的选取的，但是度规矩阵的写法却与基的选择有关。这与线性映射及其表示矩阵的关系类似，但是在内积背景下，就给出了一种不同于矩阵相似的基变换关系。

设 n 维欧氏空间中规定了一个（广义）内积 $(\cdot, \cdot)$ 。它在基 $\{\mathbf{e}_i\}$ 下的度规矩阵为 A 。向量 α, β 在这组基下的坐标分别为 $\mathbf{X}$ 和 $\mathbf{Y}$ 。则 $(\alpha, \beta) = \mathbf{X}^T A \mathbf{Y}$ 。若基变换 $\{\mathbf{e}_i\} \mapsto \{\mathbf{e}'_i\}$ 以 P 为过渡矩

阵, 新旧坐标之间的关系 $PX' = X$, $PY' = Y$. 于是有:

$$(\alpha, \beta) = X^T AY = (PX')^T APY' = X'(P^T AP)Y'$$

可见同一个内积在新基下的度规矩阵为 $P^T AP$. 也就是说, 对于实对称矩阵 A , 如果存在 n 阶可逆矩阵 P 使得 $B = P^T AP$ (此时 B 必然也是实对称的), 则矩阵 A 和 B 是 **同一个广义内积在不同基下的度规矩阵**. 此时我们称矩阵 A 和 B 是**合同的**. 变换 $A \mapsto P^T AP$ 称为**合同变换**. 可以证明相似变换是一种等价关系:

(1) 反身性: 取 $P = I$, 显然 $I^T AI = A$.

(2) 对称性: 如果 A 合同于 B , 即存在可逆矩阵 P 使得 $B = P^T AP$. 取 $Q = P^{-1}$, 则 $A = Q^T BQ$, 因此 B 与 A 合同.

(3) 传递性: 如果 A 与 B 合同, B 与 C 合同, 即存在可逆矩阵 P, Q , 使得 $B = P^T AP$, $C = Q^T BQ$, 则 $C = Q^T P^T APQ$. 取 $R = PQ$, 则 $C = R^T AR$, 即 A 与 C 合同.

如果把实对称矩阵 A 考虑成一个二次型矩阵, 那么我们说两个**二次型等价**, 就等同于说它们的二次型矩阵是合同的. 当我们做坐标变换 $X = PX'$ 时 (P 是可逆矩阵), 在二次型的视角看来, 其实就是做了一个变量替换 $(x_1, x_2, \dots, x_n) \mapsto (x'_1, x'_2, \dots, x'_n)$. 这种用可逆矩阵定义的变量替换称为**非退化线性替换**.

度规矩阵在合同关系下的不变量称为**合同不变量**. 同一个广义内积在不同的基下对应着不同的度规矩阵, 但是这些度规矩阵应该有共同的, 与基的选择无关的性质. 度规矩阵的这类性质可以看成是 (广义) 内积结构本身的属性, 这就是合同不变量的意义. 关于“不变量”思想的理解, 请与相似不变量相互参考. 好消息是, 合同不变量比相似不变量简单得多, 可以找出完全不变量. 也就是说, 我们在线性代数的课程范围内就可以做到对矩阵在合同意义下进行完全分类, 并找出所谓“合同标准型”. 这等价于对欧氏空间中所有可能的 (广义) 内积结构进行了完全分类. 我们将在下一节详细讨论.

7.1.6 保度规变换与正交矩阵

欧氏空间中的线性变换可能会改变空间的几何. 例如在 $\mathbb{R}^2$ 中直观地看, 伸缩和剪切会导致形变, 而反射和旋转却不会. 类似于后者的变换是特别重要的. 例如物理中的刚体运动, 正是保持物体内部的长度, 夹角等所有几何性质完全不变的一种运动. 我们提出**保内积**的概念来描述这种变换. 我们将这个性质抽象成如下的数学描述:

如果欧氏空间上规定了 (广义) 内积 $(\cdot, \cdot)$, 在给定基下的度规矩阵为 A . 存在线性变换 M , 满足对任意的 α, β (坐标分别为 X, Y), 有:

$$(\mathcal{M}\alpha, \mathcal{M}\beta) = (\alpha, \beta)$$

那么 $\mathcal{M}$ 称为保内积变换.

在这个话题中, 我们总是在用一组基下描述问题, 不涉及基的变换. 因此所谓“保内积”就是“保度规”. 设 $\mathcal{M}$ 的表示矩阵为 M , 则等价地有 M 满足:

$$(MX)^T A(MY) = X^T AY, \quad \text{即 } X^T M^T AMY = X^T AY$$

由此可以看出 M 应该满足 $M^T AM = A$, 这就是“保度规”的意思.

作为具体例子, 我们考察欧氏度规 (单位矩阵) I 的保度规变换.

根据定义, 它满足 $M^T IM = I$, 即 $M^T = M^{-1}$. 有这一性质的变换 $\mathcal{M}$ 称为**正交变换**, 表示矩阵 M 称为**正交矩阵**. 所谓正交变换, 就是指保持欧氏距离和夹角不变的变换, 简而言之就是旋转或者反射变换. 因此, 不难想象正交矩阵应该长什么样. 我们说, 一个线性变换可以由它在一组标准正交基上的作用唯一确定, 表现为矩阵的列向量组. 而正交矩阵代表了保持欧氏距离和夹角不变的变换. 因此, 正交矩阵的列向量应该是一组单位正交基, 即每一个列向量的欧氏长度为 1, 且两两正交.

不出意外的话, 欧氏几何是大家唯一熟悉的几何, 因此正交变换也是大家唯一能够直观理解的保度规变换. 但是对于学过狭义相对论的同学, 不妨思考保度规变换在其中的应用: 狭义相对论的时空几何是由闵氏度规 $\eta = \text{diag}(-1, 1, 1, 1)$ 来描述. 保闵氏度规的变换 Λ 满足 $\Lambda^T \eta \Lambda = \eta$. Λ 就是**洛伦兹变换**. 洛伦兹变换给出了不同惯性系下时空坐标变换的规律. 于是我们知道, 惯性系的切换只是一种 4 维时空的“转动”. 在不同的惯性系下, (闵氏度规下的) 时空距离是不变量.

7.2 矩阵合同的进一步讨论

7.2.1 合同标准型和规范型

设 A 是 n 阶实对称矩阵. 为了研究矩阵在合同意义下的分类, 与上一章类似地, 我们提出课题: 能否找到一个可逆矩阵 C , 使得 $C^T AC$ 是对角矩阵? 与之等价的问题是, 对于一个二次型 $X^T AX$, 能否找到一个非退化线性替换 $X = CY$, 使得替换后的二次型只含有平方项而不含有交叉项? 我们把这种对角矩阵 (只有平方项的二次型) 称为矩阵 A (或者二次型 $X^T AX$) 的**合同标准型**.

任何实对称矩阵都能化成合同标准型吗? 答案是可以, 而且不难给出理由: 我们在上一章就知道, 实对称矩阵一定可以正交对角化. 所谓正交对角化是指, 存在正交矩阵 C , 使得 $C^{-1}AC$ 为

对角矩阵. 但是注意正交矩阵的性质 $C^T = C^{-1}$, $C^{-1}AC$ 其实就是 C^TAC . 也就是说, 把实对称矩阵的正交对角化, 其实就是化为了合同标准型. 实对称矩阵的相似标准型就是一个合同标准型. 因此, 计算合同标准型根本不需要新的方法, 只需要按照上一章的方法, 去计算正交对角化即可. 当然, 也有别的办法更直接地去操作合同变换, 进而得到合同标准型, 将在习题部分介绍.

这里需要澄清的是, 实对称矩阵的合同标准型并不是唯一的, 可逆矩阵 C 的选取也不是唯一的. 因此, 虽然实对称矩阵总是与其相似标准型是合同的, 也并不意味着相似不变量一定就是合同不变量, 只能说相似不变量可以反映某些合同的性质. 具体将在下一小节中分析.

我们已经能找到实对称矩阵 A 的一个合同标准型 D . 设 D 是如下的对角矩阵:

$$D = \text{diag}(d_1, \dots, d_p, -d_{p+1}, \dots, -d_r, 0, 0 \dots, 0)$$

对应的二次型是:

$$f = d_1 x_1^2 + \dots + d_p x_p^2 - d_{p+1} x_{p+1}^2 - \dots - d_r x_r^2$$

方便起见, 这里我们已将对角线上的正数、负数和零分别排列到一起 (这总是可以做到的). 也就是说这里的 d_i 全都为正数, $r \leq n$. 不难想到, 可以对二次型做进一步的化简:

$$x_i = \begin{cases} \frac{y_i}{\sqrt{d_i}}, & 1 \leq i \leq p \\ y_i, & r < i \leq n \end{cases}$$

得到的对角矩阵, 对角线上只含 1, -1 和 0:

$$D = \text{diag}(1, \dots, 1, -1, \dots, -1, 0, 0 \dots, 0)$$

对应的二次型是:

$$f = y_1^2 + \dots + y_p^2 - y_{p+1}^2 - \dots - y_r^2$$

这似乎是我们能得到形式最简单的东西. 我们将上述形状的对角矩阵 (二次型) 称为实对称矩阵 A (二次型 $\mathbf{X}^T A \mathbf{X}$) 的**规范型**. 从直观上, 标准型之所以不唯一, 是因为系数的“大小”可以是任意的. 究其根本, 是说对于同一个 (广义) 内积结构而言, 用度规矩阵“测量出来的长度”并不是绝对的, 而是可以通过选取不同的基来任意确定. 这就好比一根 1 m 长的木棍, 同时也是 10 dm 和 100 cm——不同单位的选取会让长度的“读数”发生变化. 因此, 对角元的绝对大小在合同关系中并不重要. 把标准型进一步变换为规范型, 正是剔除了这一冗余的信息.

一个 n 阶实对称矩阵的规范型, 其实只需要两个数字就能确定: p 和 r . 其中 r 是非零元 (± 1) 的个数, 其实也就是秩 (注意秩也是合同不变量). p 则是 1 的个数, 我们称为**正惯性指数**. 方便起见, 我们还约定规范型中 -1 的个数 $r - p$ 为**负惯性指数**, 正惯性指数减去负惯性指数所得的差 $2p - r$ 称为**号差**.

7.2.2 规范型的进一步讨论

在教材中证明了, n 阶实对称矩阵的规范型总是存在且唯一的. 也就是说, 谈论一个实对称矩阵作为 (广义) 内积的性质, 就等同于谈论其规范型的性质. 根据上一小节最后的讨论, **秩与正惯性指数**组成了二次型 (矩阵) 的一组完全不变量. 我们可以分别从主动观点和被动观点来理解这一点. 从主动观点来看: **不同的 (广义) 内积结构, 本质上只有秩和正惯性指数的不同.** 从被动观点来看: **同一个内积结构虽然对应不同的度规矩阵, 但是它们的秩和正惯性指数是确定的.**

这里我们以闵氏度规 $\eta = \text{diag}(-1, 1, 1, 1)$ 为例简要说明这个结论的意义. 在闵氏度规下, 三个空间轴对应的 4 维矢量 $(0, x, 0, 0)^T, (0, 0, y, 0)^T, (0, 0, 0, z)^T$ 长度的平方为正数, 这反映了 3 维空间具有我们所熟悉的实内积性质. 而时间轴对应的 4 维矢量 $(t, 0, 0, 0)^T$ 长度的平方为负数. 借用这些物理上的背景, 我们提出以下概念: 在给定了广义内积结构的实线性空间中, 长度的平方为正的矢量称为**类空矢量**; 长度的平方为负的矢量称为**类时矢量**; 长度的平方为零的矢量称为**类光矢量**. 一个广义内积结构最本质的作用是将整个空间划分为**类空区域、类时区域和类光区域**. 我们可以不太严谨地说, 所谓正/负惯性指数, 就是指整个空间中类空/类时区域的维数. 比如, 从闵氏度规中可以读出, 闵氏时空中有 1 个时间维度, 3 个空间维度.

以上我们明确了, 可以使用规范型作为合同等价类的代表元. 我们引入以下的词汇来描述不同类型的实对称矩阵 (广义内积结构/规范型):

(1) 实对称矩阵 A 是**正定的**, 当且仅当以 A 为度规的广义内积是正定的 (即: A 是一个实内积的度规矩阵), 当且仅当 A 的规范型的对角元全为 1 (单位矩阵 I_n).

(2) 实对称矩阵 A 是**负定的**, 当且仅当以 A 为度规的广义内积是负定的 (非零向量长度的平方为负数), 当且仅当 A 的规范型的对角元全为 -1 (负单位矩阵 $-I_n$).

(3) 实对称矩阵 A 是**半正定的**, 当且仅当以 A 为度规的广义内积是半正定的 (非零向量长度的平方为非负数), 当且仅当 A 的规范型的对角元全为 1 和 0.

(4) 实对称矩阵 A 是**半负定的**, 当且仅当以 A 为度规的广义内积是半负定的 (非零向量长度的平方为非正数), 当且仅当 A 的规范型的对角元全为 -1 和 0.

(5) 实对称矩阵 A 是**不定的**, 当且仅当以 A 为度规的广义内积是不定的 (非零向量长度的平方可正可负), 当且仅当 A 的规范型的对角元既有 1 又有 -1 . 不定矩阵可以分为满秩 (规范型对角线上没有 0) 和不满秩 (规范型对角线上有 0) 两种.

这样我们就对广义内积结构进行了完全的分类. 这个分类既可以从广义内积本身叙述, 也可以从度规矩阵 (实对称矩阵) 和二次型的角度来叙述. 当然最简单的是从规范型的角度来叙述 (对角线上是否有 1, $-1, 0$). 这些叙述方式的切换需要熟记于心.

最后做两点补充:

(1) 一个实对称矩阵的秩和正负惯性指数从合同标准型也能看出来. 而相似标准型(对角线为 n 个实特征值)就是一个合同标准型. 因此, **实对称矩阵的非零特征值的数量就是它的秩, 正特征值的数量就是正惯性指数**. 从解题的角度, 这一结论沟通了合同与相似这两种不同的关系, 并且可以由此衍生出一些结论. 比如: 一个实对称矩阵是正定的, 当且仅当它的所有特征值都是正数. 有一些问题在合同的框架下看起来没法处理, 联系到相似关系就能轻松处理了. 比如: 为什么 A 正定可以推出 A^{-1} 正定?

(2) 实对称矩阵正定还有一个等价条件, 即**所有顺序主子式都大于 0**. 这个定理在正定性相关的计算题中常用(见习题部分). 关于它的证明, 后面也会结合其他相关习题一起讲解.

7.3 * 复内积空间

7.3.1 复内积的定义及其矩阵表示

实内积是以 $\mathbb{R}^n$ 上的标准内积为模板的, 那么复内积应当是以 $\mathbb{C}^n$ 上的标准内积为模板. 因此我们首先要讲清楚 $\mathbb{C}^n$ 上的标准内积如何定义. 我们当然希望他和 $\mathbb{R}^n$ 中的标准内积一样: 设 $\alpha = (a_1, a_2, \dots, a_n)^T$, $\beta = (b_1, b_2, \dots, b_n)^T$ 则它们的内积(希望)定义成:

$$(\alpha, \beta) = a_1 b_1 + a_2 b_2 + \dots + a_n b_n$$

但不妙的是这种定义不仅不满足正定性, 甚至一个向量与自身的内积都不一定是实数. 例如向量 $(1+i, 1+i)$. 于是, 我们对标准内积的定义做一些调整, 牺牲一些别的性质来保护正定性. 方法是在做内积时让某一个向量取复共轭, 使得 (α, α) 中辐角相互抵消. 于是, $\mathbb{C}^n$ 中的标准内积定义为:

$$(\alpha, \beta) = a_1 \overline{b_1} + a_2 \overline{b_2} + \dots + a_n \overline{b_n}$$

这样定义的复标准内积就满足了正定性, 但是牺牲了对称性. 取而代之的新性质是**共轭对称性**: $(\alpha, \beta) = \overline{(\beta, \alpha)}$.

以 $\mathbb{C}^n$ 中的标准内积为模板, 可以叙述一般复内积的定义:

设 V 是 $\mathbb{C}$ 上的线性空间. 定义 V 上的一个二元函数 $(\cdot, \cdot) : V \times V \rightarrow \mathbb{C}$, 即: 对于任意 $x, y \in V$, (x, y) 都对应一个复数. 如果对任意的 $x, y \in V$, $\alpha \in \mathbb{C}$, 满足以下 4 条规则, 那么称 V 是复内积空间(酉空间), 这个二元函数是 V 上的一个复内积:

(1) **正定性**: $(x, x) \geq 0$, 等号成立当且仅当 $x = 0$.

(2) 共轭对称性: $(\mathbf{x}, \mathbf{y}) = \overline{(\mathbf{y}, \mathbf{x})}$.

(3) 线性 (数乘): $(\alpha \mathbf{x}, \mathbf{y}) = \alpha (\mathbf{x}, \mathbf{y})$.

(4) 线性 (加法): $(\mathbf{x} + \mathbf{y}, \mathbf{z}) = (\mathbf{x}, \mathbf{z}) + (\mathbf{y}, \mathbf{z})$.

复内积的表示与实内积的思路是类似的, 但因为复内积满足的是共轭对称性, 表达式上有一些调整. 首先, 对内积进行展开得到的是:

$$(\boldsymbol{\alpha}, \boldsymbol{\beta}) = \left(\sum_{i=1}^n a_i \mathbf{e}_i, \sum_{j=1}^n b_j \mathbf{e}_j \right) = \sum_{i=1}^n \sum_{j=1}^n a_i \overline{b_j} g_{ij}$$

写成矩阵形式是:

$$(\boldsymbol{\alpha}, \boldsymbol{\beta}) = (a_1, a_2, \dots, a_n) \begin{pmatrix} g_{11} & g_{12} & \cdots & g_{1n} \\ g_{21} & g_{22} & \cdots & g_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ g_{n1} & g_{n2} & \cdots & g_{nn} \end{pmatrix} \begin{pmatrix} \overline{b_1} \\ \overline{b_2} \\ \vdots \\ \overline{b_n} \end{pmatrix}$$

这里 g_{ij} 给出一个复矩阵 H . $\boldsymbol{\alpha}, \boldsymbol{\beta}$ 在给定基下的内积表示为 $(\boldsymbol{\alpha}, \boldsymbol{\beta}) = \mathbf{X}^T H \overline{\mathbf{Y}}$. 由于复内积有共轭对称性, H 与自身的共轭转置 $\overline{H}^T$ 相等. 我们把复矩阵 H 的共轭转置记为 $H^\dagger$. 则 H 满足 $H = H^\dagger$. 满足此一性质的复矩阵称为 Hermite 矩阵. 可以把共轭转置看成转置在复矩阵中的推广, 把 Hermite 矩阵看成实对称矩阵的推广.

由内积的正定性可知, $\mathbf{X}^T H \overline{\mathbf{X}} > 0$ 对于任意非零向量 $\mathbf{X}$ 成立, 因此复度规矩阵 H 也是正定矩阵. 表达式 $\mathbf{X}^T H \overline{\mathbf{X}}$ 称为 Hermite 型.

由此看出, 酉空间中的复内积与正定 Hermite 矩阵之间存在一一对应.

考虑最简单的复标准内积矩阵 I (单位矩阵). 如果一个酉空间中的线性变换 (表示矩阵为 U) 保内积, 模仿实内积中关于度规矩阵的讨论, 我们知道 $U^T I \overline{U} = I$, 即 $U^{-1} = U^\dagger$. 这样的矩阵 U 称为酉矩阵. 它相当于正交矩阵在酉空间中的推广, 表示酉空间中复内积下的“刚体运动”.

7.3.2 自伴矩阵及其性质

在讨论广义实内积的时候, 我们曾经给出了自伴算子的概念, 并说自伴矩阵就是实对称矩阵.

按照完全相同的讨论, 我们也可以称 Hermite 矩阵对应的复线性变换是自伴算子, 自伴矩阵就是 Hermite 矩阵. 实对称矩阵只是 $\mathbb{R}$ 上的矩阵看作 $\mathbb{C}$ 上的矩阵的特殊情况.

设 H 是自伴矩阵. 则按照定义, 对任意的 $\mathbf{X}, \mathbf{Y} \in \mathbb{C}^n$, 有:

$$(H\mathbf{X}, \mathbf{Y}) = (\mathbf{X}, H\mathbf{Y})$$

其中 $(\cdot, \cdot)$ 表示 $\mathbb{C}^n$ 上的标准内积. H 作为自伴算子的表示矩阵, 自然可以纳入上一章的课题来研究, 即我们问自伴矩阵是否一定可对角化? 它在对角化的过程中有什么特殊的性质?

H 作为一个复矩阵, 根据代数基本定理 (n 次多项式一定有 n 个复根), 它一定有 n 个复特征值 λ_i . 设 $\mathbf{X}$ 是其中任意一个特征值 λ 的一个特征向量. 考虑内积 $(H\mathbf{X}, \mathbf{Y})$. 我们发现:

$$(H\mathbf{X}, \mathbf{Y}) = (\lambda\mathbf{X}, \mathbf{Y}) = \lambda(\mathbf{X}, \mathbf{Y})$$

另一方面, 可以利用自伴矩阵的性质, 把 H 转移到 2 号位上. 注意运用复内积的共轭线性, 得到:

$$(H\mathbf{X}, \mathbf{Y}) = (\mathbf{X}, H\mathbf{Y}) = (\mathbf{X}, \lambda\mathbf{Y}) = \bar{\lambda}(\mathbf{X}, \mathbf{Y})$$

两式比较, 得到 $\lambda = \bar{\lambda}$, 即 λ 是实数. 也就是说, **自伴矩阵一定有 n 个实特征值!**

再来看特征向量的性质. 设 λ_1, λ_2 是自伴矩阵 H 的两个不同的特征值, 它们分别有特征向量 $\mathbf{X}_1, \mathbf{X}_2$. 考虑内积 $(H\mathbf{X}_1, \mathbf{X}_2)$. 我们发现:

$$(H\mathbf{X}_1, \mathbf{X}_2) = (\lambda_1\mathbf{X}_1, \mathbf{X}_2) = \lambda_1(\mathbf{X}_1, \mathbf{X}_2)$$

另一方面, 可以利用自伴矩阵的性质, 把 H 转移到 2 号位上. 注意运用复内积的共轭线性, 得到:

$$(H\mathbf{X}_1, \mathbf{X}_2) = (\mathbf{X}_1, H\mathbf{X}_2) = (\mathbf{X}_1, \lambda_2\mathbf{X}_2) = \lambda_2(\mathbf{X}_1, \mathbf{X}_2)$$

比较上下二式, 发现 $\lambda_1(\mathbf{X}_1, \mathbf{X}_2) = \lambda_2(\mathbf{X}_1, \mathbf{X}_2)$. 但 $\lambda_1 \neq \lambda_2$, 因此只能是 $(\mathbf{X}_1, \mathbf{X}_2) = 0$, 即 $\mathbf{X}_1$ 与 $\mathbf{X}_2$ 相互正交. 也就是说, **自伴矩阵 H 的属于不同特征值的特征向量相互正交!**

最后, 我们还能证明自伴矩阵 H 一定可以实对角化. 证明过程用到了复矩阵的一个重要定理: 任何复矩阵 A 一定可以酉相似上三角化, 即存在酉矩阵 U 和上三角矩阵 D , 使得 $U^{-1}AU = D$.

现在将这里的 A 设为自伴矩阵 H . 因为 U 是酉矩阵, 所以 $U^\dagger HU = D$. 对这个等式两边取共轭转置, 得到 $U^\dagger H^\dagger U = U^\dagger HU = D^\dagger$. 比较两式, 可知上三角矩阵 $D = D^\dagger$. 这表明 D 是对角矩阵. 因此最初的等式 $U^{-1}HU = D$ 表明自伴矩阵 H 一定可以酉相似对角化.

从上述讨论中可以看出, 自伴矩阵的特殊性质是来自于复内积的共轭线性. 而“实对称矩阵一定可以正交对角化”的性质, 其实是将实对称矩阵作为 $\mathbb{C}$ 上的矩阵, 也就是复的自伴矩阵看待的结果.

7.4 习题

7.4.1 合同标准型和规范型

本章的典型计算题是把一个实对称矩阵化为合同标准型/规范型. 注意看清题目究竟是问标准型还是规范型.

化合同标准型的方法有三种:

(1) 直接配方法. 这种方法一般是最快的, 很适合做计算题时使用. 缺点在于它纯粹是代数运算, 理论上的意义不大.

(2) 成对初等行列变换法. 合同变换式 $C^T A C$, C 可以看成对 A 进行了一系列初等列变换, 而 C^T 则是进行了一系列相对应的初等行变换. 因此, 可以在 A 下放并排摆放一个单位矩阵, 然后与 A 一同做成对的初等行列变换, 使得 A 化为标准型. 此时, 下方的单位矩阵就记录着所做的所有列变换, 因此它经历变换后得到的就是 C . 这个方法速度也不慢, 做计算题时可用, 而且做一些证明题时需要用到这个理解.

(3) 相似对角化. 因为实对称矩阵总是可以正交相似对角化, 而正交相似变换就是一种合同变换, 所以相似标准型就是一种合同标准型. 直接用上一章的办法去计算正交相似对角化即可. 这个方法比较慢, 对于计算题来说是下策, 但是做一些证明题时需要用到这个理解.

例 7.1. 思考:

(1) n 阶实对称矩阵, 有多少个合同等价类?

(2) 对于复对称矩阵而言, “惯性指数”是什么?

解答.

(1) 问题等同于 n 阶实对称矩阵有几种不同的规范型. 秩为 r 的规范型有 $r+1$ 种. 因此不同的规范型共有 $1+2+\cdots+n+(n+1) = \frac{(n+1)(n+2)}{2}$.

(2) 复对称矩阵不必区分正负惯性指数, 秩就是完全的合同不变量.

例 7.2. 将下述二次型化为标准型, 并写出所做的非退化线性替换.

(1) $f(x_1, x_2, x_3) = x_1^2 + x_2^2 + x_3^2 + x_1x_2 + x_1x_3 + x_2x_3.$

(2) $f(x_1, x_2, x_3) = x_1x_2 + x_1x_3 + x_2x_3.$

解答. (I. 直接配方法)

(1)

$$\begin{aligned}
f(x_1, x_2, x_3) &= x_1^2 + x_1(x_2 + x_3) + x_2^2 + x_3^2 + x_2x_3 \\
&= (x_1 + \frac{1}{2}x_2 + \frac{1}{2}x_3)^2 - \frac{1}{4}(x_2 + x_3)^2 + x_2^2 + x_3^2 + x_2x_3 \\
&= (x_1 + \frac{1}{2}x_2 + \frac{1}{2}x_3)^2 + \frac{3}{4}x_2^2 + \frac{3}{4}x_3^2 + \frac{1}{2}x_2x_3 \\
&= (x_1 + \frac{1}{2}x_2 + \frac{1}{2}x_3)^2 + \frac{3}{4}(x_2 + \frac{1}{3}x_3)^2 + \frac{2}{3}x_3^2
\end{aligned}$$

做非退化线性替换:

$$\begin{cases} y_1 = x_1 + \frac{1}{2}x_2 + \frac{1}{2}x_3 \\ y_2 = x_2 + \frac{1}{3}x_3 \\ y_3 = x_3 \end{cases}$$

就将二次型化成了标准型 $g(y_1, y_2, y_3) = y_1^2 + \frac{3}{4}y_2^2 + \frac{2}{3}y_3^2$.

(2) 为了找平方项, 先做非退化线性替换:

$$\begin{cases} y_1 = x_1 + x_2 \\ y_2 = x_1 - x_2 \\ y_3 = x_3 \end{cases}$$

代入, 二次型化为 $g(y_1, y_2, y_3) = \frac{1}{4}y_1^2 - \frac{1}{4}y_2^2 + y_3y_1$. 再进行配方:

$$g(y_1, y_2, y_3) = \frac{1}{4}y_1^2 - \frac{1}{4}y_2^2 + y_3y_1 = (\frac{1}{2}y_1 + y_3)^2 - \frac{1}{4}y_2^2 - y_3^2$$

再做非退化线性替换:

$$\begin{cases} z_1 = \frac{1}{2}y_1 + y_3 \\ z_2 = y_2 \\ z_3 = y_3 \end{cases}$$

就将二次型化成了标准型 $h(z_1, z_2, z_3) = z_1^2 - \frac{1}{4}z_2^2 - z_3^2$. 所做的总的非退化线性替换为:

$$\begin{cases} z_1 = \frac{1}{2}x_1 + \frac{1}{2}x_2 + x_3 \\ z_2 = x_1 - x_2 \\ z_3 = x_3 \end{cases}$$

解答. (II. 成对初等变换法)

(1)

$$\begin{pmatrix} 1 & 1/2 & 1/2 \\ 1/2 & 1 & 1/2 \\ 1/2 & 1/2 & 1 \\ -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \xrightarrow[r_2-1/2 \cdot r_1]{c_2-1/2 \cdot c_1} \begin{pmatrix} 1 & 0 & 1/2 \\ 0 & 3/4 & 1/4 \\ 1/2 & 1/4 & 1 \\ -1 & -1/2 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \xrightarrow[r_3-1/2 \cdot r_1]{c_3-1/2 \cdot c_1} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 3/4 & 1/4 \\ 0 & 1/4 & 3/4 \\ -1 & -1/2 & -1/2 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\xrightarrow[r_3-1/3 \cdot r_2]{c_3-1/3 \cdot c_2} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 3/4 & 0 \\ 0 & 0 & 3/4 \\ -1 & -1/2 & -1/3 \\ 0 & 1 & -1/3 \\ 0 & 0 & 1 \end{pmatrix}$$

做非退化线性替换 $\mathbf{X} = \mathbf{C}\mathbf{Y}$, 能使二次型化为标准型 $g(y_1, y_2, y_3) = y_1^2 + \frac{3}{4}y_2^2 + \frac{2}{3}y_3^2$. 其中:

$$C = \begin{pmatrix} 1 & -1/2 & -1/3 \\ 0 & 1 & -1/3 \\ 0 & 0 & 1 \end{pmatrix}$$

(2)

$$\begin{pmatrix} 0 & 1/2 & 1/2 \\ 1/2 & 0 & 1/2 \\ 1/2 & 1/2 & 0 \\ -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \xrightarrow[r_2-r_1]{c_2-c_1} \begin{pmatrix} 0 & 1/2 & 1/2 \\ 1/2 & -1 & 0 \\ 1/2 & 0 & 0 \\ -1 & -1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \xrightarrow[r_1 \leftrightarrow r_2]{c_1 \leftrightarrow c_2} \begin{pmatrix} -1 & 1/2 & 0 \\ 1/2 & 0 & 1/2 \\ 0 & 1/2 & 0 \\ -1 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\xrightarrow[r_2+1/2 \cdot r_2]{c_2+1/2 \cdot c_1} \begin{pmatrix} -1 & 0 & 0 \\ 0 & 1/4 & 1/2 \\ 0 & 1/2 & 0 \\ -1 & 1/2 & 0 \\ 1 & 1/2 & 0 \\ 0 & 0 & 1 \end{pmatrix} \xrightarrow[r_3-2 \cdot r_2]{c_3-2 \cdot c_2} \begin{pmatrix} -1 & 0 & 0 \\ 0 & 1/4 & 0 \\ 0 & 0 & -1 \\ -1 & 1/2 & -1 \\ 1 & 1/2 & -1 \\ 0 & 0 & 1 \end{pmatrix}$$

做非退化线性替换 $\mathbf{X} = \mathbf{C}\mathbf{Y}$, 能使二次型化为标准型 $g(y_1, y_2, y_3) = -y_1^2 + \frac{1}{4}y_2^2 - y_3^2$. 其中:

$$C = \begin{pmatrix} -1 & 1/2 & -1 \\ 1 & 1/2 & -1 \\ 0 & 0 & 1 \end{pmatrix}$$

例 7.3. 设实二次型

$$f(\mathbf{X}) = f(x_1, x_2, x_3) = x_1^2 + x_2^2 + x_3^2 + 2ax_1x_2 + 2ax_1x_3 + 2ax_2x_3, \quad a \in \mathbb{R} \text{ 为参数}$$

可用非退化线性替换 $\mathbf{X} = \mathbf{C}\mathbf{Y}$ 化成二次型

$$g(\mathbf{Y}) = g(y_1, y_2, y_3) = y_1^2 + y_2^2 + 4y_3^2 + 2y_1y_2$$

(1) 求参数 a 的值.

(2) 求把 $f(\mathbf{X})$ 化成 $g(\mathbf{Y})$ 的非退化线性替换中的可逆矩阵 C .

解答.

(1) 写出 $f(\mathbf{X})$ 和 $g(\mathbf{Y})$ 的二次型矩阵:

$$A = \begin{pmatrix} 1 & a & a \\ a & 1 & a \\ a & a & 1 \end{pmatrix} \quad B = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 4 \end{pmatrix}$$

计算可逆矩阵 C_1 , 将 B 化为规范型:

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1/2 \\ -1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 4 \end{pmatrix} \begin{pmatrix} 1 & 0 & -1 \\ 0 & 0 & 1 \\ 0 & 1/2 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad \text{即 } C_1^T B C_1 = \text{diag}(1, 1, 0)$$

可以看出 B 的秩为 2. 因此 A 的秩也应该为 2. 计算 A 的行列式 $|A| = (a-1)^2(2a+1)$. 由 $|A|$ 的行列式为 0 可知 $a=1$ 或 $a=-\frac{1}{2}$. 但是当 $a=1$ 时 A 的秩显然为 1, a 只能是 $-\frac{1}{2}$.

(2) 再计算可逆矩阵 C_2 , 将 A 化为规范型:

$$\begin{pmatrix} \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{3}} & 0 \\ \frac{1}{3} & \frac{1}{3} & -\frac{2}{3} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \end{pmatrix} \begin{pmatrix} 1 & -\frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & 1 & -\frac{1}{2} \\ -\frac{1}{2} & -\frac{1}{2} & 1 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{3}} & \frac{1}{3} & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{3}} & \frac{1}{3} & \frac{1}{\sqrt{3}} \\ 0 & -\frac{2}{3} & \frac{1}{\sqrt{3}} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad \text{即 } C_2^T A C_2 = \text{diag}(1, 1, 0)$$

于是我们有:

$$C_1^T B C_1 = C_2^T A C_2 \quad \text{即 } B = (C_1^T)^{-1} C_2^T A C_2 C_1^{-1}$$

题目中要求的 C 为:

$$C = C_2 C_1^{-1} = \begin{pmatrix} \frac{1}{\sqrt{3}} & \frac{2}{\sqrt{3}} & \frac{2}{3} \\ -\frac{1}{\sqrt{3}} & 0 & \frac{2}{3} \\ 0 & \frac{1}{\sqrt{3}} & -\frac{4}{3} \end{pmatrix}$$

7.4.2 正定二次型

判断一个实对称矩阵是否正定, 常用的办法是验证顺序主子式是否全部大于 0.

例 7.4. 判断 $I_n + J_n$ 是否为正定矩阵.

分析. 可以去计算顺序主子式, 但是更快的方法是去证 n 个特征值都为正.

证明. (I. 顺序主子式)

$I_n + J_n$ 的顺序主子式都形如 $|I_k + J_k|$, 其中 $1 \leq k \leq n$. 用初等变换法化简之:

$$\begin{vmatrix} 2 & 1 & 1 & \cdots & 1 \\ 1 & 2 & 1 & \cdots & 1 \\ 1 & 1 & 2 & \cdots & 1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & 1 & \cdots & 2 \end{vmatrix} = \begin{vmatrix} 2 & 1 & 1 & \cdots & 1 \\ -1 & 1 & 0 & \cdots & 0 \\ -1 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -1 & 0 & 0 & \cdots & 1 \end{vmatrix} = \begin{vmatrix} n-1 & 1 & 1 & \cdots & 1 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{vmatrix} = n-1 > 0$$

所有顺序主子式都大于 0, 因此 $I_n + J_n$ 是正定的. $\square$

证明. (II. 特征值)

J_n 的秩为 1, 因此 0 是 J_n 的 $n-1$ 重特征值. 而 J_n 的迹为 n , 因此 n 也是特征值. 由此知道 J_n 的特征多项式 $|\lambda I_n - J_n| = \lambda^{n-1}(\lambda - n)$.

考虑 $I_n + J_n$ 的特征多项式: $|\lambda I_n - (I_n + J_n)| = |(\lambda - 1)I_n - J_n|$. 与 $|\lambda I_n - J_n|$ 比较, 无非是将 λ 替换为了 $\lambda - 1$. 因此 $|\lambda I_n - (I_n + J_n)| = (\lambda - 1)^{n-1}(\lambda - n - 1)$. $\lambda = 1$ 是 $n-1$ 重特征值, $\lambda = n+1$ 是 1 重特征值, 它们全都是正数, 因此 $I_n + J_n$ 是正定矩阵. $\square$

例 7.5.

(1) 若二次型

$$f(x_1, x_2, x_3) = 2x_1^2 + x_2^2 + x_3^2 + 2x_1x_2 + tx_2x_3$$

是正定的, 求 t 的取值范围.

(2) 当 $a_1, a_2, \dots, a_n$ 满足什么条件时, 实二次型

$$f(x_1, x_2, \dots, x_n) = (x_1 + a_1x_2)^2 + (x_2 + a_2x_3)^2 + \cdots + (x_{n-1} + a_{n-1}x_n)^2 + (x_n + a_nx_1)^2$$

是正定的?

分析. 第 (1) 问比较常规, 可用顺序主子式来计算. 但是第 (2) 问要这样做就有点难了. 请注意第 (2) 问已经是一个半正定的二次型.

解答.

(1) 二次型矩阵:

$$\begin{pmatrix} 2 & 1 & 0 \\ 1 & 1 & t/2 \\ 0 & t/2 & 1 \end{pmatrix}$$

其 1 阶和 2 阶顺序主子式显然都是正数. 而 3 阶顺序主子式 (即它自身的行列式):

$$\Delta_3 = \begin{vmatrix} 2 & 1 & 0 \\ 1 & 1 & t/2 \\ 0 & t/2 & 1 \end{vmatrix} = 1 - \frac{t^2}{2}$$

则该二次型正定当且仅当 $\Delta_3 > 0$, 即 $t \in (-\sqrt{2}, \sqrt{2})$.

(2) 注意这已经是一个半正定二次型. 它等于 0 当且仅当每一项都为 0. 因此, 如果这个二次型是正定的, 那么要求它每一项都为 0 当且仅当 $x_1 = x_2 = \cdots = x_n = 0$, 即下列线性方程组只有零解:

$$\begin{cases} x_1 + a_1 x_2 = 0 \\ x_2 + a_2 x_3 = 0 \\ \cdots \\ x_n + a_n x_1 = 0 \end{cases}$$

这就等同于说它的系数矩阵 A 行列式不为 0. 即:

$$\det A = \begin{vmatrix} 1 & a_1 & 0 & \cdots & 0 \\ 0 & 1 & a_2 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \cdots & \cdots & \cdots & \ddots & \cdots \\ a_n & 0 & 0 & \cdots & 1 \end{vmatrix} = 1 - (-1)^n a_1 a_2 \cdots a_n \neq 0$$

□

例 7.6. 设 A 是 $\mathbb{R}$ 上的 n 阶正定矩阵, 任取非零列向量 $\alpha \in \mathbb{R}^n$, 有:

$$\begin{vmatrix} A & \alpha \\ \alpha^T & 0 \end{vmatrix} < 0$$

分析. 通过成对的分块初等行列变换, 将其合同变换为分块对角矩阵.

证明. 对矩阵做成对分块初等行列变换 (在下式中用初等分块矩阵乘法表示), 化为分块对角矩阵:

$$\begin{pmatrix} I_n & 0 \\ -\alpha^T A^{-1} & 1 \end{pmatrix} \begin{pmatrix} A & \alpha \\ \alpha^T & 0 \end{pmatrix} \begin{pmatrix} I_n & -A^{-1}\alpha \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} A & 0 \\ 0 & -\alpha^T A^{-1}\alpha \end{pmatrix}$$

这里因为 A 是正定矩阵, 所以 A 可逆. 又知道 A 的所有特征值都为正, 则 A^{-1} 的所有特征值也都为正, 所以 A^{-1} 也是正定矩阵. 因为 α 是非零向量, 根据正定矩阵的定义, $-\alpha^T A^{-1}\alpha < 0$. 于是有:

$$\begin{vmatrix} A & \alpha \\ \alpha^T & 0 \end{vmatrix} = \begin{vmatrix} A & 0 \\ 0 & -\alpha^T A^{-1}\alpha \end{vmatrix} = \det(A) \cdot \det(-\alpha^T A^{-1}\alpha) < 0$$

□

例 7.7. 设矩阵 A :

$$\begin{pmatrix} 3 & -1 & 1 \\ -1 & 3 & 1 \\ 1 & 1 & 3 \end{pmatrix}$$

(1) 证明 A 是正定矩阵.

(2) 求可逆正定矩阵 C , 使得 $C^2 = A$.

(3) 思考: 设 A 是任意实对称矩阵, 存在正定实对称矩阵 C 使得 $C^2 = A$ 是 A 正定的充要条件吗?

分析. 对于第 (2) 问和第 (3) 问, 考虑如果 A 是标准型, 能否写出符合题意的 C ? 现在 A 本身不是一个标准型, 如何利用合同变换联系到标准型的分解?

证明.

(1) 计算顺序主子式:

$$\begin{aligned}\Delta_1 &= 3 \\ \Delta_2 &= \begin{vmatrix} 3 & -1 \\ -1 & 3 \end{vmatrix} = 8 \\ \Delta_3 &= \begin{vmatrix} 3 & -1 & 1 \\ -1 & 3 & 1 \\ 1 & 1 & 3 \end{vmatrix} = 16\end{aligned}$$

都是正数, 因此 A 是正定矩阵.

(2) 对于任意 n 阶的实对称正定矩阵 A , 考虑 A 的相似标准型 $D = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$. 因为 A 是实对称矩阵, 所以存在正交矩阵 P , 使得 $A = PDP^{-1}$. 又因为 A 是正定矩阵, 所以 A 的全部特征值 $\lambda_i > 0$. 则 D 可以分解为 $D = D_1^2$, 其中 $D_1 = \text{diag}(\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_n})$. 于是 A 可以做如下分解:

$$A = PDP^{-1} = PD_1D_1P^{-1} = (PD_1P^{-1})(PD_1P^{-1})$$

则 PD_1P^{-1} 就是符合题目要求的矩阵 C . 注意 P 是正交矩阵, $C = PD_1P^T$ 是正定实对称的. 计算 A 的相似对角化, 可知:

$$D = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 4 \end{pmatrix}, \quad P = \begin{pmatrix} -\frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} \\ -\frac{1}{\sqrt{3}} & 0 & -\frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} \end{pmatrix}$$

题目要求的矩阵 C 为:

$$C = PD_1P^T = \begin{pmatrix} \frac{5}{3} & -\frac{1}{3} & \frac{1}{3} \\ -\frac{1}{3} & \frac{5}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{5}{3} \end{pmatrix}$$

(3) 是充要条件. 必要性在 (2) 中已经证明了. 现在证明充分性. 已知存在正定实对称矩阵 C , 使得 $C^2 = A$. 则任取非零向量 $\mathbf{X}$, 有:

$$\mathbf{X}^T \mathbf{A} \mathbf{X} = \mathbf{X}^T C^2 \mathbf{X} = (\mathbf{X}^T C^T)(C \mathbf{X}) = (C \mathbf{X})^T (C \mathbf{X}) \geq 0$$

因此 A 是正定矩阵.

□

例 7.8.

(1) 证明: n 级实对称矩阵 A 正定的充要条件是, 存在 $m \times n$ 列满秩实矩阵 P , 使得

$$A = P^T P$$

(2) 证明: n 级实对称矩阵 A 半正定的充要条件是, 存在 $r \times n$ 行满秩实矩阵 Q , 使得

$$A = Q^T Q$$

分析. 考虑如果 A 是标准型, 能否做出符合题意的分解?

证明.

(1) A 正定当且仅当存在可逆 n 阶矩阵 C , 使得 $C^T A C = I_n$. 而 I_n 可以按照题意做如下分解:

$$I_n = (I_n \ O^T)_{n \times m} \begin{pmatrix} I_n \\ O \end{pmatrix}_{m \times n}$$

其中 $m \leq n$ (否则 $m \times n$ 矩阵不可能是列满秩的), O 是 $(n-m) \times n$ 阶零矩阵 (若 $m = n$, 则不存在这个矩阵块). 代入并整理, 得到:

$$A = (C^T)^{-1} I_n C^{-1} = (C^T)^{-1} (I_n \ O^T) \begin{pmatrix} I_n \\ O \end{pmatrix} C^{-1}$$

于是 A 就分解成了 $A = P^T P$, 其中 P 是 $m \times n$ 列满秩矩阵:

$$P = \begin{pmatrix} I_n \\ O \end{pmatrix} C^{-1}$$

(2) A 半正定当且仅当存在可逆 n 阶矩阵 C , 使得:

$$C^T A C = \begin{pmatrix} I_r & O \\ O & O \end{pmatrix}_{n \times n}$$

其中 $r < n$. 而这个标准型可以按照题意做如下分解:

$$\begin{pmatrix} I_r & O \\ O & O \end{pmatrix}_{n \times n} = \begin{pmatrix} I_r \\ O^T \end{pmatrix}_{n \times r} (I_r \ O)_{r \times n}$$

其中, O 是 $r \times (n-r)$ 阶零矩阵. 代入并整理, 得到:

$$A = (C^T)^{-1} \begin{pmatrix} I_r & O \\ O & O \end{pmatrix}_{n \times n} C^{-1} = (C^T)^{-1} \begin{pmatrix} I_r \\ O^T \end{pmatrix} (I_r \ O) C^{-1}$$

于是 A 就分解成了 $A = Q^T Q$, 其中 Q 是 $r \times n$ 列满秩矩阵:

$$Q = \begin{pmatrix} I_r & O \end{pmatrix} C^{-1}$$

□

7.4.3 数学归纳法

在二次型问题中, 对矩阵阶数 n 做数学归纳法来证明一些结论. 关键的操作是:

(1) 把 n 阶矩阵 A 切出一行一列来, 形成 2×2 分块矩阵.

(2) 做合同变换 (成对分块初等行列变换), 使其化为分块对角矩阵. 在这个过程中, 对于左上角的 $(n-1) \times (n-1)$ 矩阵块, 可以利用归纳假设来处理.

例 7.9. 证明: n 阶实对称矩阵 A 正定的充要条件是 A 的所有顺序主子式都大于 0.

证明. (1) “ $\Rightarrow$ ”: 已知 A 正定. $|A_k|$ 是 A 的 k 阶顺序主子式, 即 A 可以分块为:

$$A = \begin{pmatrix} A_k & * \\ * & * \end{pmatrix}$$

取 $\begin{pmatrix} \delta_k \\ \mathbf{0} \end{pmatrix}$ 是后 $n-k$ 个分量为 0, 前 k 个分量不全为 0 的列向量. 因为 A 正定, 所以:

$$0 < \begin{pmatrix} \delta_k^T & \mathbf{0}^T \end{pmatrix} \begin{pmatrix} A_k & * \\ * & * \end{pmatrix} \begin{pmatrix} \delta_k \\ \mathbf{0} \end{pmatrix} = \delta_k^T A_k \delta_k$$

这表明 A_k 也是正定矩阵. 而正定矩阵的行列式为正数, 因此 A 的 k 阶顺序主子式 $|A_k|$ 为正数. 由 k 的任意性可知, A 的全部顺序主子式都是正数.

(2) “ $\Leftarrow$ ”: 已知 A 的全部顺序主子式都是正数. 对矩阵 A 的阶数 n 做数学归纳法.

(i) 当 $n=1$ 时, 结论显然.

(ii) 当 $n>1$ 时, 假设结论对任意 $n-1$ 阶实对称矩阵都成立. 现有 n 阶实对称矩阵 A , 满足全部顺序主子式都是正数. 把 A 分块成:

$$A = \begin{pmatrix} A_{n-1} & \boldsymbol{\alpha} \\ \boldsymbol{\alpha}^T & a_{nn} \end{pmatrix},$$

其中 A_{n-1} 是 $n-1$ 阶实对称矩阵, 它的全部顺序主子式就是 A 的前 $n-1$ 个顺序主子式. 根据归纳假设, A_{n-1} 是正定矩阵.

对 A 做成对的分块初等行列变换 (在下式中用初等分块矩阵乘法表示), 化为分块对角矩阵:

$$\begin{pmatrix} I_{n-1} & 0 \\ -\boldsymbol{\alpha}^T A_{n-1}^{-1} & 1 \end{pmatrix} \begin{pmatrix} A_{n-1} & \boldsymbol{\alpha} \\ \boldsymbol{\alpha}^T & a_{nn} \end{pmatrix} \begin{pmatrix} I_{n-1} & -A_{n-1}^{-1} \boldsymbol{\alpha} \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} A_{n-1} & 0 \\ 0 & b \end{pmatrix}$$

其中 $b = a_{nn} - \boldsymbol{\alpha}^T A_{n-1}^{-1} \boldsymbol{\alpha}$. 两边取行列式, 得: $|A| = |A_{n-1}|b$. 注意其中 $|A|$ 和 $|A_{n-1}|$ 都是正数, 因此 $b > 0$.

因为 A_{n-1} 正定, 所以存在 $n-1$ 阶可逆矩阵 C_{n-1} , 使得 $C_{n-1}^T A_{n-1} C_{n-1} = I_{n-1}$. 因此有:

$$\begin{pmatrix} C_{n-1}^T & 0 \\ 0 & \sqrt{b} \end{pmatrix} \begin{pmatrix} A_{n-1} & 0 \\ 0 & b \end{pmatrix} \begin{pmatrix} C_{n-1} & 0 \\ 0 & \sqrt{b} \end{pmatrix} = \begin{pmatrix} I_{n-1} & 0 \\ 0 & 1 \end{pmatrix}$$

这说明原来的矩阵 A 合同于 n 阶单位矩阵 I_n , 因此 A 是正定矩阵. □

例 7.10. 设 A 为实对称正定矩阵, 试证明: 必存在对角元都是正数的下三角矩阵 L , 使得 $A = LL^T$ 并且这个分解是唯一的.

证明. 对矩阵 A 的阶数 n 做数学归纳法.

(i) 当 $n = 1$ 时, $A = (a)$, $a > 0$, 则 $(a) = (\sqrt{a})(\sqrt{a})$, 结论显然成立.

(ii) 当 $n > 1$ 时, 假设结论对任意 $n - 1$ 阶实对称正定矩阵都成立. 现有 n 阶实对称正定矩阵 A . 把 $A = (a_{ij})$ 分块成:

$$A = \begin{pmatrix} A_{n-1} & \boldsymbol{\alpha} \\ \boldsymbol{\alpha}^T & a_{nn} \end{pmatrix},$$

其中 A_{n-1} 是 $n - 1$ 阶实对称矩阵.

A 是正定矩阵, 则 A 的所有顺序主子式都为正, 而 A_{n-1} 的顺序主子式就是 A 的前 $n - 1$ 个顺序主子式, 所以 A_{n-1} 正定.

对 A 做成对的分块初等行列变换 (在下式中用初等分块矩阵乘法表示), 化为分块对角矩阵:

$$\begin{pmatrix} I_{n-1} & 0 \\ -\boldsymbol{\alpha}^T A_{n-1}^{-1} & 1 \end{pmatrix} \begin{pmatrix} A_{n-1} & \boldsymbol{\alpha} \\ \boldsymbol{\alpha}^T & a_{nn} \end{pmatrix} \begin{pmatrix} I_{n-1} & -A_{n-1}^{-1} \boldsymbol{\alpha} \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} A_{n-1} & 0 \\ 0 & b \end{pmatrix}$$

其中 $b = a_{nn} - \boldsymbol{\alpha}^T A_{n-1}^{-1} \boldsymbol{\alpha}$. 两边取行列式, 得:

$$|A| = |A_{n-1}|b$$

因为 A 是正定矩阵, 所以 $|A|$ 和 $|A_{n-1}|$ 都是正数, 则 b 也是正数. 将上式整理成对 A 的分解式:

$$A = \begin{pmatrix} A_{n-1} & \boldsymbol{\alpha} \\ \boldsymbol{\alpha}^T & a_{nn} \end{pmatrix} = \begin{pmatrix} I_{n-1} & 0 \\ -\boldsymbol{\alpha}^T A_{n-1}^{-1} & 1 \end{pmatrix}^{-1} \begin{pmatrix} A_{n-1} & 0 \\ 0 & b \end{pmatrix} \begin{pmatrix} I_{n-1} & -A_{n-1}^{-1} \boldsymbol{\alpha} \\ 0 & 1 \end{pmatrix}^{-1}$$

即:

$$A = L_2 \begin{pmatrix} A_{n-1} & 0 \\ 0 & b \end{pmatrix} L_2^T, \text{ 其中下三角矩阵 } L_2 = \begin{pmatrix} I_{n-1} & 0 \\ -\boldsymbol{\alpha}^T A_{n-1}^{-1} & 1 \end{pmatrix}^{-1} \text{ 对角元为正数}$$

由于 $b > 0$, 且 A_{n-1} 正定, 由归纳假设, 存在对角元为正数的下三角矩阵 L_1 , 使得 $A_{n-1} = L_1 L_1^T$. 另外 $b = \sqrt{b} \cdot \sqrt{b}$. 于是有:

$$\begin{pmatrix} A_{n-1} & 0 \\ 0 & b \end{pmatrix} = \begin{pmatrix} L_1 & 0 \\ 0 & \sqrt{b} \end{pmatrix} \begin{pmatrix} L_1 & 0 \\ 0 & \sqrt{b} \end{pmatrix}^T.$$

因此, $A = L_2 L_3 L_3^T L_2^T$. 记 $L = L_2 L_3$, 则 L 是对角元为正数的下三角矩阵, 且 $A = LL^T$. 因此结论对 n 阶矩阵 A 也成立.

□

例 7.11. 已知 n 阶实对称矩阵 A 的各阶顺序主子式 $\Delta_1, \Delta_2, \dots, \Delta_n$ 都不为零. 证明: 二次型 $f(\mathbf{X}) = \mathbf{X}^T A \mathbf{X}$ 可由非退化线性替换 $\mathbf{X} = C\mathbf{Y}$ 化为下述标准型:

$$f = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \dots + \lambda_n y_n^2$$

$$\text{其中 } \lambda_k = \frac{\Delta_k}{\Delta_{k-1}}, \Delta_0 = 1.$$

证明. 等同于去证明存在 n 阶可逆矩阵 C , 使得 $C^T A C = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$, 其中 λ_i 符合题目叙述.

对矩阵 A 的阶数 n 做数学归纳法:

(i) 当 $n = 1$ 时, 结论显然.

(ii) 假设结论对 $n - 1$ 阶实对称矩阵成立. 现有 A 是 n 阶实对称矩阵, 其各阶顺序主子式都不为零. 对矩阵 A 分块:

$$A = \begin{pmatrix} A_{n-1} & \boldsymbol{\alpha} \\ \boldsymbol{\alpha}^T & a_{nn} \end{pmatrix}$$

其中 A_{n-1} 是 $n - 1$ 阶实对称矩阵, 其顺序主子式 $\Delta_1, \Delta_2, \dots, \Delta_{n-1}$ 都不为零. 根据归纳假设, 存在 $n - 1$ 阶矩阵 S , 使得 $S^T A_{n-1} S = D_{n-1}$. 其中 $D_{n-1} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{n-1})$. 其中, $\lambda_k = \Delta_k / \Delta_{k-1}$, $\Delta_0 = 1$.

对 A 进行分块初等行列变换, 使之化为分块对角矩阵. 首先利用归纳假设把左上角的矩阵块处理成对角矩阵:

$$\begin{pmatrix} S^T & O \\ O & 1 \end{pmatrix} \begin{pmatrix} A_{n-1} & \boldsymbol{\alpha} \\ \boldsymbol{\alpha}^T & a_{nn} \end{pmatrix} \begin{pmatrix} S & O \\ O & 1 \end{pmatrix} = \begin{pmatrix} D_{n-1} & S^T \boldsymbol{\alpha} \\ \boldsymbol{\alpha}^T S & a_{nn} \end{pmatrix} \quad \text{记 } P = \begin{pmatrix} S & O \\ O & 1 \end{pmatrix}$$

接着去消除反对角线上的元素: 将第一行左乘 $-\boldsymbol{\alpha}^T S D_{n-1}^{-1}$ 加到第二行上, 将第一列右乘 $-D_{n-1}^{-1} S^T \boldsymbol{\alpha}$ 加到第二列上. 即:

$$\begin{pmatrix} I_{n-1} & O \\ -\boldsymbol{\alpha}^T S D_{n-1}^{-1} & 1 \end{pmatrix} \begin{pmatrix} D_{n-1} & S^T \boldsymbol{\alpha} \\ \boldsymbol{\alpha}^T S & a_{nn} \end{pmatrix} \begin{pmatrix} I_{n-1} & -D_{n-1}^{-1} S^T \boldsymbol{\alpha} \\ O & 1 \end{pmatrix} = \begin{pmatrix} D_{n-1} & O \\ O & b \end{pmatrix} \quad \text{记 } Q = \begin{pmatrix} I_{n-1} & -D_{n-1}^{-1} S^T \boldsymbol{\alpha} \\ O & 1 \end{pmatrix}$$

其中 $b = a_{nn} - \boldsymbol{\alpha}^T S D_{n-1}^{-1} S^T \boldsymbol{\alpha}$. 两边取行列式, 注意 $|P| = |S|$, $|Q| = 1$. 得:

$$b = \frac{|P^T Q^T A Q P|}{|D_{n-1}|} = \frac{|P^T Q^T A Q P|}{|S^T A_{n-1} S|} = \frac{|A|}{|A_{n-1}|} = \frac{\Delta_n}{\Delta_{n-1}} = \lambda_n$$

于是 A 合同于 $\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$.

综合 (i), (ii) 可知, 结论对任意 n 阶实对称矩阵 A 成立.

□

7.4.4 * 二次型的应用

例 7.12. 设二元实值函数 $F(x, y)$ 有一个稳定点 $\alpha = (x_0, y_0)$. $F(x, y)$ 在 (x_0, y_0) 邻域内有三阶连续偏导数. 如何利用 $F(x, y)$ 在 (x_0, y_0) 处的各个二阶偏导数判断该点是否为极值点? (回忆高等数学中的定理) 相关结论能否推广至 n 元函数?

解答. (x_0, y_0) 是稳定点, 一阶微分为 0. 因此泰勒展开的最低阶为 2 阶:

$$2(F(x_0 + \Delta x, y_0 + \Delta y) - F(x_0, y_0)) \approx F_{xx}(x_0, y_0) \cdot (\Delta x)^2 + 2 \cdot F_{xy}(x_0, y_0) \cdot \Delta x \Delta y + F_{yy}(x_0, y_0) \cdot (\Delta y)^2$$

右式是一个二阶微分式, 实际上也是一个关于 $(\Delta x, \Delta y)$ 的二次型, 其二次型矩阵称为 Hessian 矩阵:

$$H = \begin{pmatrix} F_{xx}(x_0, y_0) & F_{xy}(x_0, y_0) \\ F_{xy}(x_0, y_0) & F_{yy}(x_0, y_0) \end{pmatrix}, \quad \text{记为} \quad \begin{pmatrix} A & B \\ B & C \end{pmatrix}$$

如果 $\Delta x, \Delta y \neq 0$, 则 (x_0, y_0) 是极小值点当且仅当在邻域内满足 $F(x_0 + \Delta x, y_0 + \Delta y) - F(x_0, y_0) > 0$. 即上述二次型是正定的, 亦即 H 是正定矩阵. 利用顺序主子式可写出条件是 $A > 0$ 且 $AC - B^2 > 0$.

类似地, (x_0, y_0) 是极小值点当且仅当 H 负定, 即 $A < 0$ 且 $AC - B^2 > 0$.

(x_0, y_0) 不是极值点当且仅当 H 不定, 即 $AC - B^2 < 0$.

其余情况下 (H 不满秩), 无法通过二阶导数判断 (x_0, y_0) 是否为极值点.

例 7.13.

(1) $\mathbb{R}^3$ 中的曲面 $z^2 + 5x^2 + 4xy + 2y^2 = 1$ 是什么类型的二次曲面?

(2) $\mathbb{R}^2$ 中的曲线 $5x^2 + 4xy + 2y^2 - 24x - 12y + 18 = 0$ 是什么类型的二次曲线?

分析. 注意正交矩阵的意义是刚体运动, 因此对曲面/曲线方程进行正交替换, 曲面/曲线的类型不改变.

解答. (1) 考虑二次型 $5x^2 + 4xy + 2y^2$. 其二次型矩阵:

$$A = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}$$

计算其特征值为 $\lambda_1 = 6, \lambda_2 = 1$. 解出其正交对角化 $C^{-1}AC = \text{diag}(6, 1)$. 其中正交矩阵 C :

$$C = \begin{pmatrix} \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \end{pmatrix}$$

因此做正交替换:

$$\begin{pmatrix} x \\ y \end{pmatrix} = C \begin{pmatrix} x' \\ y' \end{pmatrix}$$

代入曲线方程将得到 $z^2 + 6x'^2 + y'^2 = 1$. 这是个椭球面, 因此原曲面也是椭球面.

利用 (1) 中的正交替换, 代入曲线方程, 得到 $6x'^2 + y'^2 - 12\sqrt{5}x' + 18 = 0$. 进一步配方化简得到曲线方程为 $6(x - \sqrt{5})^2 + y'^2 = 12$. 这是个椭圆, 因此原曲线也是椭圆.